


**DESAIN PARAMETER *BUCK CONVERTER* BERBASIS
*ARTIFICIAL INTELLIGENCE***

SKRIPSI



Disusun oleh:

KRISHNA LAKSHETA
20/460177/TK/50766

**PROGRAM SARJANA PROGRAM STUDI TEKNIK ELEKTRO
DEPARTEMEN TEKNIK ELEKTRO DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK UNIVERSITAS GADJAH MADA
YOGYAKARTA
2024**

HALAMAN PENGESAHAN

DESAIN PARAMETER *BUCK CONVERTER* BERBASIS *ARTIFICIAL INTELLIGENCE*

SKRIPSI

Diajukan Sebagai Salah Satu Syarat untuk Memperoleh
Gelar Sarjana Teknik
pada Departemen Teknik Elektro dan Teknologi Informasi
Fakultas Teknik
Universitas Gadjah Mada

Disusun oleh:

KRISHNA LAKSHETA
20/460177/TK/50766

Telah disetujui dan disahkan

Pada tanggal

Dosen Pembimbing I

Dosen Pembimbing II

Dr.-Ing. Ir. Yohan Fajar Sidik, S.T., M.Eng.
NIP 111199001202205101

Prof. Dr.Eng. Ir. F. Danang Wijaya, S.T., M.T., IPM.
NIP 197402261998031003

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini :

Nama : Krishna Laksheta
NIM : 20/460177/TK/50766
Tahun terdaftar : 2020
Program : Sarjana
Program Studi : Teknik Elektro
Fakultas : Teknik Universitas Gadjah Mada

Menyatakan bahwa dalam dokumen ilmiah Skripsi ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam daftar pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah Skripsi ini di kemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, 10 Juli 2024

Materai Rp10.000

(Tanda tangan)

Krishna Laksheta
20/460177/TK/50766

HALAMAN PERSEMBAHAN

Tugas akhir ini kupersembahkan kepada kedua orang tuaku. Kupersembahkan pula kepada keluarga dan teman-teman semua, serta untuk bangsa, negara, dan agamaku.

KATA PENGANTAR

Segala puji dan syukur saya panjatkan atas segala berkat dan kesempatan yang telah memungkinkan saya menyelesaikan tugas akhir berupa penyusunan skripsi ini dengan baik. Dalam proses penyusunan tugas akhir ini, penulis telah banyak menerima arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin mengucapkan terima kasih kepada:

1. Prof. Ir. Hanung Adi Nugroho, S.T., M.E., Ph.D., IPM., SMIEEE., Kepala Departemen Teknik Elektro, yang telah memberikan izin dan dukungan untuk penyusunan skripsi ini.
2. Ir. Lesnanto Multa Putranto, S.T., M.Eng., Ph.D., IPM., SMIEEE., Sekretaris Departemen Teknik Elektro, yang telah memberikan arahan dan bantuan administratif selama proses penyusunan skripsi.
3. Yohan Fajar Sidik, Dr.-Ing. Ir. , S.T., M.Eng., Dosen Pembimbing 1, yang telah memberikan topik tugas akhir, membimbing dari awal proses pengerjaan tugas akhir, sampai dengan naskah ini dapat selesai.
4. Prof. Dr.Eng. Ir. F. Danang Wijaya, S.T., M.T., IPM., sebagai Dosen Pembimbing 2, yang telah memberikan banyak wawasan terkait penulisan topik dan juga membimbing sampai naskah selesai.
5. Kedua orang tua dan adik yang selalu memberikan arahan, dukungan moral, serta doa yang tiada henti selama proses belajar dan penyelesaian tugas akhir ini. Dukungan dan bimbingan mereka sangat berarti dalam mencapai menyelesaikan naskah ini.
6. Teman-teman Laboratorium SST, Mas Mus, Mas Doni, Lathief, dan Diamond, yang menjadi teman belajar dan bermain selama proses penulisan naskah ini berlangsung.
7. Teman olahraga, Vito Hartanto, yang telah menemani di kala penat dengan berolahraga di GMC.
8. Seseorang yang namanya tak dapat saya sebutkan, namun kehadirannya telah memberikan motivasi dan dukungan yang tak terhingga.
9. Sahabat-sahabat dan rekan-rekan mahasiswa yang telah memberikan semangat, bantuan, dan kerja sama selama masa studi dan penyusunan skripsi ini.

Akhir kata, saya berharap semoga skripsi ini dapat memberikan manfaat bagi kita semua.

DAFTAR ISI

HALAMAN PENGESAHAN	ii
PERNYATAAN BEBAS PLAGIASI	iii
HALAMAN PERSEMBAHAN	iv
KATA PENGANTAR	v
DAFTAR ISI	vi
DAFTAR TABEL	x
DAFTAR GAMBAR	xii
DAFTAR SINGKATAN.....	xiii
INTISARI.....	xiv
ABSTRACT	xv
BAB I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	2
1.4 Batasan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Sistematika Penulisan.....	3
BAB II Tinjauan Pustaka dan Dasar Teori	5
2.1 Tinjauan Pustaka	5
2.1.1 Metode Desain Sirkuit Konverter Daya	5
2.1.1.1 Metode Konvensional	5
2.1.1.2 Metode CAO	6
2.1.1.3 Metode AI.....	7
2.1.2 Perbandingan Metode Desain Sirkuit Konverter Daya	8
2.2 Dasar Teori	10
2.2.1 <i>Buck Converter</i>	10
2.2.1.1 Pendahuluan	10
2.2.1.2 Prinsip Kerja	11
2.2.1.3 Komponen <i>Buck Converter</i>	14
2.2.1.4 Topologi	16
2.2.1.5 Rugi Daya	19
2.2.1.6 Perhitungan Parameter.....	22
2.2.2 <i>Machine Learning</i>	26
2.2.2.1 Jenis pembelajaran <i>Machine Learning</i>	26
2.2.2.2 <i>Neural Network</i>	27
2.2.2.3 Evaluasi <i>Machine Learning</i>	28

2.2.3	Optimisasi	31
2.2.3.1	Metode Optimisasi.....	31
2.2.4	Perbandingan Metode	34
2.2.4.1	Topologi <i>Buck Converter</i>	34
2.2.4.2	Jenis <i>Machine Learning</i>	35
2.2.4.3	Metode Optimisasi.....	36
2.2.5	Kriteria Pemilihan Metode	37
BAB III Metode Penelitian.....		39
3.1	Alat dan Bahan Tugas akhir	39
3.1.1	Alat Tugas akhir.....	39
3.1.2	Bahan Tugas akhir	39
3.2	Metode yang Digunakan.....	40
3.2.1	Topologi <i>Buck Converter</i>	40
3.2.1.1	Rangkaian <i>Synchronous Buck Converter</i>	40
3.2.1.2	Pemilihan Komponen.....	41
3.2.2	<i>Machine Learning</i>	41
3.2.2.1	Pembuatan Data Set	41
3.2.2.2	Pembuatan Model <i>Machine Learning</i>	42
3.2.3	Metode Optimisasi	43
3.2.4	Perhitungan Parameter Sirkuit Konvensional	44
3.2.5	Perbandingan dan Analisis Hasil Desain Parameter.....	44
3.2.5.1	Kriteria Perbandingan	44
3.2.5.2	Metode Evaluasi	45
3.2.5.3	Analisis Hasil Perbandingan	45
3.3	Alur Tugas Akhir	46
3.3.1	Studi Literatur	46
3.3.2	Analisis Kebutuhan Sistem	46
3.3.3	Desain Parameter Sirkuit	48
3.3.3.1	Desain Parameter Sirkuit Konvensional	48
3.3.3.2	Desain Parameter Sirkuit Berbasis Pendekatan AI.....	50
3.3.3.3	Perbandingan dan Analisis Hasil.....	56
3.3.4	Dokumentasi dan Pelaporan	56
BAB IV Perancangan Desain Parameter Sirkuit		57
4.1	Pengantar	57
4.2	Rangkaian <i>Synchronous Buck Converter</i>	57
4.2.1	Spesifikasi Rangkaian.....	57
4.2.2	Penentuan Rentang Batasan Nilai Komponen	58
4.2.3	Pemilihan Komponen	59
4.2.4	Implementasi Rangkaian dalam PLECS	61

4.3	Desain Parameter Sirkuit Berbasis Pendekatan AI	64
4.3.1	Pembuatan Data Set	65
4.3.1.1	Data Set Kapasitansi	65
4.3.1.2	Data Set Induktansi	65
4.3.1.3	Data Set Simulasi PLECS	65
4.3.1.4	Penyimpanan Data Set Simulasi	68
4.3.2	Pembuatan Model <i>Machine Learning</i>	68
4.3.2.1	Persiapan Data Set	68
4.3.2.2	Teknik <i>Machine Learning</i>	70
4.3.2.3	Proses Pelatihan	70
4.3.2.4	Evaluasi Model	71
4.3.2.5	Penyimpanan Model <i>Machine Learning</i>	71
4.3.3	Implementasi Metode Optimisasi	71
BAB V	Hasil dan Pembahasan	75
5.1	Pendahuluan	75
5.2	Desain Parameter Sirkuit Konvensional	75
5.2.1	Hasil Perhitungan	75
5.2.1.1	<i>Duty Cycle</i>	76
5.2.1.2	<i>Dead Time</i>	76
5.2.1.3	Induktansi	76
5.2.1.4	Kapasitansi	76
5.2.2	Evaluasi Kinerja	77
5.2.2.1	Hasil Simulasi	77
5.2.2.2	Volume	78
5.3	Desain Parameter Sirkuit Berbasis Pendekatan AI	78
5.3.1	Data Set	79
5.3.1.1	Hasil Data Set	79
5.3.1.2	Analisis Data Set	80
5.3.2	Evaluasi Model <i>Machine Learning</i>	81
5.3.2.1	Model <i>Machine Learning</i>	81
5.3.2.2	Hasil Evaluasi	82
5.3.2.3	Analisis Hasil	83
5.3.3	Optimisasi dengan Algoritma Genetik	85
5.3.3.1	Hasil Nilai <i>Fitness</i>	85
5.3.3.2	Waktu Eksekusi	86
5.3.3.3	Hasil Parameter Optimisasi	87
5.3.4	Evaluasi Kinerja	87
5.3.4.1	Hasil Simulasi	87
5.3.4.2	Volume	88

5.4	Perbandingan Hasil Desain Parameter Sirkuit	88
5.4.1	Kinerja Desain Parameter Sirkuit	89
5.4.2	Hasil Simulasi	90
5.4.2.1	Grafik Arus	90
5.4.2.2	Grafik Tegangan	91
5.4.2.3	Analisis Hasil Perbandingan	92
BAB VI	Kesimpulan dan Saran	94
6.1	Kesimpulan	94
6.2	Saran	94
DAFTAR PUSTAKA		96

DAFTAR TABEL

Tabel 2.1	Perbandingan Referensi pada Metode Desain Sirkuit Konvensional .	8
Tabel 2.2	Perbandingan Referensi pada Metode Desain Sirkuit CAO	8
Tabel 2.3	Perbandingan Referensi pada Metode Desain Sirkuit AI.....	9
Tabel 2.4	Kelebihan dan Kekurangan Metode Desain Sirkuit Konverter Daya .	9
Tabel 2.5	Perbandingan <i>Asynchronous</i> dan <i>Synchronous Buck Converter</i>	34
Tabel 2.6	Perbandingan MOSFET, IGBT, dan BJT.....	34
Tabel 2.7	Jenis Pembelajaran <i>Machine Learning</i> - <i>Supervised Learning</i>	35
Tabel 2.8	Jenis Pembelajaran <i>Machine Learning</i> - <i>Unsupervised Learning</i>	36
Tabel 2.9	Jenis Pembelajaran <i>Machine Learning</i> - <i>Reinforcement Learning</i>	36
Tabel 2.10	Karakteristik Metode Optimisasi - <i>Gradient Descent</i>	37
Tabel 2.11	Karakteristik Metode Optimisasi - <i>Newton-Raphson</i>	37
Tabel 2.12	Karakteristik Metode Optimisasi - Algoritma Genetik	37
Tabel 2.13	Kriteria Pemilihan Metode	38
Tabel 3.1	Parameter dan Rumus yang Digunakan	44
Tabel 3.2	Parameter Kriteria Perbandingan	45
Tabel 4.1	Spesifikasi Rangkaian <i>Synchronous Buck Converter</i>	57
Tabel 4.2	Rentang Batasan Nilai untuk Setiap Parameter	58
Tabel 4.3	Parameter MOSFET yang Digunakan	59
Tabel 4.4	Rentang Batasan Nilai untuk Setiap Parameter (Lengkap)	60
Tabel 4.5	Parameter MOSFET yang Digunakan	61
Tabel 4.6	Kapasitansi dan Ukuran Fisik Kapasitor Seri Nippon KZE 25 V	61
Tabel 4.7	<i>Header</i> Parameter Data Set (C).....	65
Tabel 4.8	<i>Header</i> Parameter Data Set Induktansi (L).....	66
Tabel 4.9	Parameter Rugi-Rugi Daya	68
Tabel 4.10	Parameter Algoritma Genetik.....	71
Tabel 5.1	Hasil Desain Parameter Sirkuit Konvensional	75
Tabel 5.2	Hasil Simulasi PLECS - Metode Konvensional.....	77
Tabel 5.3	Volume Induktansi dan Kapasitansi - Metode Konvensional.....	78
Tabel 5.4	Struktur Data CSV	79
Tabel 5.5	Koefisien Variasi (KV) Parameter	80
Tabel 5.6	Model <i>Machine Learning</i> yang Digunakan	81
Tabel 5.7	Hasil Evaluasi Model <i>Machine Learning</i> MAE	82
Tabel 5.8	Hasil Evaluasi Model <i>Machine Learning</i> dengan <i>Huber Loss</i>	83
Tabel 5.9	Model <i>Machine Learning</i> yang Digunakan dan <i>Loss Function</i>	84
Tabel 5.10	Pengaturan Parameter Algoritma Genetik.....	85
Tabel 5.11	Waktu eksekusi optimisasi pada perangkat keras tertentu.	86
Tabel 5.12	Hasil Desain Parameter Sirkuit Berbasis Pendekatan AI.....	87
Tabel 5.13	Perbandingan Nilai Hasil Optimisasi dengan Nilai Hasil Simulasi PLECS	87
Tabel 5.14	Volume Induktansi dan Kapasitansi - Metode Pendekatan Berbasis AI.....	88
Tabel 5.15	Perbandingan Hasil Desain Parameter Sirkuit Konvensional dengan Pendekatan Berbasis AI	89

Tabel 5.16 Hasil Simulasi Desain Parameter Sirkuit	89
--	----

DAFTAR GAMBAR

Gambar 2.1	<i>Duty Cycle</i>	12
Gambar 2.2	Topologi <i>Buck Converter</i> - <i>Synchronous</i> dan <i>Asynchronous</i>	17
Gambar 2.3	Diagram Alir Algoritma Genetik.....	33
Gambar 3.1	Rangkaian <i>Synchronous Buck Converter</i>	40
Gambar 3.2	Diagram Alir Penelitian	47
Gambar 3.3	Diagram Alir Penelitian - Desain Parameter Sirkuit Konvensional	49
Gambar 3.4	Diagram Alir Penelitian - Desain Parameter Sirkuit <i>Machine Learning</i>	50
Gambar 3.5	Diagram Alir Penelitian - Desain Parameter Sirkuit <i>Machine Learning</i> - Pembuatan Data Set	51
Gambar 3.6	Diagram Alir Penelitian - Desain Parameter Sirkuit <i>Machine Learning</i> - Pembuatan Model <i>Machine Learning</i>	53
Gambar 3.7	Diagram Alir Penelitian - Desain Parameter Sirkuit <i>Machine Learning</i> - Pengembangan Metode Optimisasi.....	55
Gambar 4.1	Implementasi <i>Synchronous Buck Converter</i> dalam PLECS	62
Gambar 5.1	Grafik Nilai <i>Fitness</i>	86
Gambar 5.2	Grafik Arus - Metode Konvensional dan Metode Pendekatan Berbasis AI.....	90
Gambar 5.3	Grafik Arus - Metode Konvensional dan Metode Pendekatan Berbasis AI (4 ms - 5 ms)	91
Gambar 5.4	Grafik Tegangan - Metode Konvensional dan Metode Pendekatan Berbasis AI.....	92
Gambar 5.5	Grafik Tegangan - Metode Konvensional dan Metode Pendekatan Berbasis AI (4 ms - 5 ms)	92

DAFTAR SINGKATAN

AI	= <i>artificial intelligence</i>
CAO	= <i>computer-aided optimization</i>
NN	= <i>neural network</i>
MOSFET	= <i>metal-oxide-semiconductor field-effect transistor</i>
IGBT	= <i>insulated-gate bipolar transistor</i>
BJT	= <i>bipolar junction transistor</i>
RL	= <i>reinforcement learning</i>

INTISARI

Implementasi konverter daya dalam konversi dan kontrol daya listrik semakin meningkat dalam beberapa aplikasi (kendaraan listrik, energi terbarukan, dan lain-lain) sehingga memerlukan desain parameter sirkuit yang cermat. Desain parameter sirkuit dibutuhkan supaya dapat mengoptimalkan kinerja dan efisiensi konverter daya. Penelitian ini bertujuan untuk merancang salah satu konverter daya, *buck converter*, dengan pendekatan berbasis *artificial intelligence* (AI). Metodologi yang digunakan meliputi desain rangkaian *synchronous buck converter*, pembuatan model *machine learning* dengan *neural network*, implementasi algoritma genetik, dan analisis perbandingan dengan metode konvensional. Dengan data set hasil simulasi PLECS, data set induktansi, dan data set kapasitansi, model *machine learning* dapat memprediksi nilai tegangan keluaran, riak tegangan, arus induktor, riak arus, dan juga rugi-rugi daya. Model *machine learning* menjadi basis dalam implementasi algoritma genetik yang dijalankan dengan batasan eror riak tegangan ($\leq 1\%$), riak arus ($\leq 10\%$), dan juga volume total komponen ($\leq 7 \text{ cm}^3$). Hasil penelitian menunjukkan bahwa desain parameter sirkuit berbasis pendekatan AI memiliki efisiensi yang lebih tinggi, riak tegangan, dan riak arus induktor (99,3834 %, 0,1683 %, dan 9,7573 %) yang lebih baik dibandingkan dengan desain konvensional (99,3535 %, 1,1543 %, dan 11,6609 %). Selain itu, volume total dari metode berbasis pendekatan AI lebih ringkas dibandingkan hasil metode konvensional (5,7322 cm^3 dibandingkan dengan 7,716 cm^3). Hasil penelitian menunjukkan bahwa desain parameter sirkuit konvensional tidak memenuhi batasan eror riak tegangan, riak arus, dan juga volume total. Dengan demikian, penerapan AI dalam desain *buck converter* terbukti lebih efektif dalam meningkatkan efisiensi dan kinerja sistem konversi daya dibandingkan dengan metode konvensional.

Kata kunci: *buck converter*, efisiensi, *machine learning*, optimasi parameter, rugi daya

ABSTRACT

This research aims to design a synchronous buck converter with an AI-based approach. The methodology used includes circuit design of the synchronous buck converter, creating a machine learning model with a neural network, implementing genetic algorithms, and comparative analysis with conventional methods. With the PLECS simulation result data set, inductance data set, and capacitance data set, the machine learning model can predict the values of output voltage, voltage ripple, inductor current, current ripple, and power losses. The machine learning model becomes the basis for implementing a genetic algorithm that is run with error bounds on voltage ripple ($\leq 1\%$), current ripple ($\leq 10\%$), and total component volume ($\leq 7 \text{ cm}^3$). The results show that the circuit parameter design based on the AI approach has higher efficiency, voltage ripple, and inductor current ripple (99.3834 %, 0.1683 %, and 9.7573 %), which are better than the conventional design (99.3535 %, 1.1543 %, and 11.6609 %). In addition, the total volume of the AI approach-based method is more compact than the results of the conventional method (5.7322 cm^3 compared to 7.716 cm^3). The results show that the conventional circuit parameter design does not satisfy the error constraints of voltage ripple, current ripple, and total volume. Thus, the application of AI in the design of buck converter proved to be more effective in improving the efficiency and performance of the power conversion system compared to the conventional method.

Keywords : *buck converter, efficiency, machine learning, parameter optimization, power loss*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Elektronika daya adalah teknologi yang berkaitan dengan konversi dan kontrol daya listrik. Elektronika daya memiliki beberapa topologi konverter daya yang berfungsi untuk mengatur dan mengubah bentuk tegangan dan arus [1]. Salah satu topologi konverter daya yang sering digunakan adalah *buck converter* yang berfungsi untuk mengubah tegangan searah (dc) dari satu tingkat ke tingkat lainnya dengan level yang lebih rendah.

Implementasi konverter elektronika daya menjadi komponen yang krusial dalam beberapa aplikasi. Misalnya adalah kendaraan listrik [2], energi terbarukan [3], dan juga sistem penyimpanan energi [4]. Dengan demikian, perkembangan teknologi elektronika daya yang pesat telah membuka peluang baru untuk penelitian dan pengembangan yang dinamis dalam bidang elektronika daya untuk meningkatkan efisiensi, keandalan, dan kinerja keseluruhan sistem.

Konverter daya memerlukan desain parameter sirkuit yang cermat supaya dapat memenuhi performa dan spesifikasi yang diinginkan. Performa tersebut meliputi ukuran, biaya, efisiensi, keandalan, riak-riak, dan respons transien [5,6]. Untuk mencapai kinerja yang optimal, beberapa aspek tersebut harus dipertimbangkan secara menyeluruh. Proses ini menekankan pentingnya menganalisis semua faktor yang relevan dalam merancang konverter daya. Oleh karena itu, desain parameter sirkuit menjadi langkah krusial dalam mengoptimalkan kinerja dan efisiensi konverter daya.

Desain parameter sirkuit pada konverter daya melalui dua proses utama, yaitu analisis dan deduksi dan proses optimisasi [7]. Di sisi lain, pendekatan utama yang sering dilakukan adalah *traditional human-dependent* atau konvensional [8, 9] dan *computer-aided optimization* [5, 10–13]. Proses desain parameter sirkuit pada pendekatan *traditional human-dependent* melibatkan perhitungan penuh dari insinyur. Insinyur harus menyelesaikan persamaan matematika untuk menyelesaikan proses analisis dan deduksi. Di sisi lain, proses optimisasi berkaitan dengan percobaan empiris dan pengalaman dari insinyur sendiri [7]. Metode ini terbatas pada keterbatasan analisis dan akurasi manusia serta rentan terhadap kesalahan manusia. Di sisi lain, metode *computer-aided optimization* (CAO) menggantikan proses optimisasi dalam desain parameter sirkuit dengan algoritma komputer. Algoritma akan dibuat berdasarkan model sistem kemudian akan dilakukan optimisasi untuk memilih parameter dan komponen [10]. Walaupun begitu, proses analisis dan deduksi masih mengandalkan perhitungan manual sehingga tingkat akurasi masih kurang optimal, membutuhkan waktu yang cukup lama, dan rumit dalam proses desain [10, 11].

Metode *traditional human-dependent* dan CAO masih sangat bergantung pada manusia dalam proses desain parameter sirkuit. Namun, dengan kemajuan dalam bidang *artificial intelligence* (AI), terutama dalam konteks *neural network* (NN), pendekatan baru telah muncul. Dengan memanfaatkan kekuatan komputasi dan kemampuan pembelajaran mesin, aplikasi AI dalam desain parameter sirkuit konverter daya menawarkan kemajuan yang signifikan dalam proses analisis dan deduksi dan optimisasi. *Neural network* dapat memproses data dengan cepat dan akurat, mengidentifikasi pola kompleks dalam desain parameter sirkuit, dan juga memprediksi kinerja sistem dengan tingkat keakuratan yang tinggi. Selain itu, AI juga memungkinkan optimisasi parameter yang otomatis dan efisien dengan mempertimbangkan berbagai faktor yang relevan. Beberapa penelitian juga telah menerapkan aplikasi AI untuk desain parameter sirkuit [7, 14, 15]. Dengan demikian, integrasi AI dalam proses desain parameter sirkuit tidak hanya meningkatkan akurasi dan kecepatan, tetapi juga membuka pintu bagi inovasi yang lebih lanjut dalam pengembangan konverter daya yang efisien dan andal.

Penelitian ini membahas desain parameter sirkuit konverter daya dengan topologi *buck converter* menggunakan pendekatan berbasis AI. Teknologi AI akan diterapkan dalam proses analisis dan deduksi dan juga optimisasi. Dengan menggunakan pendekatan berbasis AI dalam proses analisis dan deduksi, teknologi tersebut akan dimanfaatkan untuk mengidentifikasi pola kompleks dalam data dan parameter sirkuit. Selain itu, algoritma optimisasi akan digunakan untuk mencari solusi yang paling optimal dalam ruang desain. Oleh karena itu, diharapkan penelitian ini dapat menghasilkan desain parameter sirkuit *buck converter* yang mampu mengatasi tantangan dalam industri konverter daya, memberikan solusi yang lebih baik, dan mendorong inovasi untuk masa depan teknologi energi yang lebih berkelanjutan dan efisien.

1.2 Rumusan Masalah

Apakah penerapan AI dalam desain rangkaian daya dapat meningkatkan efisiensi dan kinerja *buck converter* dibandingkan dengan metode konvensional?

1.3 Tujuan Penelitian

1. Merancang *buck converter* dengan pendekatan berbasis AI untuk menciptakan solusi yang efisien dalam konversi daya.
2. Menggunakan algoritma optimisasi AI untuk memilih parameter yang paling optimal untuk meningkatkan efisiensi dan kinerja operasional *buck converter*
3. Membandingkan efisiensi dan kinerja operasional *buck converter* antara metode konvensional dengan metode pendekatan berbasis AI.
4. Memberikan kontribusi untuk kemajuan teknologi konverter daya dengan mengha-

dirikan inovasi baru dalam desain dan pengembangan *buck converter* dengan menggunakan pendekatan berbasis AI.

1.4 Batasan Penelitian

1. Objek penelitian: Implementasi AI pada desain *buck converter*.
2. Metode penelitian: Penelitian eksperimental yang melibatkan simulasi komputer dan pengujian empiris dalam skala laboratorium untuk mengembangkan dan menguji model AI dalam merancang parameter *buck converter*.
3. Waktu dan tempat penelitian: Januari - Juni 2024 di Fasilitas Laboratorium TTL.
4. Populasi dan sampel: Populasi penelitian ini adalah variasi konfigurasi parameter *buck converter*, sementara sampelnya adalah sejumlah kombinasi parameter *buck converter* yang disimulasikan dan diuji dalam eksperimen.
5. Variabel: Variabel bebas adalah kombinasi nilai parameter induktor (L), kapasitor (C), frekuensi *switching* (f_{sw}), *dead time* (t_d), dan *duty cycle* (d_{cycle}) yang digunakan dalam desain *buck converter*. Variabel terikat adalah kinerja dari *buck converter*, yaitu efisiensi, tegangan keluaran, arus keluaran, dan rugi-rugi daya.
6. Hipotesis: Hipotesis penelitian ini menyatakan bahwa penggunaan AI dalam desain parameter sirkuit *buck converter* akan menghasilkan *buck converter* yang lebih efisien dan optimal dibandingkan dengan metode konvensional.
7. Keterbatasan penelitian: Keterbatasan penelitian adalah hanya melibatkan pengujian sistem pada skala laboratorium dan membatasi analisis pada variabel bebas dan terikat.

1.5 Manfaat Penelitian

1. Meningkatkan efisiensi konversi energi dengan desain *buck converter* yang telah dioptimalkan.
2. Mempercepat dan menyederhanakan proses desain *buck converter* melalui pendekatan berbasis AI.
3. Mendorong kemajuan dalam desain konverter daya dengan integrasi AI.

1.6 Sistematika Penulisan

Bab I membahas tentang pendahuluan yang meliputi latar belakang penelitian, perumusan masalah yang ingin dipecahkan, dan tujuan penelitian yang ingin dicapai.

Bab II membahas tentang tinjauan pustaka yang relevan, daftar teori yang mendukung, serta analisis perbandingan metode yang digunakan dalam penelitian.

Bab III membahas tentang metode penelitian yang mencakup alat dan bahan yang digunakan, metode yang diterapkan untuk mencapai tujuan penelitian, serta alur atau langkah-langkah yang diambil dalam proses penelitian.

Bab IV membahas tentang perancangan desain parameter sirkuit yang digunakan dalam penelitian ini. Bab ini membahas implementasi rangkaian *buck converter* dalam simulasi, model *machine learning*, dan terkait implementasi metode optimisasi.

Bab V membahas tentang hasil penelitian dan pembahasan. Bagian ini menyajikan hasil-hasil yang diperoleh dari penelitian, termasuk data dan analisis yang dilakukan. Hasil-hasil tersebut kemudian dibahas secara mendalam untuk menjawab rumusan masalah yang telah diidentifikasi sebelumnya.

Bab VI membahas tentang kesimpulan yang diambil berdasarkan hasil penelitian dan pembahasan yang telah dilakukan sebelumnya. Selain itu, bab ini juga memberikan saran-saran yang diharapkan dapat bermanfaat bagi penelitian terkait selanjutnya.

BAB II

TINJAUAN PUSTAKA DAN DASAR TEORI

2.1 Tinjauan Pustaka

Tinjauan pustaka akan menjelaskan beberapa pendekatan yang telah dilakukan penelitiannya, yaitu terkait metode desain sirkuit konverter. Dengan menganalisis berbagai metodologi dari penelitian lainnya, tinjauan ini dapat memberikan gambaran yang komprehensif tentang kemajuan terkini dalam bidang desain sirkuit konverter daya. Informasi yang didapatkan akan menjadi landasan yang kuat bagi penulis untuk mengembangkan solusi inovatif dalam desain sirkuit *buck converter* yang lebih efisien, andal, dan aplikatif.

2.1.1 Metode Desain Sirkuit Konverter Daya

Bagian ini membahas tentang beberapa cara metode yang dapat digunakan dalam desain sirkuit konverter daya penelitian untuk mengoptimalkan parameter konverter daya. Tiga metode utama yang dibandingkan adalah metode konvensional, metode CAO, dan metode pendekatan berbasis AI.

2.1.1.1 Metode Konvensional

Metode *traditional human-dependent* atau konvensional telah menjadi fondasi utama dalam desain sirkuit elektronika. Pendekatan ini melibatkan analisis matematis yang cermat dan perhitungan rumit untuk merancang sirkuit *buck converter* yang sesuai dengan spesifikasi yang diberikan. Referensi [8] memberikan penjelasan yang mendetail tentang dasar cara kerja *buck converter*, penentuan spesifikasi, dan berbagai rumus perhitungan (arus riak induktor, pemilihan nilai induktor, dan pemilihan kapasitor). Di sisi lain, referensi [9] membahas desain sirkuit *buck converter* menggunakan *core independent peripheral* (CIP) sebagai kontroler. Desain ini mengimplementasikan metode konvensional untuk perhitungan parameter dan pemilihan komponen. Selain itu, metode konvensional juga digunakan untuk menghitung parameter kendali, yaitu *pole* akibat komponen resistor, induktor, dan kapasitor [9]. Kedua referensi berfokus pada analisis dan rumus yang mendasar terkait topologi rangkaian dan spesifikasi yang diinginkan.

Proses analisis dan deduksi, serta proses optimisasi dalam metode konvensional dilakukan secara manual. Pengguna tidak hanya harus menyelesaikan persamaan matematika, tetapi juga harus mempertimbangkan faktor-faktor fisik dan praktis dalam pemilihan komponen. Selain itu, pengguna perlu memperhatikan pengaruh parameter fisik, seperti toleransi nilai komponen, perubahan suhu, dan kinerja sirkuit dalam berbagai kondisi lingkungan. Hal ini membutuhkan pengalaman dan pengetahuan yang luas

dalam domain desain sirkuit elektronika. Walaupun begitu, kelebihan dari metode konvensional adalah memberikan pemahaman yang mendalam tentang kinerja sirkuit dan prinsip-prinsip dasar dalam sirkuit *buck converter* dan juga praktis. Oleh karena itu, metode konvensional menjadi pilihan yang umum karena mudah implementasinya dan dapat menghasilkan sirkuit yang andal.

2.1.1.2 Metode CAO

Metode *computer-aided optimization* atau CAO adalah pendekatan dalam desain sirkuit elektronika yang memanfaatkan kemampuan komputasi komputer untuk melakukan proses optimisasi. Dengan menggunakan algoritma dan teknik optimisasi yang telah disesuaikan, implementasi metode CAO memungkinkan pengguna untuk memperoleh solusi terbaik dalam ruang desain yang kompleks dengan cepat dan efektif.

Pada referensi [5], metode CAO digunakan untuk mendesain filter keluaran LC dengan algoritma *coevolving-AMOSA*. Implementasi tersebut dimanfaatkan untuk mencapai desain multiobjektif, meliputi optimisasi *loss*, frekuensi *cut-off*, dan volume induktor dan kapasitor. Penelitian [10] melakukan optimisasi berbasis analisis domain waktu dengan 2 derajat kebebasan (2DOFs) untuk mendapatkan nilai frekuensi *switching* dan *duty cycle*. Sementara itu, optimisasi efisiensi dan biaya untuk *Smart Transformer* dalam penelitian [11] dapat diperoleh dengan implementasi metode CAO. Di sisi lain, model matematika juga dapat digunakan sebagai dasar untuk implementasi CAO, seperti dalam referensi [12, 13] yang membahas tentang optimisasi desain parameter.

Metode CAO memiliki sejumlah kelebihan signifikan dibandingkan metode konvensional. Proses optimisasi yang dilakukan secara otomatis menggunakan algoritma komputer mampu meningkatkan efisiensi desain dan memberikan solusi yang optimal dalam ruang desain yang kompleks. Dengan otomatisasi, metode CAO mampu memproses dan menganalisis jumlah data yang besar dengan cepat. Penelitian [5, 10–13] memiliki beberapa parameter yang harus dioptimalkan atau optimisasi desain multiobjektif. Metode CAO memungkinkan penggunaannya untuk menyeimbangkan berbagai parameter tersebut dengan lebih efektif dan sesuai dengan spesifikasi desain.

Meskipun metode CAO menunjukkan proses otomatis yang canggih, ada beberapa kekurangan yang perlu dipertimbangkan. Ketergantungan pada algoritma dan perangkat lunak canggih mengharuskan pengguna untuk memiliki pemahaman yang mendalam tentang prinsip-prinsip matematika dan teknis yang digunakan. Penelitian referensi [5, 10–13] berbasis pada algoritma dan model matematika yang cukup kompleks yang memiliki tantangan tersendiri dalam menyelesaikan dan mengimplementasikan menjadi sebuah program. Meskipun proses optimisasi dapat berjalan secara otomatis, metode CAO dapat menghasilkan solusi yang terlalu ideal dan tidak praktis untuk implementasi dunia nyata.

2.1.1.3 Metode AI

Metode AI memberikan pendekatan yang lebih dinamis dan adaptif dibandingkan dengan metode konvensional dan metode CAO. Sementara metode konvensional yang hanya bergantung pada perhitungan manual yang memakan waktu dan metode CAO yang melakukan optimisasi dengan bantuan komputasi komputer, metode AI memiliki kemampuan pembelajaran dan adaptasi yang memungkinkan sistem untuk semakin andal. Penerapan metode AI dalam proses analisis dan deduksi dan proses optimisasi menjadikan solusi yang dihasilkan tidak hanya cepat, tetapi juga akurat dan efisien dalam menyesuaikan diri dengan perubahan kebutuhan dan kondisi.

Penelitian [7] menerapkan metode AI untuk desain parameter sirkuit pada *buck converter*. Penggunaan *neural network* mampu meningkatkan efisiensi desain melalui otomatisasi yang mendalam dan pemodelan prediktif. Sementara itu, penelitian [14] melakukan otomatisasi pemilihan jumlah dan topologi *Power Converter Array* (PCA) berbasis data hasil eksperimen. Implementasi metode AI memungkinkan analisis performa konverter secara otomatis sehingga dapat mempercepat proses desain. Di sisi lain, penelitian [15] mengotomatisasi desain parameter sirkuit konverter daya dengan metode *reinforcement learning*. Metode AI mempercepat pencarian parameter yang sesuai dengan spesifikasi desain tersebut.

Penelitian [7, 14, 15] menunjukkan bahwa metode AI memberikan sejumlah kelebihan. Salah satu keunggulan utama adalah kemampuan untuk mengotomatisasi proses desain yang kompleks sehingga mengurangi waktu pengembangan desain. Kelebihan lainnya adalah kemampuan adaptasi dan pembelajaran yang memungkinkan AI untuk mengolah dan menganalisis data yang besar sehingga dapat menemukan pola atau solusi yang tidak dapat diidentifikasi oleh metode konvensional atau metode CAO. Dengan kata lain, metode AI mampu meningkatkan efisiensi dan mengurangi risiko kesalahan manusia sembari memberikan kemampuan untuk beraksi terhadap perubahan kondisi secara dinamis dan *real-time*.

Meskipun kelebihan metode AI sangat dominan, metode ini memiliki beberapa kekurangan yang perlu diperhatikan. Salah satu tantangan utama adalah ketergantungan pada data yang besar dan berkualitas untuk *training* model. Padahal, data itu sendiri tidak selalu tersedia atau mahal untuk diperoleh. Bahkan, pada penelitian [14], proses pengujian PCA dilakukan selama lebih dari 210 jam untuk mengumpulkan data sebagai model statistik. Selain itu, kompleksitas model AI sebanding dengan kebutuhan sumber daya komputasi yang signifikan. Pemilihan model AI sendiri juga memerlukan pemahaman mendalam tentang AI dan masalah yang dihadapi.

2.1.2 Perbandingan Metode Desain Sirkuit Konverter Daya

Subbab ini adalah rangkuman dari subbab sebelumnya yang membahas tentang 3 metode desain sirkuit, yaitu ringkasan tiap referensi dan perbandingan kelebihan kekurangan ketiga metode. Tabel 2.1 memberikan ringkasan fokus dan isi dari referensi tentang metode konvensional, sementara Tabel 2.2 meringkas tentang referensi untuk metode CAO. Di sisi lain, Tabel 2.3 memaparkan ringkasan dari studi literatur tentang metode AI. Selain itu, terdapat pula Tabel 2.4 yang membandingkan kelebihan dan kekurangan dari tiap metode yang dipaparkan.

Tabel 2.1. Perbandingan Referensi pada Metode Desain Sirkuit Konvensional

Referensi	Fokus	Isi
[8]	Perhitungan parameter <i>buck converter</i>	Menyajikan dasar cara kerja, penentuan spesifikasi, dan perhitungan parameter <i>buck converter</i>
[9]	Desain buck converter menggunakan CIP	Mengimplementasikan metode konvensional untuk perhitungan parameter kendali <i>buck converter</i>

Tabel 2.2. Perbandingan Referensi pada Metode Desain Sirkuit CAO

Referensi	Fokus	Isi
[5]	Optimisasi desain multiobjektif filter LC pada <i>buck converter</i>	Mengimplementasikan algoritma <i>coevolving-AMOSA</i> untuk desain filter LC
[10]	Optimisasi frekuensi <i>switching</i> dan <i>duty cycle</i> pada konverter resonan	Menggunakan analisis domain waktu untuk optimasi operasi dan desain konverter resonan
[11]	Optimisasi pemilihan parameter dan komponen untuk desain <i>Smart Transformer</i>	Mengembangkan algoritma optimisasi untuk mempertimbangkan efisiensi, biaya, dan jumlah modul untuk aplikasi tegangan <i>grid</i> tertentu

Tabel 2.3. Perbandingan Referensi pada Metode Desain Sirkuit AI

Referensi	Fokus	Isi
[7]	Automatisasi desain <i>buck converter</i> dengan pendekatan berbasis AI	Mengimplementasikan model <i>machine learning</i> dalam metode optimisasi untuk desain <i>buck converter</i>
[14]	Otomatisasi pemilihan <i>Power Converter Array</i>	Mengembangkan metode <i>Automatic Design for Manufacturing</i> (ADFM) untuk desain otomatis PCA dalam aplikasi pengisian baterai
[15]	Otomatisasi desain konverter daya dengan <i>reinforcement learning</i>	Meningkatkan kecepatan desain konverter daya (<i>buck, boost, buck-boost converter</i>) dengan algoritma <i>Upper Confidence Bound for Trees</i> (UCT)

Tabel 2.4. Kelebihan dan Kekurangan Metode Desain Sirkuit Konverter Daya

Metode	Kelebihan	Kekurangan
Konvensional	Mudah menyesuaikan dan mengadaptasi desain berdasarkan kebutuhan.	Memerlukan waktu dan usaha yang lebih banyak untuk analisis manual.
	Mudah diterapkan tanpa memerlukan perangkat lunak atau keras.	Berisiko terjadi kesalahan manusia dalam perhitungan.
	Hasil yang tetap dapat diandalkan aplikasi yang umum.	Sulit untuk mengoptimalkan parameter dalam desain yang kompleks.
CAO	Meningkatkan efisiensi desain melalui otomatisasi komputer.	Memerlukan pemahaman mendalam tentang algoritma dan perangkat lunak optimisasi.
	Mampu memproses dan menganalisis data dalam jumlah besar dengan cepat.	Solusi yang dihasilkan dapat terlalu ideal dan kurang praktis.

	Mendukung optimisasi multiobjektif untuk berbagai parameter.	Bergantung pada perangkat lunak dan kapasitas komputasi yang tinggi.
AI	Mengotomatisasi proses desain yang rumit dengan adaptasi pembelajaran.	Membutuhkan data besar dan berkualitas untuk pelatihan model.
	Mampu menganalisis data besar untuk menemukan pola yang tidak terlihat.	Model AI kompleks memerlukan sumber daya komputasi yang signifikan.
	Meningkatkan efisiensi dan mengurangi kemungkinan kesalahan manusia.	Memerlukan pemahaman yang dalam tentang konsep AI dan implementasinya.

2.2 Dasar Teori

Bagian 2.2 memberikan landasan teori yang diperlukan untuk memahami penelitian yang dilakukan. Penjelasan dimulai dengan pembahasan tentang *buck converter*, mulai dari prinsip kerja, sampai dengan perhitungan rugi daya dan penentuan komponen. Kemudian, konsep *artificial intelligence* yang menjadi basis dalam pendekatan modern untuk optimisasi desain sirkuit konverter daya. Selain itu, bagian optimisasi juga dijelaskan secara rinci untuk meningkatkan kinerja dan efisiensi konverter daya.

2.2.1 Buck Converter

Pada Bagian 2.2.1 ini, akan dibahas secara mendalam tentang *buck converter*, dimulai dengan pendahuluan yang menjelaskan pentingnya dan aplikasi dari *buck converter*. Selanjutnya, tentang prinsip kerja dari *buck converter* dan juga komponen utama yang membentuk *buck converter*.

Kemudian, topologi *buck converter* akan dibahas untuk memberikan pemahaman tentang konfigurasi sirkuit yang dapat digunakan. Selain itu, rumus-rumus perhitungan rugi daya dalam *buck converter* akan dijelaskan untuk membantu memahami efisiensi dan performa sirkuit. Terakhir, metode penentuan parameter dan pemilihan komponen untuk *buck converter* akan diberikan sehingga dapat memberikan panduan praktis untuk merancang dan mengoptimalkan sirkuit *buck converter*.

2.2.1.1 Pendahuluan

Buck converter atau *step down converter* adalah jenis konverter daya dc-dc yang dirancang untuk mengurangi tegangan dari sumber yang lebih tinggi ke tegangan keluaran yang lebih rendah [16]. Tujuan utama dari penggunaan buck converter adalah untuk

menyediakan tegangan yang sesuai dengan kebutuhan beban dari sumber tegangan yang mungkin lebih tinggi dari yang dibutuhkan.

Buck converter sangat penting dalam berbagai aplikasi elektronik karena kemampuannya untuk mengubah tegangan dc yang tinggi menjadi tegangan dc yang lebih rendah dengan efisiensi yang tinggi. Hal ini dilakukan melalui proses *switching* yang cepat dan pengaturan *duty cycle*, yang memungkinkan konverter daya untuk meminimalkan kerugian daya dan panas yang dihasilkan.


Penggunaan *buck converter* mencakup berbagai bidang. Dalam perangkat elektronik portabel seperti ponsel, laptop, dan tablet, *buck converter* membantu menyediakan berbagai tingkat tegangan yang diperlukan oleh komponen internal dari baterai [17]. Dalam sistem tenaga dan distribusi daya, *buck converter* mengatur dan menurunkan tegangan dari sumber daya utama ke tingkat yang sesuai untuk peralatan elektronik [18]. Di industri otomotif, *buck converter* mengatur tegangan dari sistem kelistrikan kendaraan untuk menyediakan tegangan yang lebih rendah sesuai ke butuhan sistem elektronik di kendaraan [2]. Dalam telekomunikasi, *buck converter* menurunkan tegangan dari sumber daya utama ke tingkat yang dibutuhkan oleh modul komunikasi [19]. Selain itu, dalam sistem energi terbarukan seperti panel surya, *buck converter* menurunkan tegangan dari panel surya yang bervariasi sesuai kondisi cahaya ke tingkat tegangan yang lebih stabil dan sesuai untuk penyimpanan atau penggunaan langsung [20].

2.2.1.2 Prinsip Kerja

Buck converter mengurangi tegangan input yang lebih tinggi menjadi keluaran yang lebih rendah dengan menggunakan teknik *Pulse Width Modulation* (PWM). Teknik ini memanfaatkan komponen *switching*, seperti MOSFET, yang beroperasi dengan cepat untuk mengatur waktu dan seberapa lama saklar tersebut dalam keadaan aktif (*on*) dan tidak aktif (*off*) selama setiap siklus operasi. Proses ini mengendalikan rata-rata tegangan yang disalurkan ke beban.

1. Penggunaan *Pulse Width Modulation* (PWM):

Pulse Width Modulation (PWM) adalah teknik yang digunakan dalam *buck converter* untuk mengontrol tegangan keluaran dengan mengatur lebar pulsa, atau *duty cycle*, dari sinyal *switching* [21]. *Duty cycle* adalah rasio dari durasi saklar dalam keadaan aktif (*on*) terhadap keseluruhan periode siklus, yang dapat diwakili sebagai persentase dari waktu total (Rumus 2-1). Gambar 2.1 menunjukkan contoh pengaturan *duty cycle*, mulai dari 25 % sampai dengan 75 %. Dengan mengatur lebar pulsa ini, jumlah tegangan yang diteruskan ke beban dapat diubah sesuai dengan kebutuhan. *Duty cycle* yang lebih rendah berarti bahwa waktu pulsa aktif lebih singkat dibandingkan dengan waktu pulsa mati sehingga dapat mengha-



Gambar 2.1. *Duty Cycle*

silkan tegangan keluaran yang lebih rendah.

$$D = \left(\frac{T_{\text{on}}}{T_{\text{on}} + T_{\text{off}}} \right) \times 100\% \quad (2-1)$$

di mana,

T_{on} : Durasi waktu saklar dalam keadaan aktif (*on*)

T_{off} : Durasi waktu saklar dalam keadaan tidak aktif (*off*)

D : *Duty cycle* dalam persentase

Dalam *buck converter*, sinyal PWM beroperasi pada frekuensi tinggi, yang memungkinkan pengendalian tegangan yang halus dan efisien. Ketika komponen *switching* aktif, tegangan input diteruskan ke induktor dan beban. Sebaliknya, ketika komponen *switching* mati, energi yang tersimpan dalam induktor diteruskan ke beban melalui dioda atau transistor sinkron. Dengan pengaturan *duty cycle* yang tepat, *buck converter* dapat memastikan tegangan keluaran tetap dalam batas yang diinginkan.

2. Frekuensi *Switching* dan *Dead Time*:

Dalam desain *buck converter*, frekuensi *switching* dan *dead time* memainkan peran penting dalam menentukan performa dan efisiensi sistem. Kedua faktor ini saling berkaitan dan perlu diatur dengan cermat untuk memastikan kinerja optimal dari *buck converter*.

1. Frekuensi *Switching*:

Frequency *switching* adalah seberapa cepat saklar (komponen *swi-*

tching) dalam *buck converter* dihidupkan dan dimatikan. Frekuensi ini memiliki dampak signifikan terhadap performa dan efisiensi converter secara keseluruhan dengan rincian sebagai berikut.

1. Efisiensi dan Respon:

Frekuensi *switching* yang tinggi memungkinkan respon yang lebih cepat terhadap perubahan beban dan membantu menjaga keluaran yang lebih stabil. Hal ini akan mengurangi waktu respons induktor dalam menanggapi perubahan arus beban.

2. Ukuran Induktor dan Kapasitor:

Frekuensi yang lebih tinggi menyebabkan induktor dan kapasitor yang digunakan dapat lebih kecil sehingga akan mengurangi ukuran dan biaya dari *buck converter*.

2. *Dead Time*:

Dead time adalah interval waktu di mana kedua saklar (*high-side switch* dan *low-side switch*) dalam *buck converter* synchronous dimatikan untuk mencegah keduanya aktif secara bersamaan. Berikut adalah fungsi dari adanya *dead time*.

1. Mencegah *Short Circuit*:

Pengaturan *dead time* yang tidak tepat dapat mengakibatkan kedua komponen *switching* terhubung secara bersamaan (*short circuit*). Ini akan menyebabkan arus besar yang mengalir melalui komponen *switching* sehingga berpotensi merusak komponen dan mengurangi efisiensi secara keseluruhan.

2. Optimalisasi Performa:

Pengaturan *dead time* yang sesuai akan memastikan bahwa tidak ada energi yang terbuang karena arus bocor melalui kedua komponen *switching* yang terbuka. Di sisi lain, nilai *dead time* yang terlalu besar dapat mengurangi efisiensi konverter karena mengurangi waktu efektif di mana energi ditransfer ke beban.

3. Penyesuaian terhadap Parameter Desain:

Nilai *dead time* yang optimal bergantung pada spesifik desain dan karakteristik komponen *switching* yang digunakan. Parameter seperti waktu respons komponen *switching* dan karakteristik *gate driver* mempengaruhi nilai *dead time* yang diperlukan.

2.2.1.3 Komponen *Buck Converter*

1. Transistor:

Pemilihan jenis transistor sebagai komponen *switching* sangat memengaruhi efisiensi dan performa keseluruhan sistem. Dalam desain *buck converter*, pemilihan jenis transistor sebagai saklar sangat penting untuk menentukan efisiensi dan performa keseluruhan sistem. MOSFET (Metal-Oxide-Semiconductor Field-Effect Transistor), IGBT (Insulated-Gate Bipolar Transistor), dan BJT (Bipolar Junction Transistor) adalah tiga jenis transistor yang sering digunakan, di mana masing-masing dengan karakteristik dan keunggulan tertentu [22].

1. MOSFET:

MOSFET adalah transistor yang umum digunakan karena kemampuannya untuk mengatur tingkat tegangan keluaran dengan efisien melalui modulasi lebar pulsa (PWM). MOSFET memiliki resistansi *on-state* yang rendah sehingga mengurangi rugi daya akibat panas dan meningkatkan efisiensi keseluruhan. MOSFET juga mampu beroperasi pada frekuensi *switching* yang tinggi sehingga dapat mengontrol dengan lebih baik atas tegangan keluaran dan minimnya kerugian panas.

2. IGBT:

IGBT merupakan pilihan yang baik untuk aplikasi yang memerlukan kapasitas arus tinggi dan tegangan operasional yang lebih tinggi. Ini menggabungkan kemudahan pengendalian MOSFET dengan kapasitas menangani daya tinggi dari BJT, menjadikannya efektif untuk aplikasi tegangan tinggi. IGBT sering dipakai dalam aplikasi yang memerlukan tegangan dan arus yang lebih besar. Walaupun begitu, kecepatan *switching* IGBT lebih rendah dibandingkan MOSFET.

3. BJT:

Selain MOSFET dan IGBT, ada pilihan transistor lain yaitu BJT. Meskipun kurang umum digunakan dalam aplikasi *buck converter*, BJT bisa menjadi alternatif dengan pertimbangan biaya. Walaupun begitu, BJT memerlukan arus *base* yang signifikan untuk aktivasi yang bisa mengurangi efisiensi operasional.

2. Induktor:

Induktor adalah komponen krusial dalam desain *buck converter* karena berfungsi sebagai penyimpanan energi dan pengaturan arus. Saat transistor atau saklar dalam *buck converter* diaktifkan, arus melalui induktor meningkat dan ener-

gi disimpan dalam medan magnetiknya. Fungsi penyimpanan energi ini kritikal karena memungkinkan induktor untuk mengurangi fluktuasi arus yang dihasilkan oleh proses *switching* yang cepat dan berulang.

Ketika transistor dimatikan, induktor akan mempertahankan arus yang mengalir dengan cara melepaskan energi yang disimpan dalam medan magnetik induktor. Energi ini akan mengalir ke kapasitor keluaran dan beban sehingga dapat menjaga tegangan keluaran dan mengurangi riak. Dengan kata lain, induktor berfungsi sebagai komponen filter karena menstabilkan dan mempertahankan keluaran energi.

Nilai induktansi yang tepat menjadi kunci untuk mencapai performa optimal dari *buck converter*. Berikut adalah beberapa faktor yang harus dipertimbangkan dalam penentuan nilai induktansi.

1. **Frekuensi *Switching*:**

Nilai induktansi harus dipilih berdasarkan frekuensi *switching* yang digunakan. Frekuensi *switching* yang lebih tinggi umumnya memungkinkan penggunaan induktor dengan nilai induktansi lebih rendah, yang dapat membantu mengurangi ukuran fisik dan biaya.

2. **Riak Arus:**

Besar riak arus disesuaikan dengan kebutuhan aplikasi. Induktor dengan induktansi yang lebih tinggi akan menghasilkan riak arus yang lebih rendah sehingga sesuai untuk aplikasi yang membutuhkan keluaran yang sangat stabil.

3. **Kapasitor:**

Kapasitor dalam *buck converter* digunakan untuk menstabilkan tegangan keluaran dan mengurangi fluktuasi yang terjadi karena proses *switching*. Ketika transistor dalam *buck converter* diaktifkan dan dinonaktifkan, kapasitor berfungsi sebagai penyimpan energi yang merespons cepat terhadap perubahan arus sehingga membantu menjaga kestabilan arus dan tegangan ke beban.

Kapasitor keluaran pada *buck converter* mengurangi riak dan memperbaiki respon transien pada keluaran. Kapasitor dapat menyediakan atau menyerap energi yang diperlukan ketika ada perubahan terhadap beban secara mendadak (beban ringan ke beban berat). Hal ini akan mengurangi efek dari perubahan beban tersebut pada tegangan keluaran. Fungsi ini sangat penting dalam aplikasi yang memerlukan stabilitas tegangan yang tinggi dan kinerja yang dapat diandalkan. Berikut adalah beberapa faktor yang dapat dipertimbangkan dalam memilih kapasitor.

1. Tipe Kapasitor:

Jenis kapasitor yang paling sering digunakan dalam *buck converter* adalah kapasitor keramik dan kapasitor elektrolit. Kapasitor keramik sangat baik dalam mengurangi riak tegangan dan biasanya memiliki *Equivalent Series Resistance* (ESR) yang sangat rendah serta *Equivalent Series Inductance* (ESL) rendah [23]. Sementara itu, kapasitor elektrolit sering digunakan untuk aplikasi yang memerlukan kapasitansi yang lebih tinggi untuk penyaringan yang lebih baik pada beban tinggi.

2. Nilai Kapasitansi:

Nilai kapasitansi yang diperlukan tergantung pada besarnya riak dalam spesifikasi dan frekuensi *switching* dari *buck converter*. Kapasitansi yang lebih tinggi menghasilkan kualitas penyaringan yang lebih baik, tetapi juga dapat menyebabkan ukuran fisik yang lebih besar dan waktu respons yang lebih lambat.

3. Tegangan Operasi:

Kapasitor harus dipilih dengan tegangan kerja yang sesuai atau lebih tinggi dari tegangan maksimum yang diharapkan dalam sirkuit untuk menghindari kegagalan kapasitor karena tegangan berlebih.

4. Dioda:


Dioda adalah komponen utama yang digunakan dalam topologi *asynchronous buck converter*. Dalam topologi ini, dioda mengatur aliran arus dari induktor ke beban ketika transistor dimatikan. Aliran arus yang berubah memungkinkan energi yang disimpan oleh induktor untuk mengalir ke beban sehingga dapat mempertahankan keluaran yang stabil. Selain itu, dioda juga berperan sebagai komponen proteksi untuk mencegah arus balik. Dalam topologi *synchronous buck converter*, penggunaan dioda digantikan oleh transistor *low-side*.

2.2.1.4 Topologi

Buck converter memiliki 2 topologi yang umum digunakan, yaitu *synchronous* dan *asynchronous* [24]. Gambar 2.2 adalah skematik *buck converter* topologi *synchronous* dan *asynchronous*. Keduanya memiliki rangkaian yang identik dengan perbedaan terletak pada dioda dan transistor pada kedua topologi.

1. Asynchronous Buck Converter:

Asynchronous buck converter atau *non-synchronous buck converter* adalah jenis konverter daya dc-dc yang digunakan untuk mengurangi tegangan dari input yang lebih tinggi ke keluaran yang lebih rendah. Dalam topologi ini, hanya



Gambar 2.2. Topologi *Buck Converter* - *Synchronous* dan *Asynchronous*

ada satu komponen *switching* yang dikendalikan secara aktif, sedangkan dioda digunakan sebagai komponen pembalik arus. Berikut adalah rincian cara kerja dari *asynchronous buck converter*.

1. Mode *On* (Transistor Aktif):

Ketika transistor diaktifkan (dalam keadaan *ON*), arus mengalir dari sumber tegangan melalui transistor dan induktor menuju beban. Tegangan input pada induktor menyebabkan arus induktor meningkat. Selama fase ini, energi tersimpan dalam bentuk medan magnetik di dalam induktor. Di sisi lain, kapasitor keluaran yang terisi membantu menstabilkan tegangan keluaran dengan menyimpan sebagian energi yang diterima. Energi yang disimpan di induktor dan kapasitor ini akan digunakan untuk menjaga arus dan tegangan konstan pada beban selama siklus berikutnya.

2. Mode *Off* (Transistor Mati):

Ketika transistor dimatikan (dalam keadaan *off*), arus dari induktor tidak dapat lagi mengalir melalui transistor. Namun, karena induktor ingin mempertahankan arus yang konstan, arus tersebut diarahkan melalui dioda yang terhubung dalam arah maju (*forward biased*). Energi yang tersimpan

dalam induktor dilepaskan melalui dioda ke beban, memastikan arus tetap mengalir. Tegangan pada induktor berbalik arah, menyebabkan arus induktor menurun secara bertahap. Kapasitor keluaran membantu menjaga tegangan keluaran stabil dengan melepaskan muatan yang telah disimpannya sehingga memberikan suplai energi tambahan ke beban selama periode ini.

2. *Synchronous Buck Converter:*

Synchronous buck converter adalah jenis buck converter yang menggunakan dua komponen *switching* aktif untuk menggantikan dioda dalam topologi *asynchronous*. Penggunaan dua komponen *switching* ini meningkatkan efisiensi konverter, terutama pada tegangan dan arus tinggi, dengan mengurangi rugi daya pada dioda. Konsep dari topologi ini mirip dengan topologi *asynchronous buck converter* dengan rincian cara kerja sebagai berikut.

1. *Mode On (High-Side Switch On):*

Ketika transistor atas (*high-side*) aktif, tegangan input langsung dihubungkan ke induktor. Arus mengalir dari sumber tegangan input melalui transistor atas dan induktor menuju beban, menyebabkan induktor menyimpan energi dalam bentuk medan magnet. Pada saat ini, tegangan di beban naik sesuai dengan nilai tegangan input dikurangi sedikit kerugian pada transistor atas dan induktor. Selama mode *on* ini, PWM akan memastikan transistor *high-side* tetap aktif selama durasi tertentu untuk mengatur jumlah energi yang disimpan dalam induktor. Proses ini penting untuk menentukan berapa banyak energi yang akan disimpan dan kemudian dilepaskan selama siklus berikutnya untuk menjaga tegangan keluaran stabil.

2. *Mode Off (High-Side Switch Off):*

Ketika transistor atas mati dan transistor bawah (*low-side*) aktif, induktor mencoba mempertahankan aliran arus dengan melepaskan energi yang telah disimpannya. Arus kemudian mengalir dari induktor ke beban dan kembali melalui transistor *low-side* ke *ground*, menjaga arus tetap mengalir dalam sirkuit. Energi yang dilepaskan oleh induktor terus menyediakan daya ke beban meskipun sumber tegangan input tidak terhubung langsung pada saat itu. Selama mode *off* ini, PWM mengatur durasi transistor *low-side* tetap aktif untuk memastikan tegangan keluaran tetap stabil dan sesuai dengan nilai yang diinginkan. Dengan cara ini, rangkaian dapat mempertahankan efisiensi tinggi dan menyediakan tegangan keluaran yang konsisten.

2.2.1.5 Rugi Daya

Rugi daya dalam *buck converter* dapat terjadi pada berbagai komponen, seperti transistor, dioda, induktor, dan kapasitor. Setiap komponen ini berkontribusi terhadap total rugi daya yang terjadi selama proses konversi energi dari tegangan tinggi ke tegangan rendah.

Rugi daya dalam rangkaian *buck converter* tergantung dengan topologi yang digunakan. Bagian 2.2.1.4 menjelaskan bahwa ada 2 topologi dari *buck converter* yang memiliki perbedaan pada penggunaan transistor dan dioda. Berikut adalah rugi-rugi daya yang dapat ditemukan dalam *buck converter* dengan MOSFET sebagai komponen *switching* berdasarkan referensi [25].

1. *Conduction Loss*:

Rugi ini terjadi karena resistansi dalam MOSFET saat arus mengalir. Pada rangkaian *synchronous buck converter*, rugi daya terjadi karena resistansi *on* (R_{on}) saat kedua MOSFET bergantian menyala dan mati. Sementara itu, *conduction loss* pada rangkaian *asynchronous buck converter* terjadi karena *forward voltage* pada dioda.

Asynchronous Buck Converter

$$P_{ON-D} = I_{out} \times V_F \times \left(1 - \frac{V_{out}}{V_{in}}\right) \quad [W] \quad (2-2)$$

di mana,

P_{ON-D} : *Conduction loss* dioda [W]

I_{out} : Arus keluaran [A]

V_F : *Forward direction voltage* dioda [V]

V_{in} : Tegangan masukan [V]

V_{out} : Tegangan keluaran [V]

Synchronous Buck Converter (High-side dan Low-side MOSFET)

$$P_{ON-H} = I_{out}^2 \times R_{ON-H} \times \frac{V_{out}}{V_{in}} \quad [W] \quad (2-3)$$

$$P_{ON-L} = I_{OUT}^2 \times R_{ON-L} \times \left(1 - \frac{V_{out}}{V_{in}}\right) \quad [W] \quad (2-4)$$

di mana,

P_{ON-H} : *Conduction loss* MOSFET *high-side* [W]

$P_{\text{ON-L}}$: Conduction loss MOSFET *low-side* [W]

I_{out} : Arus keluaran [A]

$R_{\text{ON-H}}$: Resistansi MOSFET *high-side* [Ω]

$R_{\text{ON-L}}$: Resistansi MOSFET *low-side* [Ω]

V_{in} : Tegangan masukan [V]

V_{out} : Tegangan keluaran [V]

2. *Output Capacitance Loss:*

Rugi daya ini terjadi karena kapasitansi keluaran MOSFET harus di-charge pada setiap siklus. Rumus 2-5 berlaku untuk kedua topologi *buck converter*.

$$P_{\text{COSS}} = \frac{1}{2} \times C_{\text{OSS-H}} \times V_{\text{in}}^2 \times f_{\text{sw}} \quad [\text{W}] \quad (2-5)$$

$$C_{\text{OSS-H}} = C_{\text{DS-H}} + C_{\text{GD-H}} \quad [\text{F}] \quad (2-6)$$

di mana,

P_{COSS} : *Output capacitance loss* [W]

$C_{\text{OSS-H}}$: *High-side MOSFET output capacitance* [F]

$C_{\text{DS-H}}$: *High-side MOSFET drain-source capacitance* [F]

$C_{\text{GD-H}}$: *High-side MOSFET gate-drain capacitance* [F]

V_{in} : Tegangan masukan [V]

f_{sw} : Frekuensi *switching* [Hz]

3. *Dead Time Loss:*

Dead time loss terjadi kedua MOSFET mati untuk mencegah *short circuit*. Rugi daya ini hanya berlaku untuk *synchronous buck converter* yang menggunakan dua MOSFET (Rumus 2-7).

$$P_{\text{D}} = V_{\text{D}} \times I_{\text{out}} \times t_{\text{d}} \times f_{\text{sw}} \quad [\text{W}] \quad (2-7)$$

di mana,

c : *Dead time loss* [W]

V_{D} : *Forward voltage* dari

low-side MOSFET dioda [V]

I_{out} : Arus keluaran [A]

t_d : *Dead time* [ns]

t_r : *Rise time* [ns]

t_f : *Fall time* [ns]

$t_{d(on)}$: *Turn-on Delay time* [ns]

$t_{d(off)}$: *Turn-off Delay time* [ns]

f_{sw} : *Frekuensi switching* [Hz]

4. *Gate Charge Loss*

Gate charge loss diakibatkan karena proses *charging* kapasitansi *gate* pada MOSFET. Rumus untuk topologi *asynchronous* (Rumus 2-8 atau 2-9 dan *synchronous buck converter* (Rumus 2-10 atau 2-11) memiliki perbedaan pada jumlah MOSFET yang dipakai.

Asynchronous Buck Converter

$$P_G = Q_{g-H} \times V_{gs} \times f_{sw} \quad [W] \quad (2-8)$$

atau

$$P_G = C_{GS-H} \times V_{gs}^2 \times f_{sw} \quad [W] \quad (2-9)$$

di mana,

P_G : *Gate loss* [W]

Q_{g-H} : *Gate charge* dari MOSFET *high-side* [C]

C_{GS-H} : *Gate capacitance* dari MOSFET *high-side* [F]

V_{gs} : *Tegangan gate drive* [V]

f_{sw} : *Frekuensi switching* [Hz]

Synchronous Buck Converter

$$P_G = (Q_{g-H} + Q_{g-L}) \times V_{gs} \times f_{sw} \quad [W] \quad (2-10)$$

atau

$$P_G = (C_{GS-H} + C_{GS-L}) \times V_{gs}^2 \times f_{sw} \quad [W] \quad (2-11)$$

di mana,

P_G : *Gate charge loss* [W]

Q_{g-H} : *Gate charge* dari MOSFET *high-side* [C]

Q_{g-L} : Gate charge dari MOSFET low-side [C]
 C_{GS-H} : Gate capacitance dari MOSFET high-side [F]
 C_{GS-L} : Gate capacitance dari MOSFET low-side [F]
 V_{gs} : Tegangan gate drive [V]
 f_{sw} : Frekuensi switching [Hz]

5. Total Rugi Daya

Berdasarkan rumus rugi-rugi daya yang telah dipaparkan, total rugi daya untuk topologi *asynchronous buck converter* ditunjukkan oleh Rumus 2-12. Sementara itu, total daya untuk topologi *synchronous buck converter* dirumuskan dengan Rumus 2-13.

Asynchronous Buck Converter

$$P_{total} = P_{ON-D} + P_{COSS} + P_G \quad [W] \quad (2-12)$$

Synchronous Buck Converter

$$P_{total} = P_{ON-H} + P_{ON-L} + P_{COSS} + P_D + P_G \quad [W] \quad (2-13)$$

di mana,

P_{total} : Total rugi daya [W]
 P_{ON-H} : Conduction loss MOSFET high-side [W]
 P_{ON-L} : Conduction loss MOSFET low-side [W]
 P_{ON-D} : Conduction loss dioda [W]
 P_{COSS} : Output capacitance loss [W]
 P_D : Dead time loss [W]
 P_G : Gate charge loss [W]

2.2.1.6 Perhitungan Parameter

Dalam desain dan implementasi rangkaian *buck converter*, perhitungan parameter yang tepat sangatlah penting untuk memastikan kinerja yang optimal dan keandalan sistem. Setiap parameter dan komponen memiliki peran yang spesifik dan saling terkait dalam menjaga efisiensi, kestabilan, dan performa keseluruhan dari *buck converter*.

Bagian ini akan membahas beberapa parameter kunci dan komponen utama yang harus dipertimbangkan dalam proses desain.

1. Induktansi:

Nilai induktansi berbanding terbalik dengan riak arus keluaran. Semakin tinggi nilai induktansi, riak arus keluaran akan semakin kecil, tetapi ukuran dari induktor akan semakin besar. Berdasarkan referensi [8], Rumus 2-14 adalah pendekatan untuk mencari nilai induktansi yang dibutuhkan.

$$L = \frac{V_{out} \times (V_{in} - V_{out})}{\Delta I_L \times f_{sw} \times V_{in}} \times \eta \quad (2-14)$$

di mana,

V_{out} : Tegangan keluaran [V]

V_{in} : Tegangan masukan [V]

f_{sw} : Frekuensi *switching* [Hz]

η : Efisiensi konverter dalam desimal

ΔI_L : Perubahan arus induktor [A] (Rumus 2-15)

Berikut adalah rumus untuk mencari nilai dari perubahan arus induktor.

$$\Delta I_L = ripple \times \frac{P_{out}}{V_{out}} \quad (2-15)$$

di mana,

V_{out} : Tegangan keluaran [V]

P_{out} : Daya keluaran [W]

ripple : Parameter estimasi *ripple* (20%-40%)

Berdasarkan referensi [7], nilai induktansi juga dapat dihitung berdasarkan Rumus 2-16.

$$L = \frac{A_L}{1000} N^2 \mu H \quad (2-16)$$

di mana,

A_L : Induktansi nominal [nH/T²]

N : Jumlah lilitan inti

Sementara itu, nilai N atau jumlah lilitan yang dibutuhkan dapat diperoleh dengan Rumus 2-17.

$$N \leq K_u \cdot \frac{\pi I D^2}{4 A_w} = N_{\max_core} \quad (2-17)$$

di mana,

K_u : Koefisien pengisian inti

I : Arus

D : Diameter kawat

A_w : Area penampang kawat

$N_{\max_core}$: Jumlah lilitan maksimum inti

2. Kapasitansi:

Pemilihan nilai kapasitansi dalam *buck converter* sangat penting karena kapasitor berfungsi mengurangi riak tegangan pada keluaran. Nilai kapasitansi yang besar memungkinkan kapasitor menyimpan lebih banyak energi sehingga tegangan keluaran dapat dijaga dengan stabil. Walaupun begitu, nilai kapasitansi yang tinggi menyebabkan respons transien yang lebih lambat dan harganya mahal. Nilai kapasitansi dapat dihitung dengan Rumus 2-18.

$$C_{\text{out}(\min)} = \frac{\Delta I_L}{8 \times f_{\text{sw}} \times \Delta V_{\text{out}}} \quad (2-18)$$

di mana,

$C_{\text{out}(\min)}$: Kapasitor keluaran [F]

ΔI_L : Perubahan arus induktor [A]

f_{sw} : Frekuensi *switching* [Hz]

ΔV_{out} : Perubahan tegangan keluaran [V]

3. Dead Time:

Penentuan *dead time* yang tepat sangat penting untuk memastikan bahwa komponen *switching* tidak aktif secara bersamaan. Rumus 2-19 digunakan untuk menghitung *dead time* minimum yang dibutuhkan. Sementara itu, Rumus 2-20 dapat digunakan untuk memperoleh nilai *dead time* maksimal.

$$t_{\text{dead_min}} = \max(t_{d(\text{off})} + t_f, t_{d(\text{on})}) \times \text{safety margin} \quad (2-19)$$

$$t_{\text{dead_max}} = t_{\text{dead_min}} \times \text{safety margin} \quad (2-20)$$

di mana,

$t_{\text{dead_min}}$: Waktu mati minimum yang dibutuhkan [s]

$t_{\text{dead_max}}$: Waktu mati maksimal yang dibutuhkan [s]

$t_{\text{d(off)}}$: Waktu tunda saat komponen *switching* mati (*turn-off delay time*) [s]

t_{f} : Waktu jatuh tegangan komponen *switching* (*fall time*) [s]

$t_{\text{d(on)}}$: Waktu tunda saat komponen *switching* menyala (*turn-on delay time*) [s]

safety margin : Margin keamanan untuk memastikan ketepatan waktu mati

4. *Duty Cycle*:

Perhitungan *duty cycle* dilakukan untuk mengatur tegangan keluaran berdasarkan tegangan masukan maksimum. Penelitian [8] memaparkan bahwa hubungan *duty cycle* dengan V_{in} dan V_{out} dirumuskan dengan Rumus 2-21.

$$D = \frac{V_{\text{out}}}{V_{\text{in(max)}} \times \eta} \quad (2-21)$$

di mana,

V_{out} : Tegangan keluaran [V]

$V_{\text{in(max)}}$: Tegangan masukan maksimal [V]

D : *Duty cycle* dalam desimal

η : Efisiensi konverter dalam persentase (%)

5. Efisiensi:

Efisiensi dalam *buck converter* mengacu pada rasio antara daya keluaran yang berguna dan daya total yang dikonsumsi. Efisiensi ini biasanya dinyatakan dalam persentase dan merupakan indikator seberapa efektif konverter dalam mengubah tegangan input menjadi tegangan keluaran yang diinginkan dengan kehilangan daya seminimal mungkin. Faktor-faktor yang mempengaruhi efisiensi meliputi tegangan keluaran, arus keluaran, dan rugi-rugi daya. Rumus 2-22 adalah perhitungan untuk mencari efisiensi dalam *buck converter*.

$$\eta = \frac{V_{\text{out}} \times I_{\text{out}}}{V_{\text{out}} \times I_{\text{out}} + P_{\text{total}}} \quad [\%] \quad (2-22)$$

di mana,

V_{out} : Tegangan keluaran [V]

I_{out} : Arus keluaran [A]

P_{total} : Total rugi daya [W]

2.2.2 *Machine Learning*

Machine Learning (ML) merupakan cabang dari kecerdasan buatan (*Artificial Intelligence* atau AI) yang fokus pada pengembangan sistem yang mampu belajar dari data dan membuat keputusan atau prediksi berdasarkan data tersebut tanpa diprogram secara eksplisit [26]. ML memanfaatkan algoritma untuk memodelkan dan memahami kompleksitas data sehingga dapat menggeneralisasi dari data yang diberikan. Konsep dasar di balik ML adalah untuk mengidentifikasi pola dan hubungan dalam data yang digunakan untuk memprediksi hasil di masa depan atau untuk mengklasifikasikan data baru. Bagian ini akan membahas beberapa jenis pembelajaran *machine learning* dan evaluasi model *machine learning*.

2.2.2.1 Jenis pembelajaran *Machine Learning*

ML dapat dikategorikan ke dalam beberapa jenis pembelajaran berdasarkan cara data diproses dan model dipelajari. Masing-masing jenis memiliki pendekatan yang unik dalam menganalisis data dan memecahkan masalah yang berbeda. Tiga jenis pembelajaran utama dalam ML adalah *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. Pemahaman mendalam tentang masing-masing jenis ini penting untuk mengaplikasikan teknik yang tepat sesuai dengan kebutuhan data dan tujuan analisis.

1. *Supervised Learning*:

Dalam *supervised learning*, model dilatih menggunakan data set yang sudah dilabeli. Data set tersebut memiliki input dan keluaran atau jawaban yang benar. Tujuan utama adalah untuk mengembangkan sebuah model yang mampu menggeneralisasi atau memprediksi label untuk data set yang belum pernah dilihat sebelumnya. *Supervised learning* melibatkan dua tahap utama, yaitu tahap pelatihan dan tahap pengujian, dengan data set yang bagi untuk kedua tahapan [27]. Dalam tahap pelatihan, model secara iteratif menyesuaikan parameter internalnya untuk meminimalkan kesalahan prediksi dengan *loss function*. Setelah model dilatih, performanya diuji menggunakan data set yang dibagi atau data set yang tidak digunakan selama fase pelatihan untuk mengevaluasi kemampuan model dalam memprediksi berdasarkan data baru.

2. *Unsupervised Learning*:

Unsupervised learning adalah jenis pembelajaran *machine learning* yang menggunakan data set tanpa label [28]. Teknik ini akan mengidentifikasi pola dan struktur dari data set tanpa label tersebut. Pendekatan ini sangat berguna karena terkadang

tidak ada informasi awal mengenai hasil atau kategori dari data set. Teknik ini sering digunakan untuk segmentasi pasar atau pengelompokan konsumen berdasarkan data yang tidak memiliki label yang jelas.

3. **Reinforcement Learning:**

Reinforcement learning (RL) adalah jenis machine learning di mana agen belajar untuk membuat keputusan dengan cara berinteraksi dengan lingkungan dan menerima umpan balik dalam bentuk *reward* atau *punishment* [29]. Tujuan utama dari RL adalah untuk mengembangkan agen yang dapat mengambil tindakan yang memaksimalkan *reward* kumulatif dari waktu ke waktu. Proses belajar dalam RL melibatkan *trial and error*, di mana agen mencoba berbagai tindakan dan belajar dari hasilnya untuk meningkatkan performa di masa depan.

Dalam reinforcement learning, agen melakukan tindakan yang mempengaruhi keadaan lingkungan dan menerima reward berdasarkan tindakan tersebut. Agen mengembangkan strategi (*policy*) untuk memilih tindakan terbaik dalam berbagai situasi.

2.2.2.2 **Neural Network**

Neural network (NN) adalah salah satu jenis algoritma dalam *machine learning*. NN dirancang untuk meniru struktur dan fungsi otak manusia yang memiliki unit-unit yang saling berhubungan (neuron) [30]. Setiap neuron akan menerima sinyal, memproses, dan mengirimkan sinyal tersebut ke neuron lain dalam jaringan yang terdiri dari beberapa lapisan. Lapisan dalam *neural network* biasanya terdiri dari lapisan input (*input layer*), lapisan tersembunyi (*hidden layer*), dan lapisan keluaran (*output layer*).

1. **Lapisan Input (*Input Layer*):**

Lapisan pertama dalam *neural network* ini menerima data mentah, di mana jumlah neuron sesuai dengan jumlah fitur dari data input. Neuron dalam lapisan ini hanya meneruskan data ke lapisan berikutnya tanpa melakukan pemrosesan. Oleh karena itu, *input layer* seringkali digabungkan dengan *hidden layer* sekaligus.

2. **Lapisan Tersembunyi (*Hidden Layer*):**

Lapisan yang berada dalam bagian tengah ini dapat terdiri dari satu atau lebih lapisan. *Hidden layer* akan memproses dan mentransformasikan data yang diterima dari *input layer*. Setiap neuron di lapisan tersembunyi mengaplikasikan fungsi aktivasi pada input yang diterima, kemudian mengirimkan hasilnya ke neuron-neuron di lapisan berikutnya. Fungsi aktivasi, seperti *Rectified Linear Unit* (ReLU) atau *sigmoid*, membantu jaringan untuk belajar dan menangkap pola-pola nonlinear dalam data. Lapisan tersembunyi ini adalah tempat sebagian besar pem-

rosesan terjadi dan sangat berpengaruh terhadap kemampuan jaringan untuk mempelajari representasi fitur yang kompleks.

3. Lapisan Output (*Output Layer*):

Lapisan keluaran adalah lapisan terakhir dalam *neural network* yang menghasilkan prediksi akhir atau keputusan berdasarkan pemrosesan yang dilakukan oleh lapisan-lapisan sebelumnya. Jumlah neuron di lapisan keluaran disesuaikan dengan jumlah keluaran yang diinginkan. Lapisan keluaran juga memiliki fungsi aktivasi yang disesuaikan dengan jenis masalah yang sedang diselesaikan. Berikut adalah beberapa fungsi aktivasi yang umum digunakan beserta aplikasinya:

1. *Sigmoid*:

Fungsi ini sering digunakan untuk masalah klasifikasi biner. Fungsi *sigmoid* mengubah output menjadi nilai antara 0 dan 1, yang cocok untuk memodelkan probabilitas kelas.

2. *Softmax*:

Fungsi ini lebih umum digunakan untuk klasifikasi multikelas. *Softmax* mengubah output menjadi distribusi probabilitas di antara beberapa kelas sehingga total probabilitas untuk semua kelas adalah 1.

3. *Softplus*:

Fungsi ini menghasilkan output dalam rentang (0, tak terhingga) dan sering digunakan untuk data yang hasilnya harus berupa nilai positif. *Softplus* bisa menjadi pilihan yang baik untuk regresi atau tugas lain di mana nilai keluaran tidak terbatas pada interval tertentu.

2.2.2.3 Evaluasi *Machine Learning*

Evaluasi model *machine learning* adalah langkah penting untuk menilai kinerja dan efektivitas model dalam menyelesaikan tugas tertentu. Dua komponen yang perlu dipertimbangkan adalah metrik pengukuran dan *loss function*.

1. Metrik Pengukuran

Metrik pengukuran digunakan untuk mengevaluasi kinerja model setelah pelatihan. Berikut adalah beberapa metrik pengukuran yang sering digunakan dalam evaluasi model *machine learning*.

1. *Mean Absolute Error (MAE)*:

MAE adalah rata-rata nilai absolut dari selisih antara prediksi dan nilai aktual. Rumus 2-23 adalah rumusan perhitungan untuk mencari nilai

MAE.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2-23)$$

MAE mengukur seberapa besar kesalahan tanpa memperhatikan arah kesalahan. Metrik ini mudah diinterpretasikan karena berada dalam skala yang sama dengan data asli. MAE memberikan gambaran rata-rata seberapa jauh prediksi model dari nilai aktualnya.

2. *Mean Squared Error (MSE)*:

MSE adalah rata-rata kuadrat dari selisih antara prediksi dan nilai aktual. Rumus 2-24 menunjukkan bagaimana nilai MSE dapat diperoleh.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2-24)$$

MSE memberikan penalti yang lebih besar untuk kesalahan yang lebih besar sehingga lebih sensitif terhadap *outlier*. MSE membantu memahami seberapa parah kesalahan prediksi dengan memberikan bobot lebih besar pada kesalahan yang lebih besar.

3. *Root Mean Squared Error (RMSE)*:

RMSE adalah akar kuadrat dari MSE. Nilai RMSE dapat diperoleh dengan perhitungan dengan Rumus 2-25.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2-25)$$

RMSE memberikan skala yang sama dengan data asli dan lebih intuitif dibandingkan MSE. RMSE juga lebih sensitif terhadap *outlier* dibandingkan MAE. RMSE memberikan gambaran seberapa besar kesalahan prediksi dalam satuan yang sama dengan variabel target.

4. *R-squared (Coefficient of Determination)*:

R-squared mengukur proporsi variansi dalam data dependen yang bisa dijelaskan oleh variabel independen. Rumus 2-26 adalah cara menghitung nilai tersebut.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2-26)$$

Nilai *R-squared* yang mendekati 1 menunjukkan bahwa model dapat menjelaskan sebagian besar variansi dalam data. *R-squared* sering digunakan untuk menilai seberapa baik model *fit* dengan data. *R-squared* menunjukkan

seberapa besar variasi data yang dapat dijelaskan oleh model, di mana semakin tinggi nilainya, semakin baik model dalam menjelaskan data.

5. **Mean Absolute Percentage Error (MAPE):**

MAPE adalah rata-rata persentase absolut dari selisih antara prediksi dan nilai aktual. MAPE dapat dihitung dengan Rumus 2-27.

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2-27)$$

MAPE mengukur kesalahan dalam bentuk persentase sehingga lebih mudah untuk diinterpretasikan. MAPE menunjukkan rata-rata persentase kesalahan prediksi terhadap nilai aktual, memudahkan pemahaman tentang seberapa besar kesalahan dalam konteks persentase.

6. **Koefisien Variasi (KV):**

KV adalah rasio standar deviasi terhadap rata-rata, yang digunakan untuk mengukur tingkat variabilitas relatif terhadap rata-rata. Nilai KV dapat dihitung dengan Rumus 2-28.

$$\text{KV} = \frac{\sigma}{\mu} \times 100\% \quad (2-28)$$

KV memberikan gambaran seberapa besar variasi relatif terhadap rata-rata data. Metrik ini berguna untuk membandingkan tingkat variabilitas antara data set yang berbeda. KV menunjukkan seberapa besar penyimpangan standar dari mean dalam bentuk persentase, memungkinkan pemahaman tentang seberapa besar variasi relatif terhadap *mean*.

7. **Error:**

Error adalah kesalahan atau penyimpangan dari nilai sebenarnya. Nilai error dalam persentase dapat dihitung menggunakan Rumus 2-29.

$$\%_{\text{error}} = \left| \frac{\text{theoretical} - \text{experimental}}{\text{theoretical}} \right| \times 100\% \quad (2-29)$$

2. **Loss Function:**

Loss function, atau fungsi kerugian, adalah komponen penting dalam pelatihan model *machine learning*. Fungsi ini digunakan untuk mengukur seberapa baik atau buruk kinerja model dengan membandingkan prediksi model dengan nilai sebenarnya. Beberapa *loss function* yang sering digunakan dalam masalah regresi dijelaskan dalam subbagian ini.

1. *Mean Squared Error (MSE)*:

Sama seperti metrik MSE yang digunakan untuk evaluasi, MSE sering digunakan sebagai *loss function* dalam pelatihan model regresi karena penalti yang diberikan untuk kesalahan yang besar. Rumus yang dapat digunakan juga sama, yaitu Rumus 2-24.

2. *Mean Absolute Error (MAE)*:

Selain metrik evaluasi, MAE juga dapat digunakan menjadi *loss function* untuk mengurangi pengaruh *outlier*. Rumus 2-23 dapat digunakan sebagai perhitungan *loss function* ini.

3. *Huber Loss*:

Huber loss adalah *loss function* yang sering digunakan dalam regresi. *Huber loss* menggabungkan keunggulan MSE dan MAE. *Huber loss* dirancang untuk mengatasi beberapa kelemahan dari MSE dan MAE secara individual. Secara khusus, *Huber loss* memberikan toleransi yang lebih baik terhadap *outlier* dibandingkan dengan MSE dan lebih sensitif terhadap *outlier* dibandingkan dengan MAE. Rumus 2-30 menunjukkan perhitungan *loss function* ini.

$$L_{\delta}(a) = \begin{cases} \frac{1}{2}a^2 & \text{untuk } |a| \leq \delta, \\ \delta(|a| - \frac{1}{2}\delta) & \text{selainnya.} \end{cases} \quad (2-30)$$

Evaluasi yang komprehensif menggunakan berbagai metrik pengukuran dan *loss function* yang tepat akan memberikan gambaran yang lebih jelas tentang kinerja model regresi dan membantu dalam memilih model terbaik untuk diterapkan pada masalah yang dihadapi.

2.2.3 Optimisasi

Optimisasi adalah proses mencari nilai terbaik dari suatu fungsi atau sistem dalam kondisi tertentu dengan cara seefektif atau sefungsional mungkin [31]. Proses ini sangat penting karena membantu meningkatkan performa dan efisiensi sistem dengan menemukan cara paling efektif untuk menggunakan sumber daya yang terbatas, mengurangi biaya, dan meningkatkan hasil.

2.2.3.1 Metode Optimisasi

Terdapat banyak metode optimisasi yang telah dikembangkan untuk berbagai aplikasi. Di antara banyak metode yang ada, tiga yang sering digunakan adalah *Gradient Descent*, *Newton-Raphson*, dan algoritma genetik. Masing-masing metode ini memiliki pendekatan yang berbeda-beda dalam mencapai solusi yang efektif dan efisien.

1. *Gradient Descent*:

Gradient Descent adalah teknik iteratif yang digunakan untuk menemukan nilai minimum dari suatu fungsi. Algoritma ini bekerja dengan memperbarui parameter dengan bergerak ke arah berlawanan dari gradien fungsi objektif, seperti yang ditunjukkan dalam Rumus 2-31.

$$x_{n+1} = x_n - \gamma \nabla F(x_n) \quad (2-31)$$

di mana,

x_{n+1} : Nilai parameter yang diperbarui pada iterasi $n + 1$

x_n : Nilai parameter pada iterasi n

γ : Ukuran langkah atau *learning rate*

$\nabla F(x_n)$: Gradien dari fungsi F pada titik x_n

2. *Newton-Raphson*:

Newton-Raphson digunakan untuk menemukan titik optimal dari suatu fungsi yang dapat diturunkan. Teknik ini memanfaatkan turunan pertama dan kedua dari fungsi untuk memperkirakan solusi dengan lebih tepat dan cepat. Rumus 2-32 menunjukkan cara untuk memperbarui perkiraan nilai optimal pada iterasi ke- n .

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \quad (2-32)$$

di mana,

x_{n+1} : Nilai parameter yang diperbarui pada iterasi $n + 1$


x_n : Nilai parameter pada iterasi n

$f(x_n)$: Nilai fungsi pada x_n

$f'(x_n)$: Turunan pertama dari fungsi pada x_n

3. *Algoritma Genetik*:

Algoritma genetik mengadopsi prinsip seleksi alam dari biologi untuk mencari solusi optimal [32]. Proses dalam algoritma ini melibatkan inisialisasi populasi solusi yang kemudian diubah secara bertahap melalui seleksi, *crossover*, dan mutasi, yang bertujuan untuk menemukan solusi yang lebih baik dalam pencarian global. Gambar 2.3 menunjukkan diagram alir dari algoritma genetik.



Gambar 2.3. Diagram Alir Algoritma Genetik

Algoritma genetik diawali dengan inisialisasi populasi dengan membentuk sejumlah solusi acak. Selanjutnya, setiap individu dievaluasi berdasarkan *fitness* mereka. Individu-individu dengan *fitness* tertinggi kemudian dipilih untuk reproduksi. Proses *crossover* dilakukan untuk menghasilkan keturunan baru dengan menukar bagian dari gen dua individu, diikuti dengan mutasi yang mengubah beberapa bagian gen secara acak. Proses ini diulang hingga kriteria berhenti terpenuhi, seperti jumlah generasi tertentu atau tingkat konvergensi yang diinginkan.

2.2.4 Perbandingan Metode

Bagian perbandingan metode dilakukan untuk mengevaluasi dan mengidentifikasi metode yang dapat digunakan dalam penelitian ini. Perbandingan akan melibatkan dua topologi utama *buck converter* (*asynchronous* dan *synchronous*), teknik *machine learning*, dan juga metode optimisasi. Fokus utama dalam analisis ini adalah untuk memberikan gambaran tentang metode yang dapat digunakan. Dengan demikian, metode yang nantinya digunakan dapat sesuai dengan kriteria, yaitu berkaitan dengan kinerja, efisiensi, kompleksitas, dan aplikasinya dalam desain parameter sirkuit.

2.2.4.1 Topologi Buck Converter

Bagian 2.2.1.4 menjelaskan bahwa ada dua topologi *buck converter* yang sering digunakan, yaitu *asynchronous* dan *synchronous buck converter*. Kedua topologi ini memiliki karakteristik, kelebihan, dan kelemahan masing-masing yang memengaruhi efisiensi, kompleksitas desain, dan biaya implementasi. Berikut akan diberikan gambaran tentang keuntungan dan kelemahan dari kedua topologi ini yang ditunjukkan dalam Tabel 2.5.

Tabel 2.5. Perbandingan *Asynchronous* dan *Synchronous Buck Converter*

Kriteria	<i>Asynchronous Buck Converter</i>	<i>Synchronous Buck Converter</i>
Karakteristik	Satu transistor dan satu dioda	Dua transistor yang dikendalikan secara sinkron
Efisiensi	Lebih rendah karena penggunaan dioda	Lebih tinggi, tidak menggunakan dioda
Biaya Produksi	Lebih rendah	Lebih tinggi karena komponen tambahan
Pengelolaan Panas	Lebih sulit pada arus tinggi	Lebih efisien dan mudah
Kompleksitas Desain	Lebih sederhana	Lebih kompleks karena kontrol sinkronisasi

Kedua topologi *buck converter* sama-sama membutuhkan komponen *switching*, di mana terdapat 3 pilihan yang biasa digunakan. Tabel 2.6 memberikan perbandingan beberapa kriteria untuk MOSFET, IGBT, dan BJT.

Tabel 2.6. Perbandingan MOSFET, IGBT, dan BJT

Kriteria	MOSFET	IGBT	BJT
Resistansi <i>On-State</i>	Rendah	Menengah	Tinggi

Kecepatan Switching	Tinggi	Menengah	Rendah
Efisiensi	Tinggi	Menengah	Rendah
Kemampuan Arus	Menengah	Tinggi	Menengah
Tegangan Operasional	Menengah	Tinggi	Rendah-Menengah
Kontrol	Mudah	Mudah	Sulit
Biaya	Menengah	Tinggi	Rendah

2.2.4.2 Jenis *Machine Learning*

Berbagai jenis pembelajaran *machine learning* sudah dibahas dalam Bagian 2.2.2, yaitu *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. Masing-masing jenis memiliki karakteristik unik serta kelebihan dan kekurangan yang membedakannya dalam berbagai aplikasi. Tabel 2.7 menjelaskan tentang karakteristik dari *machine learning* dengan *supervised learning*, sementara Tabel 2.8 memaparkan tentang *unsupervised learning*. Di sisi lain, Tabel 2.9 meringkas tentang jenis pembelajaran dengan *reinforcement learning*.

Tabel 2.7. Jenis Pembelajaran *Machine Learning* - *Supervised Learning*

Karakteristik	Kelebihan	Kekurangan
Menggunakan data set yang telah dilabeli.	Efektif dalam kasus dengan keluaran yang diketahui.	Bergantung pada kualitas dan kuantitas data yang dilabeli.
Mengasosiasikan input ke keluaran yang diketahui.	Menghasilkan prediksi yang akurat jika model terlatih dengan baik.	Kurang fleksibel terhadap data tanpa label atau kategori yang jelas.
Dibagi menjadi fase pelatihan dan pengujian.	Sesuai untuk aplikasi dengan prediksi dan klasifikasi yang jelas.	Rentan terhadap <i>overfitting</i> jika data pelatihan tidak representatif atau bervariasi.

Tabel 2.8. Jenis Pembelajaran *Machine Learning - Unsupervised Learning*

Karakteristik	Kelebihan	Kekurangan
Tidak menggunakan data yang dilabeli.	Mengidentifikasi pola yang tidak diketahui sebelumnya.	Hasil bisa sulit diinterpretasikan.
Menemukan pola atau struktur tersembunyi tanpa label.	Berguna dalam analisis eksploratif dan segmentasi pasar.	Tidak menghasilkan prediksi atau klasifikasi yang jelas.
Berguna untuk eksplorasi data dan identifikasi kelompok.	Fleksibel dalam menangani data yang beragam dan kompleks.	Memerlukan eksperimen dan penyetelan parameter yang intensif.

Tabel 2.9. Jenis Pembelajaran *Machine Learning - Reinforcement Learning*

Karakteristik	Kelebihan	Kekurangan
Belajar melalui interaksi dengan lingkungan.	Efektif dalam lingkungan dinamis dan situasi keputusan berurutan.	Memerlukan banyak sumber daya komputasi dan waktu untuk belajar.
Mendapatkan <i>reward</i> atau hukuman sebagai <i>feedback</i> .	Efisien dalam aplikasi seperti robotika, permainan, dan navigasi otomatis.	Bergantung pada desain <i>reward system</i> yang efektif.
Mengembangkan strategi atau kebijakan keputusan.	Adaptif terhadap perubahan dalam data atau lingkungan.	Sulit mencapai konvergensi di lingkungan dengan banyak variabel.

2.2.4.3 Metode Optimisasi

Bagian ini akan memberikan rangkuman karakteristik, kelebihan, dan kekurangan dari tiga metode optimisasi yang telah dibahas sebelumnya. Tabel 2.10 menunjukkan ringkasan dari metode *gradient descent*. Sementara itu, Tabel 2.11 berisi tentang metode *newton raphson*. Terakhir, Tabel 2.12 membahas tentang ringkasan karakteristik, kelebihan, dan kekurangan dari algoritma genetik.

Tabel 2.10. Karakteristik Metode Optimisasi - *Gradient Descent*

Karakteristik	Kelebihan	Kekurangan
Iteratif berdasarkan gradien.	Mudah diimplementasikan.	Rentan terhadap minimum lokal.
Menemukan nilai minimum fungsi.	Efektif untuk banyak masalah optimasi.	Memerlukan <i>learning rate</i> yang tepat.
Efisien untuk fungsi dengan turunan.	Berguna untuk pelatihan model ML.	Kurang efisien untuk banyak dimensi.

Tabel 2.11. Karakteristik Metode Optimisasi - *Newton-Raphson*

Karakteristik	Kelebihan	Kekurangan
Menggunakan turunan pertama dan kedua.	Konvergensi cepat jika dekat titik optimal.	Memerlukan perhitungan turunan kedua, yang bisa rumit.
Menemukan titik optimal dari fungsi yang dapat diturunkan	Akurat untuk fungsi dengan turunan kedua.	Rentan terhadap titik nonoptimal.
Cepat konvergensi jika mendekati solusi.	Efisien dalam banyak kasus.	Tidak efektif jika jauh dari titik optimal awal.

Tabel 2.12. Karakteristik Metode Optimisasi - Algoritma Genetik

Karakteristik	Kelebihan	Kekurangan
Berdasarkan prinsip seleksi alam dan genetika.	Dapat menemukan solusi global.	Memerlukan banyak sumber daya komputasi.
Menggunakan populasi solusi yang berevolusi.	Tidak memerlukan turunan fungsi.	Konvergensi bisa lambat.
Melibatkan operasi seleksi, <i>crossover</i> , dan mutasi.	Fleksibel dan dapat diterapkan pada berbagai masalah.	Hasil akhir bergantung pada parameter algoritma.

2.2.5 Kriteria Pemilihan Metode

Pemilihan metode yang tepat dalam desain dan implementasi suatu sistem sangatlah penting untuk mencapai kinerja yang optimal. Pada subbagian ini, akan dibahas kriteria pemilihan metode yang mencakup tiga aspek utama yang telah dibahas sebelumnya,

yaitu topologi *buck converter*, teknik *machine learning*, dan metode optimisasi. Tabel 2.13 memberikan daftar kriteria pemilihan metode sehingga dapat mencapai objektif dari penelitian ini.

Tabel 2.13. Kriteria Pemilihan Metode

Topologi <i>Buck Converter</i>	Teknik <i>Machine Learning</i>	Metode Optimisasi
Efisiensi Energi	Akurasi	Kecepatan Konvergensi
Biaya Produksi	Kecepatan Pelatihan	Kemudahan Implementasi
Kompleksitas Desain	Kompleksitas Model	Stabilitas Konvergensi
Pengelolaan Panas	Kemampuan Generalisasi	Kompleksitas Perhitungan

BAB III

METODE PENELITIAN

Bab III membahas tentang metode penelitian yang digunakan dalam penelitian ini. Metode penelitian digunakan untuk mencapai tujuan utama dalam penelitian ini, yaitu merancang *buck converter* dengan pendekatan berbasis AI. Metode penelitian mencakup alat dan bahan tugas akhir, metode yang digunakan, dan alur tugas akhir.

3.1 Alat dan Bahan Tugas akhir

Pada penelitian ini, digunakan berbagai alat dan bahan yang terdiri dari perangkat keras dan perangkat lunak untuk mendukung pelaksanaan penelitian tugas akhir ini. Alat dan bahan yang digunakan memiliki peran penting dalam memastikan bahwa penelitian dapat berjalan dengan lancar dan menghasilkan data yang akurat serta dapat diandalkan. Pada subbagian berikut, akan dijelaskan secara rinci mengenai alat dan bahan yang digunakan dalam tugas akhir ini.

3.1.1 Alat Tugas akhir

Dalam penelitian ini, berbagai alat, baik perangkat keras maupun perangkat lunak, digunakan sebagai sarana pendukung penelitian. Berikut adalah alat-alat yang digunakan.

1. *Laptop* dengan spesifikasi minimum sistem operasi Windows 10 64-bit, *processor* Intel Core i5 CPU @ 2,5 GHz, memori 4GB DDR3, hardisk 256GB. Pada tugas akhir ini digunakan Windows 10 64-bit, Intel Core i5 7200U CPU, Memori 8GB DDR 3, hardisk 256GB.
2. Python versi 3.11.6
3. PLECS versi 4.8.2 (64 bit)

3.1.2 Bahan Tugas akhir

Bahan yang digunakan dalam penelitian ini berupa data atau informasi yang dikumpulkan menjadi data set. Data set dalam penelitian ini berupa data set pihak pertama yang disusun melalui simulasi dan perhitungan. Berikut adalah data set yang digunakan dalam penelitian.

1. *Data set simulasi PLECS*. Data set disusun berdasarkan hasil simulasi PLECS dengan variasi nilai parameter L , C , f_{sw} , t_d , dan d_{cycle} .
2. *Data set kapasitansi*. Data set berisi nilai-nilai kapasitansi yang beredar di pasar dan nilai kapasitansi hasil kombinasi (paralel atau seri) [33]. Data set juga memuat hasil perhitungan volume dari kombinasi kapasitor yang digunakan.

3. *Data set induktansi*. Data set ini berisi nilai-nilai induktansi yang umum digunakan dan nilai hasil kombinasinya (paralel dan seri) [34]. Volume hasil perhitungan juga disusun untuk melengkapi data set induktansi.

3.2 Metode yang Digunakan


Bagian 3.2 membahas metode atau cara yang akan digunakan dalam penelitian ini. Metode yang digunakan dalam penelitian ini mencakup tiga aspek utama, yaitu pemilihan topologi *buck converter*, teknik *machine learning*, dan metode optimisasi. Ketiga aspek ini akan dijelaskan secara rinci untuk memberikan gambaran yang jelas tentang pendekatan yang diambil dalam penelitian ini.

3.2.1 Topologi Buck Converter

Terdapat dua pilihan terkait pemilihan topologi *buck converter*, yaitu *synchronous* dan *asynchronous*. Tabel 2.5 menunjukkan perbandingan dari kedua topologi tersebut. Topologi *synchronous buck converter* memiliki beberapa keunggulan dibandingkan *asynchronous buck converter*. Berdasarkan referensi [35] yang membahas tentang perbandingan efisiensi kedua topologi, topologi *synchronous buck converter* memiliki efisiensi yang lebih tinggi dibandingkan topologi *asynchronous buck converter* dengan pengujian pada frekuensi *switching* dan beban yang bervariasi. Pengujian tersebut juga dilakukan menggunakan perangkat lunak simulasi sehingga relevan dengan pendekatan yang akan dilakukan dalam penelitian ini. Di sisi lain, faktor biaya dapat diabaikan karena tidak masuk dalam lingkup penelitian. Oleh karena itu, berdasarkan keunggulan telah diuraikan, topologi *synchronous buck converter* akan digunakan dalam penelitian ini.

Subbagian selanjutnya akan membahas tentang rangkaian dan pemilihan komponen pada *synchronous buck converter*.

3.2.1.1 Rangkaian Synchronous Buck Converter



Gambar 3.1. Rangkaian *Synchronous Buck Converter*

Gambar 3.1 adalah rangkaian dari *synchronous buck converter*. Rangkaian tersebut menunjukkan konfigurasi dasar dari *synchronous buck converter* yang menggunakan dua transistor sebagai sakelar (Q_1 dan Q_2), induktor (L) yang menyimpan energi, dan kapasitor (C) yang berfungsi sebagai filter. Kemudian, terdapat tegangan input (V_{in}), arus induktor (I_L), dan tegangan keluaran (V_{out}) yang juga akan dibahas lebih lanjut. Selain itu, terdapat resistor beban yang terhubung dengan keluaran *synchronous buck converter*.

3.2.1.2 Pemilihan Komponen

Subbab ini membahas pemilihan komponen berdasarkan rangkaian *synchronous buck converter* yang dibahas sebelumnya. Komponen yang dipilih meliputi komponen *switching*, induktor, dan kapasitor.

Tabel 2.6 tentang perbandingan transistor menunjukkan bahwa MOSFET memiliki beberapa keunggulan dibandingkan dengan IGBT dan BJT. MOSFET dipilih karena memiliki resistansi *on-state* yang rendah sehingga mengurangi rugi daya akibat panas dan meningkatkan efisiensi. Selain itu, MOSFET mampu beroperasi pada kecepatan *switching* yang tinggi. Keunggulan lain dari MOSFET adalah kemudahan dalam kontrol karena MOSFET dikendalikan oleh tegangan dan membutuhkan arus kontrol yang rendah, membuatnya lebih efisien dalam aplikasi konverter daya.

Sementara itu, untuk induktor dan kapasitor dapat diperoleh berdasarkan perhitungan dalam Bagian 2.2.1.6 dengan menyesuaikan spesifikasi desain. Pemilihan komponen untuk rangkaian *synchronous buck converter* ini juga mempertimbangkan komponen asli untuk memastikan akurasi dan sesuai dengan implementasi.

3.2.2 Machine Learning

Bagian 3.2.2 menjelaskan secara rinci metode penelitian yang digunakan dalam penerapan *machine learning*. Bagian ini mencakup proses pembuatan data set untuk pelatihan model, serta langkah-langkah yang diambil dalam pengembangan dan evaluasi model *machine learning*.

3.2.2.1 Pembuatan Data Set

Subbagian ini akan membahas proses dalam pembuatan data set yang digunakan untuk pelatihan dan pengujian model *machine learning*. Tahap ini krusial karena kualitas data set menentukan kinerja model yang dikembangkan. Sesuai dengan penjelasan Bagian 3.1.2 tentang bahan tugas akhir, ada 3 data set yang dibuat, yaitu data set simulasi PLECS, data set kapasitansi, dan data set induktansi. Pembuatan setiap data set memiliki tahapan spesifik yang akan dijelaskan dalam bagian selanjutnya.

1. Data Set Simulasi PLECS:

Data set yang dihasilkan dari simulasi PLECS merupakan kompilasi data yang dikumpulkan untuk menganalisis kinerja rangkaian *synchronous buck converter*. Dalam simulasi ini, beberapa parameter utama diubah-ubah untuk mengevaluasi pengaruhnya terhadap performa sistem. Parameter-parameter yang divariasikan meliputi induktansi (L), kapasitansi (C), frekuensi *switching* (f_{sw}), *dead time* (t_d), dan *duty cycle* (d_{cycle}). Dengan menguji berbagai kombinasi nilai dari parameter-parameter ini, data set yang komprehensif dapat dibuat untuk digunakan dalam pelatihan model *machine learning* dan analisis lebih lanjut.

2. Data Set Kapasitansi:

Data set kapasitansi berisi nilai-nilai kapasitansi (C) yang diatur dalam berbagai konfigurasi, baik dalam bentuk rangkaian seri maupun paralel. Nilai-nilai kapasitansi ini berada dalam suatu rentang yang telah didefinisikan untuk mencakup berbagai skenario operasional yang mungkin terjadi. Selain nilai C , data set ini juga mencakup volume fisik dari setiap konfigurasi kapasitansi. Dengan kata lain, pemilihan nilai kapasitansi juga tergantung komponen asli yang penting untuk pertimbangan desain dan aplikasi praktis. Data set ini memberikan gambaran komprehensif mengenai bagaimana variasi kapasitansi dan konfigurasinya mempengaruhi karakteristik keseluruhan dari sistem yang sedang diteliti.

3. Data Set Induktansi

Data set induktansi berisi nilai-nilai induktansi (L) yang diatur berdasarkan komponen asli, yaitu inti toroid dengan jumlah lilitan tertentu. Nilai-nilai induktansi ini berada dalam suatu rentang yang telah ditentukan untuk memastikan bahwa semua kemungkinan skenario operasional dapat dianalisis. Selain nilai L , data set ini juga mencakup volume fisik dari setiap induktor yang dihasilkan.

3.2.2.2 Pembuatan Model *Machine Learning*

Bagian ini diawali dengan pemilihan teknik *machine learning* yang digunakan dalam penelitian ini. Beberapa jenis pembelajaran *machine learning* telah dieksplorasi dalam Bagian 2.2.2.1 dan dibandingkan dalam Bagian 2.2.4.2. Berdasarkan karakteristik, kelebihan, dan kekurangan yang disajikan dalam Tabel 2.7, *supervised learning* efektif dalam situasi di mana hasil yang diharapkan sudah diketahui dan data set telah dilabeli dengan baik. Hal ini membuat jenis ini sesuai untuk penelitian ini yang membutuhkan prediksi yang akurat dan terstruktur. Berdasarkan analisis tersebut, *neural network* dipilih karena kemampuannya yang unggul dalam menangani data nonlinier dan kompleks yang dapat ditemui dalam data set ini. *Neural network* memberikan fleksibilitas dalam menyesuaikan kedalaman dan lebar model, yang memungkinkan penyesuaian yang tepat terhadap kebutuhan dan kompleksitas data dalam penelitian ini. Selain itu, *neural network* memiliki kemampuan untuk belajar dari data yang besar, melakukan generalisasi

dari data pelatihan, dan mendeteksi pola-pola yang tidak terlihat secara eksplisit. Kelebihan ini menjadikan *neural network* pilihan yang tepat untuk mencapai hasil yang akurat dan handal dalam konteks penelitian ini.

3.2.3 Metode Optimisasi

Dalam penelitian ini, pemilihan metode optimisasi merupakan tahap yang sangat krusial. Berdasarkan karakteristik masalah yang dihadapi dan tujuan yang ingin dicapai, metode optimisasi yang paling tepat harus dipilih. Setelah mengevaluasi tiga metode optimisasi utama dari Bagian 2.2.3.1 dan tabel-tabel perbandingan dalam Bagian 2.2.4.3, metode optimisasi yang akan digunakan dalam penelitian ini. Berikut adalah alasan-alasan yang mendasari pemilihan algoritma genetik dibandingkan dua metode lainnya.

1. Kemampuan Pencarian Global:

Algoritma genetik memiliki kemampuan untuk melakukan pencarian global yang lebih baik dibandingkan *Gradient Descent* dan *Newton-Raphson*. Algoritma ini tidak mudah terjebak dalam titik minimum lokal karena proses seleksi, *crossover*, dan mutasi yang memastikan eksplorasi ruang solusi yang luas. Hal ini sangat penting dalam konteks penelitian ini di mana permukaan fungsi objektif dapat memiliki banyak titik minimum lokal yang dapat menyesatkan algoritma pencarian.

2. Ketahanan Terhadap Kondisi Awal:

Algoritma genetik tidak terlalu bergantung pada kondisi awal seperti *Gradient Descent* dan *Newton-Raphson*. Dalam *Gradient Descent*, pemilihan *learning rate* yang tidak tepat dapat mengakibatkan konvergensi yang lambat atau bahkan divergensi. Sementara itu, metode *Newton-Raphson* membutuhkan perhitungan turunan kedua yang bisa sangat sensitif terhadap kondisi awal. Algoritma genetik, dengan pendekatan populasi, meminimalkan risiko ini dan cenderung lebih stabil dalam berbagai kondisi awal.

3. Fleksibilitas dalam Menangani Fungsi Kompleks:

Algoritma genetik dapat digunakan untuk mengoptimalkan fungsi yang tidak harus kontinu atau terdiferensiasi, yang sering menjadi kendala dalam penggunaan *Gradient Descent* dan *Newton-Raphson*. Fungsi objektif dalam penelitian ini dapat memiliki karakteristik yang kompleks, sehingga fleksibilitas algoritma genetik menjadi keunggulan utama.

4. Evolusi dan Adaptasi:

Algoritma genetik mengadopsi prinsip evolusi dan adaptasi yang memungkinkan solusi untuk terus berkembang menuju yang lebih baik melalui generasi.

Proses seleksi yang mempertahankan solusi terbaik dan mengkombinasikan solusi yang baik untuk menghasilkan generasi baru memastikan bahwa solusi yang ditemukan cenderung lebih optimal dari waktu ke waktu.

Dengan mempertimbangkan alasan-alasan di atas, algoritma genetik dipilih sebagai metode optimisasi dalam penelitian ini. Pendekatan ini diharapkan mampu mengatasi tantangan optimisasi yang kompleks dan memberikan solusi yang lebih efektif dan efisien dibandingkan dengan *Gradient Descent* dan *Newton-Raphson*. Implementasi dari algoritma genetik akan dibuat sesuai dengan Gambar 2.3 atau diagram alir dari algoritma genetik.

3.2.4 Perhitungan Parameter Sirkuit Konvensional

Subbagian ini membahas langkah-langkah rinci untuk mendesain parameter-parameter kunci dari *synchronous buck converter* secara manual. Proses desain ini mencakup pemilihan dan perhitungan nilai induktor, kapasitor keluaran, frekuensi *switching*, dan *duty cycle*. Desain yang tepat dari parameter-parameter ini sangat penting untuk memastikan efisiensi, stabilitas, dan kinerja keseluruhan dari *converter*. Tabel 3.1 memberikan rincian terkait parameter dan rumus yang digunakan untuk memperoleh nilai untuk desain parameter sirkuit konvensional.

Tabel 3.1. Parameter dan Rumus yang Digunakan

Parameter	Rumus yang Digunakan
Induktansi (L)	Rumus 2-14
Kapasitansi (C)	Rumus 2-18
<i>Dead Time</i> (t_d)	Rumus 2-19
<i>Duty Cycle</i> (d_{cycle})	Rumus 2-21

3.2.5 Perbandingan dan Analisis Hasil Desain Parameter

Dalam bagian ini, hasil desain parameter yang diperoleh dari pendekatan berbasis AI akan dibandingkan dengan metode konvensional. Perbandingan ini mencakup beberapa aspek penting seperti efisiensi, tegangan keluaran, arus keluaran, dan juga rugi-rugi daya. Metode perbandingan dan analisis yang digunakan dijelaskan sebagai berikut.

3.2.5.1 Kriteria Perbandingan

Untuk membandingkan kedua metode desain, beberapa kriteria utama ditetapkan sebagai berikut. Kriteria-kriteria ini akan membantu dalam mengevaluasi performa dan keandalan dari masing-masing metode desain. Tabel 3.2 adalah parameter-parameter yang akan digunakan untuk kriteria perbandingan.

Tabel 3.2. Parameter Kriteria Perbandingan

Parameter	Penjelasan
Efisiensi (η)	Indikator utama dari seberapa baik konverter dalam mengubah daya masukan menjadi daya keluaran tanpa kerugian yang signifikan.
Tegangan Keluaran (V_{out})	Parameter yang menunjukkan kesesuaian tegangan keluaran dengan spesifikasi yang diinginkan.
Arus Keluaran (I_{out})	Nilai yang mencerminkan jumlah arus yang dihasilkan pada keluaran dan kesesuaiannya dengan kebutuhan sistem.
Riak Tegangan (ΔV_{out})	Fluktuasi tegangan keluaran yang menunjukkan stabilitas dan kualitas tegangan keluaran.
Riak Arus (ΔI_L)	Tingkat fluktuasi arus yang melalui induktor, yang mempengaruhi stabilitas dan efisiensi konverter.
Rugi-Rugi Daya	Berbagai kerugian daya dalam sistem, meliputi <i>conduction loss</i> , <i>output capacitance loss</i> , <i>dead time loss</i> , dan <i>gate charge loss</i> .

3.2.5.2 Metode Evaluasi

Metode evaluasi akan dilakukan melalui simulasi dan pengukuran. Kedua set parameter, baik yang dihasilkan melalui pendekatan berbasis AI maupun metode konvensional, akan diterapkan pada simulasi rangkaian menggunakan perangkat lunak PLECS. Simulasi ini akan memberikan gambaran lengkap mengenai performa sistem, termasuk efisiensi, tegangan keluaran, arus keluaran, riak tegangan, riak arus, dan juga rugi-rugi daya rangkaian. Hasil simulasi ini akan mencakup berbagai parameter kinerja penting yang ditunjukkan Tabel 3.2. Dengan menjalankan simulasi yang komprehensif, pemahaman yang lebih mendalam tentang pengaruh setiap set parameter akan diperoleh. Hal ini memungkinkan penilaian yang lebih akurat dalam menentukan metode desain yang paling optimal untuk diterapkan.

3.2.5.3 Analisis Hasil Perbandingan

Hasil dari metode evaluasi akan dibandingkan secara mendetail untuk menentukan kelebihan dan kekurangan dari masing-masing metode desain. Analisis ini akan mencakup parameter kinerja dalam Tabel 3.2. Dengan membandingkan kedua set parameter, gambaran yang jelas tentang performa sistem dalam berbagai kondisi operasional akan diperoleh. Identifikasi kelebihan dan kekurangan dari setiap metode akan membantu dalam memilih desain yang paling sesuai untuk aplikasi yang diinginkan, serta memberikan wawasan berharga untuk perbaikan lebih lanjut dalam pengembangan konverter daya.

3.3 Alur Tugas Akhir

Tugas akhir dilakukan dalam suatu urutan rangkaian yang sistematis untuk memastikan kelancaran dan kualitas penelitian. Gambar 3.2 menunjukkan diagram alir keseluruhan penelitian ini. Berikut adalah penjelasan untuk setiap bagiannya.

3.3.1 Studi Literatur


Studi literatur merupakan tahap awal dalam penelitian ini yang bertujuan untuk mengumpulkan informasi dari berbagai sumber seperti, jurnal, *conference paper*, dan artikel ilmiah. Tahap ini penting untuk memahami konsep dasar, metode yang telah digunakan sebelumnya, dan menemukan celah penelitian yang dapat menjadi landasan dalam penelitian ini. Studi literatur juga membantu dalam merumuskan hipotesis dan menetapkan kerangka teori yang kuat.

3.3.2 Analisis Kebutuhan Sistem

Analisis kebutuhan sistem merupakan langkah awal yang penting untuk memahami persyaratan dan spesifikasi dalam proses pengembangan penelitian ini. Proses ini melibatkan identifikasi kebutuhan fungsional dan nonfungsional dari sistem yang akan dibangun. Kebutuhan fungsional mencakup fitur dan fungsi yang harus dimiliki oleh sistem, seperti kemampuan model untuk menganalisis data, mengoptimalkan parameter sirkuit, dan menghasilkan desain yang memenuhi kriteria performa tertentu. Selain itu, perangkat lunak khusus diperlukan untuk memperoleh data set dan mengimplementasikan algoritma AI dan optimisasi.

Di sisi lain, kebutuhan nonfungsional berkaitan dengan kualitas sistem, termasuk keandalan, efisiensi, dan skalabilitas. Sistem yang dikembangkan harus dapat diandalkan dalam menghasilkan desain yang akurat dan konsisten dan mampu bekerja dengan efisien tanpa memerlukan sumber daya komputasi yang berlebihan. Data set yang berkualitas tinggi juga menjadi komponen krusial, mencakup data yang lengkap dan representatif untuk melatih model *machine learning* agar dapat melakukan prediksi. Selain itu, algoritma optimisasi yang digunakan juga harus mampu mengatasi kompleksitas dan dimensi data yang besar serta dapat beradaptasi dengan perubahan pada struktur rangkaian yang dianalisis. Analisis kebutuhan sistem yang komprehensif akan memastikan bahwa semua aspek penting telah optimal sehingga desain parameter sirkuit yang dihasilkan memenuhi persyaratan teknis dan beroperasi secara optimal.

Dengan analisis kebutuhan yang menyeluruh, nantinya akan dianalisis kebutuhan spesifikasi rangkaian untuk memastikan bahwa semua aspek penting telah optimal sehingga desain parameter sirkuit yang dihasilkan memenuhi persyaratan teknis dan beroperasi secara optimal. Pendekatan ini memastikan bahwa setiap elemen dari sistem



Gambar 3.2. Diagram Alir Penelitian

diperiksa dan diatur dengan hati-hati agar dapat berfungsi sesuai harapan dalam berbagai skenario operasional. Melalui tahapan ini, persyaratan teknis dapat dipenuhi dan sistem yang dihasilkan akan beroperasi dengan efisiensi dan keandalan yang tinggi.

3.3.3 Desain Parameter Sirkuit

Desain parameter sirkuit dalam proyek ini meliputi dua pendekatan utama, yaitu metode konvensional dan pendekatan berbasis AI. Pendekatan ini memungkinkan evaluasi yang komprehensif tentang keefektifan dan keakuratan dari setiap metode dalam penentuan parameter yang optimal.

3.3.3.1 Desain Parameter Sirkuit Konvensional

Desain parameter sirkuit konvensional merupakan pendekatan tradisional yang melibatkan pemilihan parameter berdasarkan pengetahuan teknis, pengalaman, dan analisis teoretis. Gambar 3.3 adalah penjabaran bagian desain parameter sirkuit konvensional dari diagram alir keseluruhan pada Gambar 3.2. Berikut adalah langkah-langkah utama dalam desain parameter sirkuit konvensional.

1. Analisis Rangkaian:

Pada tahap ini, analisis yang mendalam dilakukan terhadap rangkaian yang akan dirancang. Analisis ini melibatkan pemahaman terhadap spesifikasi teknis, persyaratan performa, dan lingkungan operasional dari sirkuit. Metode analisis teoretis dan simulasi dapat digunakan untuk mendapatkan gambaran awal tentang perilaku rangkaian.

2. Pemilihan Komponen:


Setelah analisis, langkah berikutnya adalah pemilihan komponen yang sesuai. Komponen utama yang dipilih adalah induktansi (L), kapasitansi (C), frekuensi *switching* (f_{sw}), *dead time* (t_d), dan *duty cycle* (d_{cycle}). Pemilihan ini memperhatikan berbagai faktor seperti nilai komponen, peringkat daya, dan nilai toleransi.

3. Pengujian Rangkaian:

Setelah komponen dipilih, rangkaian disusun dan diuji. Pengujian dilakukan untuk memastikan bahwa rangkaian berfungsi sesuai dengan desain awal dan memenuhi spesifikasi yang diinginkan. Pengujian ini mencakup pengukuran tegangan, arus, dan parameter lainnya. Pengujian juga dapat dilakukan menggunakan perangkat lunak simulasi yang tersedia.

4. Evaluasi Hasil:

Setelah pengujian, hasilnya dievaluasi untuk menentukan apakah rangkaian beroperasi sesuai dengan spesifikasi yang diinginkan. Jika hasil pengujian




Gambar 3.3. Diagram Alir Penelitian - Desain Parameter Sirkuit Konvensional

menunjukkan bahwa rangkaian belum memenuhi spesifikasi, maka proses kembali ke langkah *Pemilihan Komponen* untuk melakukan penyesuaian dan perbaikan yang diperlukan. Jika hasil pengujian sudah sesuai spesifikasi, maka proses desain

parameter sirkuit konvensional selesai dan siap untuk diterapkan atau diproduksi lebih lanjut.

3.3.3.2 Desain Parameter Sirkuit Berbasis Pendekatan AI




Gambar 3.4. Diagram Alir Penelitian - Desain Parameter Sirkuit *Machine Learning*

Desain parameter sirkuit menggunakan pendekatan berbasis AI menawarkan solusi yang lebih efisien dan adaptif dibandingkan dengan metode konvensional. Dengan memanfaatkan algoritma optimisasi, proses pemilihan dan pengoptimalan parameter sirkuit dapat dilakukan secara otomatis dan lebih akurat berdasarkan data yang dikumpulkan dari berbagai simulasi dan eksperimen.

Detail dari bagian desain parameter sirkuit *machine learning* dari Gambar 3.2 ditunjukkan dalam Gambar 3.4. Diagram alur *machine learning* menunjukkan terdapat beberapa tahapan dari pendekatan ini, yaitu pembuatan data set, pengembangan model *machine learning*, serta pengembangan metode optimisasi untuk mencapai performa optimal. Setiap tahap dirancang untuk mengintegrasikan kemampuan *machine learning* dalam memahami dan mengelola kompleksitas parameter sirkuit secara efektif.

1. Pembuatan Data Set:



Gambar 3.5. Diagram Alir Penelitian - Desain Parameter Sirkuit *Machine Learning* - Pembuatan Data Set

Pembuatan data set adalah langkah penting untuk analisis lebih lanjut dari hasil simulasi PLECS. Data set mencakup data set simulasi PLECS, data set kapasitansi, dan data set induktansi. Gambar 3.5 menunjukkan tahapan pembuatan data set, meliputi persiapan *environment* Python-PLECS, pembuatan data set kapasitansi dan induktansi, pengaturan parameter komponen, dan proses simulasi yang juga menyimpan data set simulasi.

1. Persiapan *Environment* Python - PLECS:

Proses ini akan mengintegrasikan antara simulasi PLECS dengan skrip Python. Hal ini memungkinkan otomatisasi proses simulasi dan pengolahan data sehingga dapat meningkatkan efisiensi. Dengan otomatisasi ini,

berbagai kombinasi parameter dapat diuji dengan cepat untuk menghasilkan data set yang komprehensif.

2. Pembuatan Data Set Kapasitansi dan Induktansi:

Data set kapasitansi dan induktansi berisi nilai-nilai induktansi dan kapasitansi dengan mempertimbangkan komponen aslinya. Berdasarkan jumlah seri dan paralel komponen, data set kapasitansi berisi berbagai nilai kapasitansi beserta dengan volumenya. Begitu pula dengan data set induktansi yang memberikan gambaran tentang nilai induktansi dan juga volume komponen tersebut.

3. Proses Simulasi:

Setelah persiapan pembuatan data set dilakukan, simulasi akan dilakukan untuk mengambil data dari simulasi PLECS sesuai dengan kombinasi parameter yang diatur. Nilai dari hasil perhitungan dan analisis Python akan disimpan dan menjadi data set simulasi PLECS.

2. Pembuatan Model *Machine Learning*:

Pembuatan model *machine learning* merupakan langkah krusial dalam proses desain parameter sirkuit dengan pendekatan berbasis AI. Tahap ini melibatkan pemilihan teknik *machine learning*, proses pelatihan, dan juga evaluasi model, seperti yang ditunjukkan dalam Gambar 3.6 yang merupakan detail dari diagram alur desain parameter sirkuit *machine learning* bagian pembuatan model.


1. Persiapan Data Set:

Proses pembuatan model *machine learning* diawali dengan persiapan data set simulasi PLECS. Persiapan ini mencakup ekstraksi dan pemberian data untuk memastikan kualitas dan relevansi input yang akan digunakan dalam model. Data set yang telah dipersiapkan kemudian diatur sedemikian rupa agar dapat mendukung proses pelatihan dan evaluasi model secara efektif. Langkah-langkah ini sangat penting untuk memastikan bahwa model yang dibangun memiliki akurasi dan kemampuan generalisasi yang baik.

2. Pemilihan Teknik *Machine Learning*:

Pemilihan teknik *machine learning* yang tepat sangat penting untuk memastikan model dapat menangkap pola dalam data dengan baik. Teknik yang dapat dipertimbangkan sudah dijelaskan secara rinci dalam Bagian 2.2.2.1 Pemilihan teknik ini juga mempertimbangkan tujuan analisis, sifat data, dan ketersediaan sumber daya komputasi.

3. Proses Pelatihan:



Gambar 3.6. Diagram Alir Penelitian - Desain Parameter Sirkuit *Machine Learning* - Pembuatan Model *Machine Learning*

Proses pelatihan melibatkan penggunaan data set yang telah disiapkan untuk melatih model. Model belajar dari data melalui iterasi dan optimasi parameter sehingga dapat meminimalkan kesalahan prediksi dan meningkatkan akurasi. Selama pelatihan, parameter model disesuaikan secara bertahap untuk mencapai performa terbaik.

4. **Evaluasi Model:**

Evaluasi model dilakukan untuk menilai kinerja model menggunakan data set validasi. Metrik evaluasi yang telah dijelaskan dalam Bagian 2.2.2.3 dapat digunakan untuk memastikan model bekerja dengan baik pada data yang tidak terlihat sebelumnya. Proses ini juga mencakup pengaturan *hyperparameter* untuk mengoptimalkan performa model. Model yang telah dilatih dan divalidasi kemudian disimpan untuk digunakan dalam prediksi dan analisis lebih lanjut. Jika model *machine learning* belum memiliki performa yang sesuai dengan kriteria, maka tahapan pembuatan model akan kembali ke proses iterasi, di mana penyesuaian pada parameter, pemilihan fitur, atau teknik *machine learning* yang berbeda mungkin diperlukan untuk mencapai hasil yang diinginkan. Langkah-langkah ini berulang hingga model memenuhi standar kinerja yang ditetapkan.

3. Pengembangan Metode Optimisasi

Model machine learning yang telah diperoleh dari proses sebelumnya akan digunakan sebagai basis prediksi di dalam metode optimisasi. Diagram alir detail dari bagian pengembangan metode optimisasi ini ditunjukkan oleh Gambar 3.7.

1. Pemilihan Metode Optimisasi:

Pemilihan metode optimisasi yang tepat sangat penting untuk memastikan bahwa parameter sirkuit yang dihasilkan adalah yang paling optimal. Metode dipilih berdasarkan kemampuan tiap metode untuk menangani kompleksitas masalah dan efisiensi dalam mencapai solusi yang diinginkan.


2. Implementasi Metode Optimisasi:

Implementasi metode optimisasi melibatkan penerapan algoritma optimisasi yang telah dipilih pada model yang telah dilatih. Proses ini bertujuan untuk menemukan kombinasi parameter sirkuit yang memberikan performa terbaik. Implementasi ini memastikan bahwa semua langkah optimisasi dilakukan dengan benar dan efisien.

3. Pengaturan Parameter Metode Optimisasi:

Pengaturan parameter metode optimisasi adalah langkah penting untuk memastikan bahwa algoritma optimisasi bekerja dengan efisien dan efektif. Parameter-parameter optimisasi, seperti jumlah iterasi, ukuran populasi, atau tingkat pembelajaran, disesuaikan untuk mengoptimalkan kinerja metode optimisasi. Pengaturan ini memungkinkan metode untuk mencapai hasil yang optimal dalam waktu yang lebih singkat.

4. Evaluasi Hasil:



Gambar 3.7. Diagram Alir Penelitian - Desain Parameter Sirkuit *Machine Learning* - Pengembangan Metode Optimisasi

Evaluasi hasil dilakukan untuk menilai apakah hasil optimisasi sudah sesuai dengan kriteria yang telah ditetapkan. Metrik performa yang relevan akan digunakan untuk memastikan bahwa kombinasi parameter yang dihasilkan memenuhi standar yang diinginkan. Jika hasil evaluasi menunjukkan bahwa performa masih belum sesuai dengan kriteria, proses akan kembali ke tahapan pengaturan parameter metode optimisasi. Penyesuaian lebih lanjut akan dilakukan hingga hasil yang optimal tercapai. Langkah ini memastikan

bahwa setiap iterasi membawa perbaikan signifikan terhadap performa keseluruhan sistem.

3.3.3.3 Perbandingan dan Analisis Hasil

Setelah model machine learning diterapkan dan parameter sirkuit dioptimalkan, langkah selanjutnya adalah melakukan perbandingan dan analisis hasil untuk menentukan desain sirkuit terbaik. Proses ini melibatkan evaluasi kinerja sirkuit yang dihasilkan, termasuk efisiensi, tegangan keluaran, arus keluaran, dan juga rugi-rugi daya yang dihasilkan. Hasil dari desain parameter sirkuit konvensional akan dibandingkan dengan desain parameter sirkuit berbasis pendekatan AI sehingga dapat diketahui metode yang memberikan hasil paling optimal.

3.3.4 Dokumentasi dan Pelaporan

Proses dokumentasi dan pelaporan adalah bagian terakhir dari penelitian ini. Tahap ini sangat penting untuk memastikan bahwa seluruh proses penelitian tercatat dengan baik, memungkinkan peneliti lain untuk memahami, mereplikasi, dan memverifikasi hasil yang telah dicapai. Dokumentasi yang baik juga membantu dalam menyusun pelaporan yang komprehensif sehingga memudahkan untuk dipublikasikan dalam jurnal ilmiah.

Dokumentasi dimulai dengan mencatat setiap langkah yang diambil selama proses penelitian, mulai dari pengumpulan data, pemilihan dan perancangan model *machine learning*, hingga tahap pelatihan dan evaluasi model. Setiap keputusan yang diambil, seperti alasan pemilihan algoritma tertentu, parameter yang digunakan, serta hasil percobaan, akan didokumentasikan secara rinci.

Di sisi lain, pelaporan penelitian melibatkan penyusunan dokumen yang menjelaskan tujuan, metodologi, hasil, dan kesimpulan dari penelitian secara jelas dan terstruktur. Laporan ini terdiri dari beberapa bab yang telah dijelaskan dalam Bagian 1.6.

BAB IV

PERANCANGAN DESAIN PARAMETER SIRKUIT

4.1 Pengantar

Bab IV membahas secara mendalam tentang parameter sirkuit *synchronous buck converter*. Pembahasan dalam bab ini meliputi rincian dari perancangan *synchronous buck converter* yang meliputi spesifikasi rangkaian, pemilihan komponen, dan juga implementasi rangkaian dalam perangkat lunak simulasi PLECS. Bagian selanjutnya membahas tentang rancangan desain parameter sirkuit dengan pendekatan berbasis AI. Data set, model *machine learning*, dan juga metode optimisasi akan dibahas dengan mendetail sehingga dapat memberikan panduan yang komprehensif dalam proses perancangan.

4.2 Rangkaian *Synchronous Buck Converter*

Sesuai dengan Bagian 3.2.1 tentang pemilihan topologi *buck converter*, rangkaian yang akan digunakan adalah *synchronous buck converter*. Pada bagian ini, akan dibahas secara rinci mengenai spesifikasi teknis, pemilihan komponen, serta implementasi rangkaian *synchronous buck converter* dalam perangkat lunak simulasi PLECS.

4.2.1 Spesifikasi Rangkaian

Spesifikasi teknis rangkaian buck converter yang digunakan dalam penelitian ini dirinci dalam Tabel 4.1. Tabel ini menyajikan parameter-parameter kunci meliputi tegangan masukan, tegangan keluaran, daya keluaran, riak arus dan tegangan, limit volume, dan efisiensi target.

Tabel 4.1. Spesifikasi Rangkaian *Synchronous Buck Converter*

Parameter	Nilai
Tegangan Masukan (V_{in})	48 V
Tegangan Keluaran (V_{out})	12 V
Daya Keluaran (P_o)	100 W
Riak Arus (ΔI_L)	$\leq 10 \%$
Riak Tegangan (ΔV_{out})	$\leq 1 \%$
Limit Volume (V_{lim})	$\leq 7 \text{ cm}^3$
Efisiensi Target	90 %

Rangkaian *synchronous buck converter* didesain untuk memberikan tegangan keluaran sebesar 12 V dengan masukan 48 V. Dengan daya keluaran yang diharapkan sebesar 100 W dan efisiensi target sebesar 90%, rangkaian ini dioptimalkan untuk aplikasi

yang membutuhkan konversi daya yang efisien dan andal. Konversi tegangan 48 V ke 12 V banyak digunakan dalam aplikasi perangkat elektronik dalam kendaraan listrik [36].

Selain itu, riak arus (ΔI_L) ditargetkan tidak melebihi 10% dari arus keluaran rata-rata. Riak tegangan (ΔV_{out}) juga dijaga di bawah 1 % untuk memastikan tegangan keluaran tetap stabil dan sesuai dengan kebutuhan implementasi. Limit volume (V_{lim}) dari desain ini adalah 7 cm³. Limit tersebut merupakan batas maksimum untuk memastikan rangkaian tetap kompak dan cocok untuk aplikasi dengan keterbatasan ruang. Efisiensi target sebesar 90% menunjukkan bahwa desain ini dirancang untuk meminimalkan rugi daya sehingga meningkatkan kinerja keseluruhan dan mengurangi panas yang dihasilkan.

Dengan spesifikasi ini, rangkaian *buck converter* dirancang untuk mencapai kinerja optimal dengan mempertimbangkan efisiensi, stabilitas tegangan keluaran, dan riak arus yang minimal, sambil tetap menjaga ukuran fisik yang kompak.

4.2.2 Penentuan Rentang Batasan Nilai Komponen

Tabel 4.2 menunjukkan pengaturan rentang nilai untuk setiap parameter. Setiap parameter akan diatur rentang batasan nilai tertentu dengan nilai yang umum digunakan, kecuali nilai *dead time* yang tergantung dari spesifikasi MOSFET.

Tabel 4.2. Rentang Batasan Nilai untuk Setiap Parameter

Parameter	Rentang Nilai
Induktansi (L)	30 μ H - 2000 μ H
Kapasitansi (C)	20 μ F - 1000 μ F
Frekuensi <i>Switching</i> (f_{sw})	20 kHz - 200 kHz
<i>Dead Time</i> (t_d)	Tergantung Spesifikasi MOSFET
<i>Duty Cycle</i> (d_{cycle})	0,2 - 0,35

Nilai L_{min} dan C_{min} ditentukan dengan mempertimbangkan performa *filtering* [5], sementara nilai L_{max} dan C_{max} dipilih berdasarkan biaya dan *power density* [7]. Nilai rentang frekuensi *switching* dipilih berdasarkan rentang yang dipaparkan oleh [7]. Di sisi lain, rentang *duty cycle* ditentukan berdasarkan desain efisiensi dalam Tabel 4.1 dan Rumus 2-21. Berikut adalah perhitungan untuk rentang *duty cycle*.

Dengan nilai $V_{out} = 12$ V, $V_{in} = 48$ V, dan $\eta = 0.90$, nilai $d_{cycle(min)}$ dapat dihitung sebagai berikut

$$d_{cycle(min)} = \frac{V_{out}}{V_{in} \times \eta} = \frac{12 \text{ V}}{48 \text{ V} \times 0,90} = \frac{12}{43,2} \approx 0,2778 \quad (4-1)$$

Sementara itu, dengan mempertimbangkan efisiensi rendah, efisiensi sebesar 70% digu-

nakan untuk mencari $d_{\text{cycle(max)}}$.

$$d_{\text{cycle(max)}} = \frac{V_{\text{out}}}{V_{\text{in}} \times \eta} = \frac{12 \text{ V}}{48 \text{ V} \times 0,70} = \frac{12}{33,6} \approx 0,3571 \quad (4-2)$$

Dengan demikian, rentang *duty cycle* untuk desain ini adalah antara 27,78% dan 35,71%. Dengan sedikit penyesuaian, rentang *duty cycle* yang digunakan adalah 20% dan 35%.

4.2.3 Pemilihan Komponen

Dalam penelitian ini, MOSFET, induktor, dan kapasitor dipilih berdasarkan komponen asli untuk memastikan akurasi dan sesuai dengan implementasi. Pemilihan komponen telah disesuaikan untuk spesifikasi pada Tabel 4.1. Dengan *datasheet* komponen sebagai acuan, beberapa parameter dapat diset dengan lebih realistis, seperti resistansi on (R_{ON}), *rise time* MOSFET (t_r), *fall time* MOSFET (t_f), *forward voltage* (V_D), dan parameter ukuran induktor dan kapasitor. Pemilihan komponen ini bertujuan untuk menciptakan data set yang realistis dan akurat sehingga hasil simulasi dapat diandalkan untuk pelatihan model *machine learning* dan perbandingan dengan hasil perhitungan konvensional. Berikut adalah komponen-komponen utama yang dipilih.

1. MOSFET:

MOSFET yang akan digunakan dalam penelitian ini sebagai dasar simulasi dan perhitungan adalah IRFS4310 dari Infineon. Tabel 4.3 menunjukkan parameter IRFS4310 yang akan digunakan.

Tabel 4.3. Parameter MOSFET yang Digunakan

Parameter	Nilai
Resistansi On (R_{ON})	5,6 mΩ
Rise Time (t_r)	110 ns
Fall Time (t_f)	78 ns
Turn-on Delay Time ($t_{d(\text{on})}$)	26 ns
Turn-off Delay Time ($t_{d(\text{off})}$)	68 ns
Forward Direction Voltage (V_D)	0,7 V
Kapasitansi Keluaran (C_{OSS})	540 pF
Total Gate Charge (Q_g)	170 nC
Gate Drive Volage (V_{gs})	10 V

Berdasarkan Tabel 4.3, terdapat 4 parameter MOSFET yang berkaitan dengan waktu, yaitu t_r , t_f , $t_{d(\text{on})}$, dan $t_{d(\text{off})}$. Nilai tersebut dapat digunakan untuk melengkapi Tabel 4.2 tentang rentang batasan nilai. Formula menunjukkan perhitungan nilai minimum *deadtime*.

Dengan nilai parameter berdasarkan 4.3 dan safety margin sebesar 1,2, Formula 2-19 dapat dihitung sebagai berikut:

$$\begin{aligned}
 t_{\text{dead_min}} &= \max(68 \text{ ns} + 78 \text{ ns}, 26 \text{ ns}) \times 1,2 \\
 &= \max(146 \text{ ns}, 26 \text{ ns}) \times 1,2 \\
 &= 146 \text{ ns} \times 1,2 \\
 &= 175,2 \text{ ns}
 \end{aligned} \tag{4-3}$$

Untuk menentukan rentang dead time terbesar yang praktis, $t_{\text{dead_max}}$ dapat dihitung dengan mengalikan nilai $t_{\text{dead_min}}$ dengan faktor 1,5:

$$t_{\text{dead_max}} = t_{\text{dead_min}} \times 1,5 = 175,2 \text{ ns} \times 1,5 = 262,8 \text{ ns} \tag{4-4}$$

Dari perhitungan di atas, *dead time* minimum ($t_{\text{dead_min}}$) yang diperlukan untuk MOSFET dalam desain ini adalah 175,2 ns dengan nilai *dead time* maksimum ($t_{\text{dead_max}}$) yang diatur menjadi 262,8 ns. Tabel 4.4 adalah tabel batasan rentang nilai yang telah dilengkapi untuk semua parameter.

Tabel 4.4. Rentang Batasan Nilai untuk Setiap Parameter (Lengkap)

Parameter	Rentang Nilai
Induktansi (L)	30 μH - 2000 μH
Kapasitansi (C)	20 μF - 1000 μF
Frekuensi <i>Switching</i> (f_{sw})	20 kHz - 200 kHz
<i>Dead Time</i> (t_d)	175.2 ns - 262.8 ns
<i>Duty Cycle</i>	0,2 - 0,35

2. Induktor:

Penelitian ini tidak hanya menganalisis induktor dari nilai induktansinya saja. Pada penelitian ini, inti toroid yang digunakan adalah seri TAF-200. Dari *datasheet* [34], 5 inti toroid dipilih dengan rentang nilai yang beragam berdasarkan ukurannya. Selain itu, kawat yang digunakan dalam penelitian ini adalah kawat tembaga jenis UEFN/U dengan diameter 1 mm, yang memastikan konsistensi dalam perhitungan. Tabel 4.5 menunjukkan daftar inti toroid yang dipilih dengan parameter-parameternya.

3. Kapasitor:

Kapasitor 25 V Nippon KZE digunakan dalam penelitian ini. Dalam *datasheet* [33], diambil nilai kapasitansi, faktor disipasi ($\tan\delta$), beserta dengan ukuran *casing*, yaitu ΦD dan juga L . Tabel 4.6 menunjukkan variasi nilai kapasitansi,

Tabel 4.5. Parameter MOSFET yang Digunakan

<i>Part Number</i>	OD (mm)	ID (mm)	Ht (mm)	AL Value (nH/T²)
T20-75-200	5,08	2,24	1,78	18,5
T50-75-200	12,7	7,7	4,83	33,0
T80B-75-200	20,2	12,6	9,53	71,0
T106B-75-200	26,9	14,5	14,6	124,0
T200B-75-200	50,8	31,8	25,4	160,0

ukuran *casing* dan volume yang memungkinkan analisis kapasitansi dengan lebih akurat. Di sisi lain, faktor disipasi dari kapasitor ini adalah 0,14 [33].

Tabel 4.6. Kapasitansi dan Ukuran Fisik Kapasitor Seri Nippon KZE 25 V


Kapasitansi (μF)	Ukuran Fisik (ΦD x L) (mm)	Volume (mm³)
47	5 × 11	215,9844949
100	6,3 × 11	342,8969842
220	8 × 11,5	578,0530483
330	8 × 15	753,9822369
470	8 × 20	1005,309649
680	10 × 20	1570,796327
820	10 × 25	1963,495408
1.000	12,5 × 20	2454,369261

4.2.4 Implementasi Rangkaian dalam PLECS

Implementasi rangkaian *synchronous buck converter* bertujuan untuk memastikan bahwa desain yang telah dibuat dapat berfungsi sesuai dengan spesifikasi yang diharapkan. Proses implementasi ini melibatkan pengaturan berbagai parameter, pengujian, dan optimasi rangkaian untuk mencapai kinerja yang optimal.

Untuk mencapai tujuan ini, simulasi digunakan sebagai langkah penting dalam proses implementasi. Simulasi memungkinkan evaluasi berbagai kondisi operasi dan skenario tanpa memerlukan prototipe fisik sehingga dapat menghemat waktu dan biaya. Dalam hal ini, perangkat lunak PLECS digunakan sebagai alat utama untuk menganalisis dan mengoptimalkan kinerja rangkaian *synchronous buck converter*.

Rangkaian *synchronous buck converter* yang digunakan dalam penelitian ini dirancang berdasarkan Gambar 3.2.1. Implementasi rangkaian dalam PLECS (Gambar 4.1) dapat dibagi menjadi beberapa bagian, yaitu ***Synchronous Buck Converter***, ***Controller***, ***Scope***, dan ***Export Data***.



Gambar 4.1. Implementasi Synchronous Buck Converter dalam PLECS

1. *Synchronous Buck Converter*:

Bagian ini mencakup komponen utama dari *synchronous buck converter* yang merepresentasikan rangkaian fisik dan pengukuran yang disimulasikan dalam PLECS. Setiap komponen memiliki parameter pengaturannya masing-masing dan dapat disesuaikan dengan kebutuhan penelitian.

1. **Blok Voltage Source DC (V_{in}):**

Blok ini menghasilkan tegangan dc konstan yang dapat diatur melalui parameter bloknya. Dalam penelitian ini, tegangan masukan (V_{in}) diset pada 48 V.

2. **MOSFET:**

Blok MOSFET yang digunakan dalam rangkaian ini adalah **MOSFET with Diode**. MOSFET dipilih karena karakteristik switching yang cepat dan efisiensi yang tinggi. Parameter blok **MOSFET with Diode** memungkinkan pengaturan R_{ON} sehingga dapat lebih merepresentasikan komponen sebenarnya.

3. **Induktor (L):**

Nilai induktor diset sesuai dengan pengaturan atau hasil perhitungan. Induktor ini bertanggung jawab untuk menyimpan dan melepaskan energi selama siklus *switching* sehingga penting untuk mengatur arus dan tegangan dalam rangkaian.

4. **Kapasitor (C):**

Dalam rangkaian PLECS, kapasitor dipasang paralel sesuai dengan konfigurasi standar untuk menyaring riak tegangan pada keluaran. Kapasitor ini membantu menjaga tegangan keluaran tetap stabil dan mengurangi fluktuasi yang disebabkan oleh switching.

5. **Komponen Pengukuran:**

Blok *Ammeter* dan *Voltmeter* digunakan untuk mengukur arus dan tegangan dalam rangkaian. Blok *Ammeter* ditempatkan dalam jalur arus untuk memantau arus yang mengalir melalui induktor dan beban, sedangkan blok *Voltmeter* dipasang paralel dengan beban untuk mengukur tegangan keluaran. Pengukuran ini penting untuk mengevaluasi kinerja rangkaian, termasuk efisiensi konversi daya dan stabilitas tegangan keluaran. Data yang diperoleh dari komponen pengukuran ini juga digunakan untuk analisis lebih lanjut dan validasi hasil simulasi.

6. **Beban:**

Dalam penelitian ini, beban yang digunakan adalah resistor sebesar $1,44\ \Omega$ supaya memiliki daya keluaran sebesar 100W pada 12V. Penggunaan beban resistif ini bertujuan untuk menyederhanakan analisis dan memastikan bahwa tegangan keluaran tetap stabil di bawah kondisi beban yang konstan. Resistor dipilih karena kemampuannya untuk menyediakan beban linier sehingga memudahkan pengukuran dan evaluasi kinerja rangkaian *synchronous buck converter*.

2. **Controller:**

Bagian *controller* bertanggung jawab untuk mengendalikan *switching* MOSFET secara sinkron. Bagian ini akan menghasilkan PWM dengan *dead time* yang dapat diatur.

1. **PWM:**

Blok *Symmetrical PWM* digunakan untuk menghasilkan sinyal PWM. Frekuensi sinyal PWM dapat diatur dari parameter di dalam blok *Symmetrical PWM*. Di sisi lain, nilai *duty cycle* menjadi masukan sehingga dapat menentukan rasio waktu aktif terhadap periode sinyal. *Duty cycle* ini dapat diatur berdasarkan kebutuhan kontrol untuk mencapai tegangan keluaran yang diinginkan.

2. **Dead Time:**

Blok ini digunakan untuk mengatur *dead time* antara sinyal PWM untuk *high-side* dan *low-side* MOSFET. *Dead Time* adalah interval waktu di

mana kedua MOSFET tidak aktif untuk mencegah kondisi *short-circuit*.

3. Logika Pemisahan PWM:

Sinyal PWM yang sudah diberi *dead time* adalah kendali untuk kedua MOSFET secara bersamaan. PWM perlu dipisah dahulu supaya dapat digunakan masing-masing MOSFET (*high-side* dan *low-side*).

- Blok > 0 : Blok logika ini melewatkan sinyal logika untuk MOSFET high side.
- Blok < 0 : Blok ini menghasilkan sinyal logika yang mengatur kondisi MOSFET low side.

3. Scope:

Dengan blok **Scope**, bagian ini dapat menampilkan bacaan blok **Ammeter** dan **Voltmeter**. **Scope** membantu dalam visualisasi data secara *real-time* selama proses simulasi.

4. Export Data:

Bagian ini digunakan untuk mengeksport data hasil simulasi untuk analisis lebih lanjut. Data yang diekspor adalah tegangan dan arus dari rangkaian. Eksport data memungkinkan peneliti untuk melakukan evaluasi dan validasi hasil simulasi dengan lebih mendetail.

1. Signal From:

Blok **Signal From** digunakan untuk mengambil sinyal dari berbagai titik dalam skematik simulasi.

2. Signal Outport:

Blok ini digunakan untuk mengeksport sinyal-sinyal yang telah diambil oleh blok **Signal From** ke luar lingkungan simulasi PLECS. Data yang diekspor dapat dianalisis lebih lanjut menggunakan perangkat lunak analisis data lainnya seperti Python, MATLAB atau Excel untuk mendapatkan wawasan yang lebih mendalam mengenai performa rangkaian.

4.3 Desain Parameter Sirkuit Berbasis Pendekatan AI

Bagian 4.3 ini akan diuraikan dalam tiga subbagian utama. Pertama, pembahasan mengenai data set akan dilakukan, yaitu data set simulasi, data set kapasitansi, dan data set induktansi. Kedua, model *machine learning* yang diterapkan dalam perancangan parameter sirkuit akan dijelaskan, meliputi jenis model, arsitektur, dan proses pelatihan. Terakhir, metode optimisasi dengan algoritma genetik akan diuraikan secara mendetail.

Dengan pendekatan ini, diharapkan dapat diperoleh desain parameter sirkuit yang

lebih efisien dan handal, yang mampu memenuhi spesifikasi dan kebutuhan aplikasi secara optimal.

4.3.1 Pembuatan Data Set

Ada tiga data set yang akan dibuat, yaitu data set simulasi PLECS, data set kapasitansi, dan data set induktansi. Berdasarkan diagram alir 3.5, data set kapasitansi dan induktansi diperlukan untuk menghasilkan data set simulasi PLECS.

4.3.1.1 Data Set Kapasitansi

Data set kapasitansi data tentang berbagai kombinasi nilai kapasitor yang dapat digunakan dalam rangkaian sesuai dengan rentang nilai (Tabel 4.4). Kombinasi dapat dilakukan secara seri dan paralel dengan jumlah maksimal kapasitor yang digunakan adalah 5 buah. Sementara itu, nilai volume adalah hasil penjumlahan volume tiap nilai kapasitansi berdasarkan Tabel 4.6.

Tabel 4.7. *Header* Parameter Data Set (C)

Parameter
Combination
Cap(uF)
Total_Volume(mm ³)

Tabel 4.7 menunjukkan *header* dari data set kapasitansi yang berisi kombinasi nilai kapasitansi, nilai kapasitansi dalam mikro Farad, dan juga total volume.

4.3.1.2 Data Set Induktansi

Data set induktansi dibuat berdasarkan komponen induktor yang sudah dipilih dalam Bagian 4.2.3. Tabel 4.8 menunjukkan *header* dari data set induktansi. Nilai N dalam data set akan diurutkan dari 1 sampai $N_{\max}$ (Rumus 2-17) dengan nilai $K_u = 0.5$. Kemudian, nilai induktansi (L) dapat dihitung dengan Rumus 2-16. Nilai induktansi dalam data set ini juga dibatasi oleh nilai rentang batasan nilai dalam Tabel 4.4.

4.3.1.3 Data Set Simulasi PLECS

Proses pembuatan data set dari simulasi PLECS meliputi beberapa tahapan, yaitu persiapan *environment* Python - PLECS, pengaturan parameter komponen, dan proses simulasi.

1. Persiapan *Environment* Python - PLECS:

Integrasi antara bahasa pemrograman Python dan PLECS memungkinkan otomatisasi proses simulasi dan pengolahan data sehingga dapat meningkatkan

Tabel 4.8. *Header* Parameter Data Set Induktansi (*L*)

Parameter
Part Number
OD (mm)
ID (mm)
Ht (mm)
AL Value (nH/T ²)
N
L (uH)

efisiensi. Proses ini dapat dilakukan dengan menggunakan modul *xmlrpc.client*. Akibatnya, proses simulasi PLECS dapat dikendalikan dengan kode Python. Berikut adalah kelebihan implementasi *xmlrpc.client* dalam konteks penelitian ini.

1. Kontrol Simulasi dengan Bahasa Pemrograman Python:

Dengan integrasi ini, simulasi PLECS dapat dikontrol langsung dengan kode Python. Proses ini memudahkan dilakukannya iterasi cepat atas parameter simulasi dan melihat hasilnya secara instan tanpa perlu interaksi manual dengan antarmuka PLECS.

2. Otomatisasi Pengolahan Data:

Setelah data simulasi diterima oleh Python melalui modul *xmlrpc.client*, data tersebut dapat langsung diproses, dianalisis, atau disimpan menggunakan berbagai *library* Python seperti NumPy, Pandas, atau Matplotlib. Integrasi ini memudahkan analisis dari proses simulasi yang dapat dilakukan berulang kali dengan variasi parameter yang berbeda.

2. Proses Simulasi:

Dalam setiap proses simulasi PLECS yang berjalan, terjadi proses pengolahan data dengan menggunakan Python. Data dapat menjadi basis untuk ekstraksi nilai tegangan dan arus ataupun perhitungan rugi-rugi daya. Proses simulasi terkadang membutuhkan penyesuaian parameter secara dinamis tergantung masukan dari lima parameter utama. Kode Python harus dipastikan dapat menangani hal sehingga data yang dihasilkan konsisten dan dapat direproduksi. Setelah proses simulasi berakhir, data hasil simulasi dan perhitungan akan disimpan dan dapat digunakan untuk pengembangan model *machine learning*. Beberapa tahapan perlu diperhatikan dalam proses simulasi ini, yaitu pengaturan simulasi itu sendiri, kombinasi lima parameter utama, perhitungan rugi-rugi daya, dan juga penyimpanan hasil data.

1. Pengaturan Simulasi:

Pengaturan simulasi meliputi parameter-parameter yang mengatur jalannya simulasi di PLECS. Berikut adalah pengaturan yang digunakan:

- **Time Span:** 10 ms, untuk memastikan simulasi berjalan cukup lama untuk mencapai kondisi steady-state
- **Solver:** *Variable-step*, untuk memungkinkan penyesuaian otomatis dari langkah waktu berdasarkan dinamika sistem
- Parameter simulasi lainnya menggunakan pengaturan bawaan dari perangkat lunak PLECS.

Dengan pengaturan parameter simulasi yang tepat, rangkaian *synchronous buck converter* dapat dianalisis secara mendalam untuk mengevaluasi kinerja dan efisiensi sistem dalam kondisi operasional yang realistis.

2. Kombinasi Parameter:

Kombinasi dari lima parameter utama akan dibuat menggunakan fungsi *itertools.product*. Jumlah total kombinasi sesuai dengan jumlah nilai yang dipilih pada masing-masing parameter. Nilai L dan C akan diambil dari masing-masing data set yang telah diperoleh sebelumnya. Sementara itu, nilai frekuensi *switching*, *dead time*, dan *duty cycle* dihasilkan dari rentang yg didefinisikan. Jika nilai-nilai untuk setiap parameter disimpan dalam L_values , C_values , fsw_values , t_dt_values , dan d_cycle_values , maka kombinasi dapat dibuat dengan Kode IV.1.

```
1 combinations = list(itertools.product(L_values, C_values
2 , fsw_values, t_dt_values, d_cycle_values))
```

Listing IV.1. Kode Kombinasi Parameter

Jumlah kombinasi sesuai dengan perkalian jumlah dari tiap parameter. Misal masing-masing parameter memiliki 4 nilai dari rentang batasnya, Kode IV.1 akan menghasilkan $4^5 = 1024$ kombinasi.

3. Perhitungan Rugi-Rugi Daya

Perhitungan rugi-rugi daya dilakukan berdasarkan data yang diterima dari simulasi PLECS (V_{out} dan I_{out}). Rumus rugi-rugi daya yang digunakan berdasarkan Bagian 2.2.1.5 untuk rangkaian *synchronous buck converter*. Rugi-rugi daya yang diperhitungkan ada 5 jenis, yaitu *conduction loss*, *output capacitance loss*, *dead time loss*, dan *gate charge loss*, dan total rugi-rugi daya. Tabel 4.9 menunjukkan nilai-nilai parameter yang diperlukan untuk perhitungan. Di sisi lain, total rugi-rugi daya cukup menambahkan seluruh rugi daya yang telah diperoleh.

Tabel 4.9. Parameter Rugi-Rugi Daya

Rugi Daya	Parameter	Rumus yang Digunakan
<i>Conduction Loss</i>	$R_{\text{ON-H}} = R_{\text{ON-L}} = 5,6 \text{ m}\Omega$	Rumus 2-3 dan Rumus 2-4
<i>Output Capacitance Loss</i>	$C_{\text{OSS-H}} = 540 \text{ pF}$	Rumus 2-5
<i>Dead Time Loss</i>	$t_{\text{d(on)}} = 26 \text{ ns}$ $t_{\text{d(off)}} = 68 \text{ ns}$ $t_{\text{r-H}} = t_{\text{r-L}} = 110 \text{ ns}$ $t_{\text{f-H}} = t_{\text{f-L}} = 78 \text{ ns}$ $V_{\text{D}} = 0,7 \text{ V}$	Rumus 2-7
<i>Gate Charge Loss</i>	$Q_{\text{g-H}} = Q_{\text{g-L}} = 170 \text{ nC}$ $V_{\text{GS}} = 10 \text{ V}$	Rumus 2-11

4.3.1.4 Penyimpanan Data Set Simulasi

Data set ini berisi hasil perhitungan berdasarkan kombinasi parameter rangkaian, yaitu nilai induktor (L), kapasitor (C), frekuensi *switching* (f_{sw}), *dead time* (t_{d}), dan *duty cycle* (d_{cycle}). Data set yang telah dibuat akan disimpan dalam format *Comma-Separated Values* (CSV). Format CSV dipilih karena memudahkan penggunaan kembali data set untuk pelatihan model *machine learning*. Data ini akan digunakan untuk melakukan analisis performa dan optimasi dari desain rangkaian. Setiap baris dalam data set mewakili kombinasi unik dari nilai parameter yang berbeda, memungkinkan evaluasi yang komprehensif terhadap berbagai konfigurasi. Dengan demikian, dapat ditentukan konfigurasi yang paling optimal untuk mencapai tujuan desain yang diinginkan.

4.3.2 Pembuatan Model *Machine Learning*

Bagian ini menjelaskan langkah-langkah penting dalam pembuatan model *machine learning*, dimulai dari persiapan data set hingga penyimpanan model yang telah dilatih. Proses ini mencakup pemilihan teknik yang tepat, pelatihan model, serta evaluasi kinerja untuk memastikan model bekerja dengan baik pada data yang belum terlihat sebelumnya. Setiap langkah yang dijelaskan bertujuan untuk menghasilkan model *machine learning* yang akurat dan dapat diandalkan dalam berbagai aplikasi.

4.3.2.1 Persiapan Data Set

Persiapan data set adalah langkah awal yang sangat penting dalam proses pembuatan model *machine learning*. Langkah-langkah ini meliputi pemisahan fitur dan label, skala data, serta pembagian data set menjadi subset pelatihan, validasi, dan pengujian.

1. Ekstraksi Fitur Data Set:

Untuk membangun model *machine learning* yang efektif, proses ekstraksi fitur input dan *output* dilakukan dari data set simulasi PLECS. Fitur input meliputi nilai induktansi (L), kapasitansi (C), frekuensi *switching* (f_{sw}), *dead time* (t_d), dan *duty cycle* (d_{cycle}), karena variabel-variabel ini merupakan parameter utama yang dapat dikendalikan dan memiliki dampak signifikan pada performa sirkuit. Fitur *output* yang menjadi target prediksi meliputi tegangan keluaran, arus keluaran, dan rugi-rugi daya. Ekstraksi ini melibatkan identifikasi dan pemisahan kolom yang relevan serta memastikan data siap untuk pelatihan model, termasuk langkah normalisasi untuk meningkatkan akurasi. Pendekatan ini memungkinkan model dapat memprediksi kinerja sirkuit berdasarkan konfigurasi parameter desain dan membantu mengoptimalkan desain agar memenuhi spesifikasi yang diinginkan.

2. Normalisasi Data:

Normalisasi data dalam persiapan data set digunakan untuk memastikan bahwa semua fitur input berada dalam skala yang sama. Hal ini bertujuan untuk meningkatkan kinerja dan stabilitas model *machine learning* selama pelatihan. Normalisasi membantu dalam mempercepat konvergensi model dan mencegah dominasi fitur dengan skala yang lebih besar terhadap fitur lainnya.

Dalam proses normalisasi ini, setiap fitur input, yaitu L , C , f_{sw} , t_d , dan d_{cycle} akan diubah skalanya sehingga berada dalam rentang yang sama, yaitu menjadi antara 0 dan 1.

3. Pembagian Data:

Data set dibagi menjadi tiga subset utama untuk memastikan model dapat dievaluasi dan divalidasi dengan benar:

- (a) **Data Latih (*Training Data*):** 70% dari total data set digunakan sebagai data latih. Data ini digunakan oleh model untuk belajar pola dan hubungan antara fitur input (L , C , f_{sw} , t_d , dan d_{cycle}) dan *output* yang diprediksi.
- (b) **Data Validasi (*Validation Data*):** 15% dari total data set digunakan sebagai data validasi. Data ini digunakan untuk mengevaluasi performa model selama proses pelatihan dan membantu dalam *tuning hyperparameter*.
- (c) **Data Uji (*Testing Data*):** 15% dari total data set digunakan sebagai data uji. Data ini tidak digunakan dalam proses pelatihan model, tetapi digunakan untuk mengevaluasi performa akhir model yang telah dilatih. Dengan demikian, model dapat dinilai kemampuannya dalam menggeneralisasi pola yang telah dipelajarinya.

4.3.2.2 Teknik *Machine Learning*

Jenis *machine learning* yang akan digunakan adalah *supervised learning* dengan model *neural network* (Lihat Bagian 3.2.2.2). Model *neural network* yang digunakan dalam proyek ini dirancang dengan menggunakan Keras, *library high-level* untuk *neural networks* yang berjalan di atas TensorFlow. Model ini memiliki beberapa lapisan (*layer*) yang dirancang untuk menangani data input dan *output*.

1. Lapisan Input (*Input Layer*):

Model menerima input dengan dimensi lima, yang terdiri dari fitur-fitur L , C , f_{sw} , t_d , dan d_{cycle} . Ini berarti bahwa setiap data input memiliki lima nilai yang mewakili parameter-parameter tersebut. Pada tahap ini, penting untuk memastikan bahwa semua fitur yang relevan dan informatif dimasukkan ke dalam model. Neuron dalam lapisan ini hanya meneruskan data ke lapisan berikutnya tanpa melakukan pemrosesan sehingga fokus utama adalah memastikan kualitas dan kelengkapan data input.

2. Lapisan Tersembunyi (*Hidden Layers*):

Lapisan tersembunyi pertama memiliki sejumlah neuron yang ditentukan oleh variabel Nh . Fungsi aktivasi yang digunakan adalah *ReLU* (Rectified Linear Unit), yang membantu model dalam menangani hubungan non-linier dalam data. Setelah lapisan *dense* ini, ditambahkan lapisan *batch normalization* yang berfungsi untuk menstabilkan distribusi data input ke lapisan berikutnya dan mempercepat proses pelatihan. Beberapa konfigurasi akan dieksplorasi untuk menentukan struktur optimal yang mampu menangkap pola-pola kompleks dalam data.

3. Lapisan Output (*Output Layer*):

Lapisan output terdiri dari neuron yang memiliki jumlah sesuai dengan keluaran yang diinginkan. Fungsi aktivasi yang digunakan adalah *Softplus*, yang memastikan bahwa nilai prediksi bersifat nonnegatif. Dalam penelitian ini, keluaran dari model *machine learning* berupa prediksi nilai parameter *buck converter*. Pemilihan fungsi aktivasi di lapisan keluaran akan disesuaikan dengan aplikasi ini untuk memastikan hasil yang akurat dan dapat diandalkan.

4.3.2.3 Proses Pelatihan

Model dilatih menggunakan data latih selama 100 *epochs* dengan ukuran *batch* 32. Dalam proses pelatihan tersebut, dilakukan percobaan berbagai kombinasi nilai *hyperparameter* untuk menemukan kombinasi terbaik yang menghasilkan kinerja optimal. Kombinasi *hyperparameter* tersebut adalah jumlah lapisan tersembunyi (H) dan jumlah neuron per lapisan (Nh) dari lapisan tersembunyi. Kombinasi dihasilkan meng-

gunakan teknik *grid search*. Data validasi digunakan untuk memonitor performa model, dan beberapa teknik seperti *early stopping* dan pengaturan *learning rate* diterapkan untuk menghindari *overfitting* dan memastikan model konvergen dengan baik. Setelah semua kombinasi *hyperparameter* diuji, model dengan kinerja terbaik pada data validasi akan dipilih untuk digunakan dalam prediksi lebih lanjut. Proses pelatihan dilakukan dengan menggunakan fungsi `fit` dari *library* Keras.

4.3.2.4 Evaluasi Model

Setelah pelatihan, model dievaluasi menggunakan data uji untuk mengukur kinerjanya. Metode evaluasi meliputi perhitungan metrik MSE, MAE, RMSE, R2, dan juga MAPE (lihat Bagian 2.2.2.3). Jika hasil evaluasi tidak memenuhi kriteria yang telah ditetapkan, proses sebelumnya, yaitu proses pelatihan dan optimasi *hyperparameter*, akan diulangi. Proses ini akan terus diulang hingga model memenuhi kriteria kinerja yang diinginkan. Dengan demikian, model yang dihasilkan diharapkan memiliki akurasi dan kemampuan generalisasi yang optimal.

4.3.2.5 Penyimpanan Model *Machine Learning*

Berdasarkan hasil evaluasi model, model yang menunjukkan kinerja terbaik dengan kombinasi jumlah lapisan tersembunyi (H) dan jumlah neuron (Nh) disimpan untuk digunakan lebih lanjut. Penyimpanan model dilakukan dengan menggunakan fungsi `save` dari Keras, yang menyimpan struktur model, bobot, dan konfigurasi pelatihan ke dalam sebuah *file*. Proses ini memungkinkan model yang telah dilatih untuk dimuat kembali dan digunakan tanpa perlu dilatih ulang.

4.3.3 Implementasi Metode Optimisasi

Algoritma genetik diimplementasikan sesuai dengan diagram alir yang telah dijelaskan sebelumnya (Gambar 2.3). Algoritma ini akan mengoptimalkan pemilihan nilai parameter L , C , f_{sw} , t_d , dan d_{cycle} . Beberapa parameter algoritma genetik perlu disesuaikan terlebih dahulu. Tabel 4.10 menunjukkan parameter algoritma genetik dan penjelasannya.

Tabel 4.10. Parameter Algoritma Genetik

Parameter	Nama Variabel	Penjelasan
Jumlah generasi	num_generations	Jumlah iterasi atau siklus yang akan dilakukan oleh algoritma genetik

Jumlah populasi awal	num_values	Jumlah kombinasi 5 parameter (L , C , f_{sw} , t_d , dan d_{cycle}) yang digunakan sebagai nilai awal
Jumlah <i>parent</i> yang dipilih	num_parents_mating	Jumlah individu yang dipilih sebagai orang tua untuk reproduksi
Jumlah gen yang dimutasi	mutation_rate	Banyak gen yang akan dimutasi dalam setiap individu

Implementasi algoritma genetik akan dibagi menjadi beberapa blok yang menggambarkan proses utama, dimulai dengan inisialisasi populasi hingga menghasilkan populasi baru melalui seleksi, *crossover*, dan mutasi.

1. Inisialisasi Populasi:

Blok pertama adalah inisialisasi populasi. Blok ini akan memberikan populasi awal sesuai dengan jumlah *num_values* dengan rentang nilai yang didefinisikan (lihat Tabel 4.2).

Algorithm 1 Parameter Optimization with *Genetic Algorithm*

- 1: **procedure** GENETIC_ALGORITHM_OPTIMIZATION
 - 2: **Initialize Population:**
 - 3: Create *num_values* arrays of discrete values for L , C , f_{sw} , t_d , and d_{cycle} .
-

2. Perhitungan Nilai *Fitness*:

Blok kedua digunakan untuk mencari nilai *fitness* berdasarkan hasil prediksi model *machine learning*. Fungsi objektif dalam algoritma genetik yang dibuat adalah total dari rugi-rugi daya sesuai dengan persamaan 4-5. Nilai dari fungsi objektif ini akan diminimalkan untuk mendapatkan solusi terbaik.

$$\min(\text{objective_value}) = P_{ON_H} + P_{ON_L} + P_{COSS} + P_D + P_G \quad (4-5)$$

Blok kedua menunjukkan nilai *fitness* akan dihitung untuk setiap kromosom di mana model *machine learning* digunakan untuk memprediksi nilai P_{ON_H} , P_{ON_L} , P_{COSS} , P_D , dan P_G . Prediksi ini kemudian digunakan untuk menghitung nilai fungsi objektif.

3. *Check Constraints*:

Blok ketiga adalah untuk memastikan setiap kromosom dalam populasi memenuhi batasan yang telah ditetapkan (Tabel 4.1). Jika sebuah kromosom tidak memenuhi batasan, maka akan diberikan penalti besar pada nilai *fitness*-nya.

```

4:   for generation = 1 to num_generations do
5:       Calculate Fitness Value:
6:       Load machine learning models: P_ON_H_P_ON_L, P_COSS, P_D, P_G.
7:       for each chromosome in the population do
8:           Predict P_ON_H_P_ON_L, P_COSS, P_D, P_G.
9:           Calculate the objective function value.
10:      end for

```

Fungsi `check_constraints` digunakan untuk memeriksa apakah kromosom memenuhi syarat-syarat yang telah ditentukan.

Algorithm 2 Check Constraints with Machine Learning Models

```

11:  Check Constraints:
12:  Load machine learning models: delta_current, delta_voltage,
    voltage.
13:  for each chromosome in the population do
14:      Predict voltage
15:      if not meet constraint then
16:          Apply penalty.
17:      end if
18:  end for

```

4. Seleksi *Parent* dan *Crossover*:

Blok keempat untuk memilih orang tua terbaik dari populasi berdasarkan nilai *fitness* yang paling minimal dan melakukan *crossover* untuk menghasilkan keturunan baru. Jumlah orang tua yang dipilih sesuai dengan pengaturan variabel `num_parents_mating` dalam Tabel 5.10.

```

19:  Parent Selection:
20:  Select num_parents_mating best parents based on minimum fitness values.
21:  Crossover:
22:  Initialize offspring array.
23:  Determine the crossover point.
24:  for each offspring in the offspring size do
25:      Combine genes from parents.
26:  end for

```

Seleksi orang tua memastikan bahwa individu terbaik dalam populasi memiliki peluang lebih besar untuk mewariskan gen mereka ke generasi berikutnya, sedangkan *crossover* menggabungkan gen dari beberapa orang tua untuk menciptakan variasi genetik dalam populasi.

5. Mutasi:

Blok mutasi digunakan untuk menerapkan mutasi pada keturunan yang dihasilkan dari proses sebelumnya. Variabel `mutation_rate` mengatur berapa banyak

gen yang akan dimutasi dalam setiap keturunan.

Algorithm 3 Parameter Optimization with *Genetic Algorithm* (cont.)

```
27:      Mutation:
28:      Apply mutations to maintain genetic diversity.
29:      for each offspring do
30:          Select mutation_rate genes to mutate.
31:          Mutate selected genes.
32:      end for
```

6. Pembaruan Populasi dan Penyimpanan *Output*:

Blok keenam adalah untuk memperbarui populasi dengan keturunan yang baru dihasilkan. Setelah jumlah generasi sejumlah *num_generations* yang ditentukan tercapai, proses algoritma genetik akan dihentikan, dan *output* terbaik yang diperoleh selama proses akan disimpan.

```
33:      Update Population:
34:      Replace the old population with the offspring.
35:      end for
36:      Save Output
37: end procedure
```

BAB V

HASIL DAN PEMBAHASAN

5.1 Pendahuluan

Bab V membahas hasil penelitian mengenai penerapan *Artificial Intelligence* (AI) dalam desain *synchronous buck converter* untuk meningkatkan efisiensi dan kinerja operasionalnya. Pembahasan ini dilakukan berdasarkan Bab IV tentang perancangan desain parameter sirkuit. Hasil dan pembahasan akan mencakup perbandingan antara metode konvensional dan pendekatan berbasis AI. Metode AI akan melingkupi evaluasi kinerja model *machine learning* dan analisis hasil optimisasi parameter menggunakan algoritma genetik.

Penerapan AI dalam desain rangkaian daya menawarkan peluang baru untuk mengatasi tantangan efisiensi dan kinerja *power converter*. Rumusan masalah yang ingin dijawab adalah bagaimana AI dapat meningkatkan efisiensi dan kinerja operasional *buck converter* dibandingkan dengan metode konvensional yang bergantung pada pengalaman dan perhitungan manual manusia.

5.2 Desain Parameter Sirkuit Konvensional

Desain parameter sirkuit konvensional akan dilakukan dengan metode yang telah dijelaskan pada Bagian 3.2.4. Perhitungan dilakukan berdasarkan Tabel 4.1 tentang spesifikasi rangkaian. Parameter komponen *switching*, induktor, dan kapasitor sama dengan yang telah dijelaskan pada Bagian 4.2.3 untuk memastikan konsistensi dalam desain sirkuit. Tabel 5.1 adalah hasil desain parameter sirkuit konvensional yang meliputi nilai L , C , f_{sw} , t_d , dan d_{cycle} . Subbagian 5.2.1 membahas lebih detail tentang perhitungan manual tiap parameter.

Tabel 5.1. Hasil Desain Parameter Sirkuit Konvensional

Parameter	Nilai
Induktansi	243,097 μH
Kapasitansi	21,692 μF
Frekuensi <i>Switching</i>	40 kHz
<i>Dead Time</i>	175,2 ns
<i>Duty Cycle</i>	22,5 %

5.2.1 Hasil Perhitungan

Pada subbagian ini, hasil perhitungan dari parameter-parameter sirkuit yang telah didesain akan disajikan. Perhitungan ini melibatkan berbagai rumus dan metode yang

diterapkan sesuai dengan spesifikasi yang diberikan. Setiap langkah perhitungan akan dijelaskan secara rinci untuk memastikan kejelasan dan akurasi dari hasil yang diperoleh.

5.2.1.1 Duty Cycle

Duty cycle yang dibutuhkan dalam rangkaian *buck converter* dapat dihitung dengan Rumus 2-21. Berdasarkan Tabel 4.1 tentang spesifikasi rangkaian, diperoleh nilai $V_{out} = 12 \text{ V}$, $V_{in} = 48 \text{ V}$, dan $\eta = 0,90$, maka nilai *duty cycle* dapat dihitung sebagai berikut:

$$D = \frac{12 \text{ V}}{48 \text{ V} \times 0,90} = 0,225 \text{ atau } 22,5\% \quad (5-1)$$

Jadi, nilai *duty cycle* yang diperoleh adalah 0,225 atau 22,5%.

5.2.1.2 Dead Time

Nilai *dead time* dapat ditentukan dengan Rumus 2-19, di mana nilai perhitungan dapat berdasarkan Tabel 4.3.

$$t_{dead_min} = \max(68 \text{ ns} + 78 \text{ ns}, 26 \text{ ns}) \times 1,2 = 175,2 \text{ ns} \quad (5-2)$$

Jadi, nilai *dead time* minimum (t_{dead_min}) adalah 175,2 ns.

5.2.1.3 Induktansi

Rumus 2-14 dapat digunakan untuk menghitung nilai induktansi yang dibutuhkan. Nilai frekuensi *switching* diatur ke 40 kHz, di mana nilai tersebut sudah sesuai dengan aplikasi MOSFET yang digunakan di bagian 4.2.3. Sebelum menghitung nilai induktansi, nilai perubahan arus induktor (ΔI_L) dapat dihitung terlebih dahulu dengan Rumus 2-15.

Dengan $P_{out} = 100 \text{ W}$, $V_{out} = 12 \text{ V}$, dan $\text{ripple} = 10\%$ atau 0,1:

$$\Delta I_L = 0,1 \times \frac{100 \text{ W}}{12 \text{ V}} = 0,833 \text{ A} \quad (5-3)$$

Kemudian, nilai induktansi dapat dihitung dengan $V_{in} = 48 \text{ V}$, $V_{out} = 12 \text{ V}$, $\Delta I_L = 0,833 \text{ A}$, $f_{sw} = 40 \text{ kHz}$, dan efisiensi (η) sebesar 90 % atau 0,9:

$$L = \frac{12 \text{ V} \times (48 \text{ V} - 12 \text{ V})}{0,833 \text{ A} \times 40 \text{ kHz} \times 48 \text{ V}} \times 0,9 = 243,097 \text{ } \mu\text{H} \quad (5-4)$$

Jadi, nilai induktansi (L) yang dibutuhkan adalah 243,097 μH .

5.2.1.4 Kapasitansi

Nilai kapasitansi dapat dihitung dengan Rumus 2-18. Nilai perubahan tegangan keluaran (ΔV_{out}) dapat diperoleh berdasarkan riak yang diatur sebesar 1%. Sementara

itu, nilai perubahan arus keluaran dan frekuensi *switching* sudah diperoleh sebelumnya.

$$\Delta V_{\text{out}} = 0,01 \times 12 \text{ V} = 0,12 \text{ V} \quad (5-5)$$

Akibatnya, nilai C_{out} dapat diperoleh sebagai berikut.

$$C_{\text{out}} = \frac{0,833 \text{ A}}{8 \times 40 \text{ kHz} \times 0,12 \text{ V}} = 21,692 \mu\text{F} \quad (5-6)$$

Jadi, kapasitansi keluaran (C_{out}) yang digunakan adalah 21,692 μF .

5.2.2 Evaluasi Kinerja

Evaluasi kinerja dilakukan dengan melakukan simulasi PLECS untuk memverifikasi performa *buck converter* yang didesain menggunakan pendekatan konvensional. Simulasi dilakukan untuk mendapatkan parameter tegangan, arus, dan rugi-rugi daya. Selain itu, volume dari induktansi dan kapasitansi yang sesuai juga akan diperoleh dari data set kapasitansi dan induktansi yang telah dibuat.

5.2.2.1 Hasil Simulasi

Pada subbagian ini, hasil simulasi PLECS akan disajikan untuk menunjukkan performa *buck converter* yang didesain. Hasil simulasi mencakup tegangan output, arus melalui induktor, dan efisiensi keseluruhan sistem. Selain itu, rugi-rugi daya yang terjadi pada rangkaian juga akan ditampilkan. Hasil ini digunakan untuk evaluasi akurasi dan validitas metode desain yang digunakan. Tabel 5.2 menunjukkan rincian hasil simulasi yang diperoleh dari simulasi PLECS untuk parameter perhitungan manual.

Tabel 5.2. Hasil Simulasi PLECS - Metode Konvensional

Parameter	Nilai
Arus Induktor (I_L)	7,228 A
Riak Arus Induktor (ΔI_L)	0,8429 A
Riak Arus Induktor Dalam Persentase (ΔI_L (%))	11,661 %
Tegangan Keluaran (V_{out})	10,395 V
Riak Tegangan Keluaran (ΔV_{out})	0,120 V
Riak Tegangan Keluaran Dalam Persentase (ΔV_{out} (%))	1,154 %
<i>Conduction Loss</i> ($P_{\text{ON-H}} - P_{\text{ON-L}}$)	0,0634 W; 0,229 W
<i>Output Capacitance Loss</i> (P_{COSS})	0,0249 W
<i>Dead Time Loss</i> (P_D)	0,0355 W

<i>Gate Charge Loss (P_G)</i>	0,136 W
Total Rugi Daya	0,489 W
Efisiensi	99,353 %

Jika dibandingkan dengan spesifikasi rangkaian yang diinginkan (Lihat Tabel 4.1), hasil simulasi metode konvensional sudah memenuhi efisiensi target sebesar 90 %. Akan tetapi, nilai ΔI_L dan ΔV_{out} tidak memenuhi desain yang seharusnya $\Delta I_L \leq 10 \%$ dan $\Delta V_{out} \leq 1\%$. V_{out} juga memiliki eror sebesar 13,38 % dari V_{out} yang diinginkan (12 V).

5.2.2.2 Volume

Pada subbagian ini, akan dibahas mengenai volume komponen induktansi (L) dan kapasitansi (C) yang diperoleh dari perhitungan manual. Berdasarkan nilai L dan C yang telah diperoleh, volume masing-masing komponen akan dicari berdasarkan data set yang telah dibuat sebelumnya. Volume komponen sangat penting untuk memastikan desain yang kompak dan sesuai dengan batasan fisik yang ditentukan.

Dengan mengetahui volume masing-masing komponen, evaluasi dapat dilakukan untuk menentukan apakah desain yang dihasilkan memenuhi batasan ukuran yang didefinisikan. Tabel 5.3 menunjukkan hasil pengecekan volume komponen induktansi dan kapasitansi berdasarkan data set kapasitansi dan induktansi.

Tabel 5.3. Volume Induktansi dan Kapasitansi - Metode Konvensional

Parameter	Volume
Induktor	4,28 cm ³
Kapasitor	2,896 cm ³
Total	7,176 cm ³

Jadi, hasil volume dari desain parameter sirkuit konvensional tidak sesuai dengan spesifikasi rangkaian yang sudah ditetapkan (Lihat Tabel 4.1), yaitu $\leq 7 \text{ cm}^3$.

5.3 Desain Parameter Sirkuit Berbasis Pendekatan AI

Bagian 5.3 membahas tentang hasil desain parameter sirkuit *synchronous buck converter* dengan pendekatan berbasis AI. Pembahasan mencakup analisis data set, penerapan model *machine learning*, dan juga implementasi algoritma genetik.

5.3.1 Data Set

Data set merupakan komponen krusial dalam penelitian ini karena digunakan sebagai dasar untuk melatih dan menguji model *machine learning* yang dikembangkan. Data set ini mencerminkan berbagai kondisi operasional dari sirkuit yang dioptimalkan, sehingga mampu menyediakan informasi yang dibutuhkan untuk memprediksi performa sirkuit secara akurat. Dalam bagian ini, akan dijelaskan hasil data set dan analisis data set.

5.3.1.1 Hasil Data Set

Data set yang digunakan dalam penelitian ini terdiri dari data simulasi yang mencakup berbagai kombinasi nilai L , C , f_{sw} , t_d , dan d_{cycle} . Data dikumpulkan dengan menggunakan simulasi PLECS untuk menghasilkan parameter-parameter seperti tegangan keluaran, arus keluaran, dan rugi-rugi daya. Tiap parameter diatur memiliki 10 variasi nilai sehingga kombinasi yang dihasilkan sebanyak 100.000 sampel dengan 10 variabel input dan 5 variabel *output*. Tabel 5.4 menunjukkan isi dari data set yang dihasilkan simulasi PLECS.

Tabel 5.4. Struktur Data CSV

Parameter	Jenis Data	Jenis Variabel
L	Desimal	Input
C	Desimal	Input
fsw	<i>Integer</i>	Input
t_d	Desimal	Input
d_cycle	Desimal	Input
average_current	Desimal	<i>Output</i>
delta_current	Desimal	<i>Output</i>
delta_current_percentage	Desimal	<i>Output</i>
average_voltage	Desimal	<i>Output</i>
delta_voltage	Desimal	<i>Output</i>
delta_voltage_percentage	Desimal	<i>Output</i>
P_ON_H	Desimal	<i>Output</i>
P_ON_L	Desimal	<i>Output</i>
P_COSS	Desimal	<i>Output</i>
P_D	Desimal	<i>Output</i>
P_G	Desimal	<i>Output</i>
P_total	Desimal	<i>Output</i>

5.3.1.2 Analisis Data Set

Analisis data set dilakukan untuk memahami karakteristik data yang akan digunakan dalam pelatihan model *machine learning*. Analisis yang dilakukan dengan mencari nilai koefisien variasi dengan Rumus 2-28. Tabel 5.5 menunjukkan koefisien variasi dari tiap parameter yang ada dalam data set.

Tabel 5.5. Koefisien Variasi (KV) Parameter

Parameter	Koefisien Variasi (KV)
L	0,878
C	0,525
fsw	0,522
t_d	0,128
d_cycle	0,174
average_current	1,404
delta_current	2,115
delta_current_percentage	0,719
average_voltage	1,409
delta_voltage	6,316
delta_voltage_percentage	2,556
P_ON_H	2,338
P_ON_L	2,004
P_COSS	0,522
P_D	1,640
P_G	0,522

Hasil koefisien variasi (KV) ini memberikan dasar yang kuat untuk analisis lebih lanjut dan pelatihan model *machine learning*. Berikut adalah beberapa temuan utama dari analisis ini

1. Variasi yang Signifikan:

- Fitur seperti *delta_voltage* memiliki KV yang sangat tinggi (6,316), menunjukkan bahwa terdapat variasi yang sangat besar relatif terhadap *mean*-nya.
- Fitur seperti *average_current* dan *average_voltage* juga memiliki KV yang tinggi (1,404 dan 1,409), menunjukkan variasi yang signifikan dalam data set ini.

2. Distribusi Data:

- KV yang lebih rendah pada fitur seperti *C* dan *fsw* menunjukkan bahwa data pada fitur-fitur ini lebih konsisten dan kurang bervariasi relatif terhadap

mean-nya.

5.3.2 Evaluasi Model *Machine Learning*

Bagian ini akan mengevaluasi model *machine learning* yang digunakan untuk memprediksi performa sirkuit berdasarkan data set yang telah dianalisis sebelumnya. Proses evaluasi ini bertujuan untuk menilai sejauh mana model dapat menghasilkan prediksi yang akurat dan dapat diandalkan.

5.3.2.1 Model *Machine Learning*

Analisis data set menunjukkan adanya variasi yang tinggi dalam setiap beberapa fitur. Model akan dibuat secara terpisah untuk setiap fitur sehingga dapat menghasilkan performa yang jauh lebih akurat. Sebelum diterapkan pada model *machine learning*, data set akan dinormalisasi untuk memastikan bahwa setiap fitur berada dalam skala yang sama, yang dapat meningkatkan akurasi prediksi. Untuk prediksi nilai ΔI_L ataupun ΔV_{out} terdapat pilihan untuk menggunakan nilai asli atau dalam persentasenya. Hasil analisis di bagian sebelumnya menunjukkan bahwa KV data set nilai asli ΔI_L ataupun ΔV_{out} dibandingkan nilai dalam persentase. Oleh karena itu, model ΔI_L ataupun ΔV_{out} akan menggunakan data set nilai dalam persentase. Tabel 5.6 menunjukkan model *machine learning* untuk setiap fitur yang akan diprediksi.

Tabel 5.6. Model *Machine Learning* yang Digunakan

Model <i>Machine Learning</i>	Hasil Keluaran
average_current	I_L
delta_current_percentage	ΔI_L (%)
average_voltage	V_{out}
delta_voltage_percentage	ΔV_{out} (%)
P_ON_H_P_ON_L	$P_{ON-H} - P_{ON-L}$
P_COSS	P_{COSS}
P_D	P_D
P_G	P_G

Model *machine learning* memiliki arsitektur yang telah disesuaikan dengan nilai *hyperparameter* (jumlah lapisan tersembunyi dan neuron) yang telah dioptimalkan. Setiap model memiliki arsitektur yang sama, tetapi nilai *hyperparameter* yang berbeda. Berikut adalah rincian tentang arsitektur model yang digunakan.

1. *Input Layer*:

- Fungsi aktivasi: *Rectified Linear Unit* (ReLU) karena kemampuannya untuk mempercepat konvergensi pelatihan dengan mengurangi efek *vanishing gra-*

dient, serta kemampuannya untuk memodelkan hubungan nonlinear dalam data.

2. *Hidden Layer*:

- (a) Fungsi aktivasi: ReLU (Rectified Linear Unit).
- (b) Jumlah *layer* dan neuron tergantung hasil *grid search* tiap model.

3. *Output Layer*:

- (a) Fungsi aktivasi: *Softplus* supaya dapat menjaga semua *output* tetap positif dan memberikan transisi yang halus, yang bermanfaat untuk masalah regresi di mana *output* yang lebih halus diperlukan.
- (b) Jumlah neuron pada *output layer* adalah 1 atau sesuai dengan jumlah fitur yang diprediksi.

4. *Loss Function*:

- (a) *Mean Absolute Error* (MAE) dan *Huber Loss* adalah pilihan yang akan digunakan sebagai *loss function*. MAE cocok untuk data dengan nilai kecil dan KV tinggi karena memberikan toleransi yang lebih besar terhadap fluktuasi nilai yang ekstrem. Kekurangan MAE adalah kurang sensitif terhadap variasi error, di mana kekurangan tersebut diatasi oleh *Huber Loss*.

5. *Optimizer*:

- (a) *Adam optimizer* digunakan untuk mempercepat konvergensi model dan mengoptimalkan pembelajaran.

5.3.2.2 Hasil Evaluasi

Bagian ini menyajikan hasil evaluasi dari model *machine learning* yang telah dikembangkan. Setiap model diuji dengan data set yang telah disebutkan sebelumnya dan performa model diukur berdasarkan metrik evaluasi. Tabel 5.7 dan Tabel 5.8 memperlihatkan metrik evaluasi performa model menggunakan dua *loss function* yang berbeda, yaitu *Mean Absolute Error* (MAE) dan *Huber Loss*.

Tabel 5.7. Hasil Evaluasi Model *Machine Learning* MAE

Model	MSE	MAE	RMSE	<i>R-squared</i>	MAPE (%)
average_current	0,057	0,057	0,238	0,994	0,200
delta_current_percentage	0,570	0,509	0,755	0,998	0,059
average_voltage	0,066	0,066	0,258	0,997	0,134
delta_voltage_percentage	0,109	0,118	0,331	0,996	0,118
P_ON_H_P_ON_L	0,0003523	0,0003523	0,019	0,993	0,112

P_COSS	0,003	0,003	0,057	0,983	0,071
P_D	0,002	0,002	0,049	0,932	0,254
P_G	0,010	0,010	0,102	0,995	0,047

Tabel 5.8. Hasil Evaluasi Model *Machine Learning* dengan *Huber Loss*

Model	MSE	MAE	RMSE	<i>R-squared</i>	MAPE (%)
average_current	0,001	0,041	0,037	0,998	0,231
delta_current_percentage	0,225	0,309	0,474	0,999	0,046
average_voltage	0,004	0,071	0,061	0,997	0,233
delta_voltage_percentage	0,113	0,137	0,336	0,996	0,146
P_ON_H_P_ON_L	0,00003605	0,007	0,006	-1,655	12863
P_COSS	0,00001617	0,004	0,004	0,975	0,109
P_D	0,00003720	0,008	0,006	0,845	3,633
P_G	0,0001678	0,014	0,013	0,991	0,074

5.3.2.3 Analisis Hasil

Metrik yang ditampilkan dalam dua tabel sebelumnya meliputi MSE, MAE, *R-squared*, dan MAPE. Berikut adalah analisis yang lebih spesifik berdasarkan masing-masing model.

1. Model *average_current*:

Huber menghasilkan hasil yang lebih baik dengan MSE lebih rendah (0,001 dengan 0,057), MAE lebih rendah (0,041 dibandingkan dengan 0,057), dan RMSE lebih rendah (0,037 dibandingkan dengan 0,238), menunjukkan tingkat kesalahan rata-rata dan variasi kesalahan yang lebih kecil dibandingkan dengan MAE.

2. Model *delta_current_percentage*:

Huber juga unggul secara signifikan dalam model ini dengan MSE, MAE, dan RMSE yang lebih rendah (0,225, 0,309, 0,474) dibandingkan MAE (0,570, 0,509, 0,755). *R-squared* yang sangat tinggi (0,999) menunjukkan kesesuaian yang sangat baik dengan data dibandingkan dengan MAE (0,998).

3. Model *average_voltage*:

Huber kembali menunjukkan performa yang lebih superior dengan nilai MSE, MAE, dan RMSE yang lebih rendah (0,004, 0,071, 0,061) dibandingkan dengan MAE (0,066, 0,066, 0,258), serta *R-squared* yang tinggi (0,997) menunjukkan model sangat cocok dengan data.

4. **Model *delta_voltage_percentage*:**

MAE memberikan hasil yang hampir serupa namun sedikit lebih baik dalam hal *R-squared* (0,996 dengan 0,995) dan MSE (0,109 dengan 0,113) dibandingkan dengan *Huber*. Namun, perbedaan ini minimal, menunjukkan bahwa kedua *loss function* hampir sama efektifnya untuk model ini.

5. **Model *P_ON_H_P_ON_L*:**

MAE menghasilkan *R-squared* yang positif (0,993) dibandingkan dengan nilai negatif pada *Huber* (-1,655), yang menunjukkan kecocokan yang lebih baik pada data aktual dan kesalahan prediksi yang lebih rendah. Nilai *R-squared* negatif menunjukkan bahwa model *Huber* berkinerja lebih buruk daripada model acak. Selain itu, *R-squared* negatif juga dapat terjadi ketika prediksi tidak berasal dari prosedur pemodelan yang sesuai dengan data tersebut. Selain itu, nilai MAPE yang sangat tinggi (12863%) mengindikasikan adanya kesalahan prediksi yang sangat besar.

6. **Model *P_COSS*:**

Huber unggul dengan nilai MSE dan MAE yang lebih rendah (0,000016 dan 0,004) dibandingkan dengan MAE (0,003 dan 0,003).

7. **Model *P_D*:**

MAE memberikan nilai yang lebih baik dibandingkan dengan *Huber* dalam semua metrik (MSE, MAE, RMSE) dan *R-squared*, menunjukkan kesalahan yang lebih rendah dan kecocokan yang lebih baik dengan data.

8. **Model *P_G*:**

Huber memberikan hasil yang lebih baik dengan nilai MAE dan RMSE yang lebih rendah serta *R-squared* yang lebih tinggi, menunjukkan performa model yang lebih baik.

Tabel 5.9 menunjukkan hasil model *machine learning* yang digunakan. Hasil tersebut meliputi *grid search* dan juga *loss function* yang dipakai.

Tabel 5.9. Model *Machine Learning* yang Digunakan dan *Loss Function*

Model <i>Machine Learning</i>	Jumlah Lapisan Tersembunyi dan Neuron	Loss Function
average_current	2 dan 256	<i>Huber</i>
delta_current_percentage	5 dan 64	<i>Huber</i>
average_voltage	1 dan 64	<i>Huber</i>

delta_voltage_percentage	5 dan 64	MAE
P_ON_H_P_ON_L	1 dan 32	MAE
P_COSS	1 dan 16	MAE
P_D	4 dan 64	MAE
P_G	2 dan 16	MAE

5.3.3 Optimisasi dengan Algoritma Genetik

Bagian ini membahas hasil algoritma genetik yang telah dirancang dalam Bagian 4.3.3. Tabel 5.10 menunjukkan beberapa parameter yang digunakan dengan nilai pengaturannya.

Tabel 5.10. Pengaturan Parameter Algoritma Genetik

Parameter	Nilai	Nama Variabel
Jumlah populasi awal	4	num_values
Jumlah parent yang dipilih	2	num_parents_mating
Jumlah generasi	100	num_generations
Jumlah gen yang dimutasi	2	mutation_rate


Pengaturan ini dirancang untuk mencapai keseimbangan antara eksplorasi dan eksploitasi dalam pencarian solusi optimal. Setiap parameter memiliki peran penting dalam menentukan efisiensi dan efektivitas dari proses optimisasi. Implementasi algoritma genetik dapat dilihat lebih detail dalam Bagian 4.3.3.

Subbagian ini menjelaskan hasil dari algoritma optimisasi yang telah dilakukan. Pembahasan mencakup analisis nilai *fitness* selama jumlah generasi, waktu eksekusi algoritma, dan hasil parameter yang diperoleh setelah optimisasi.

5.3.3.1 Hasil Nilai *Fitness*

Nilai *fitness* yang dihasilkan untuk 100 generasi ditampilkan dalam Gambar 5.1 di bawah. Grafik ini membantu mengamati bagaimana nilai *fitness* menurun seiring dengan bertambahnya jumlah generasi, menunjukkan konvergensi algoritma menuju solusi optimal.

Algoritma genetik dimulai dengan nilai *fitness* sebesar 2,51423. Dalam beberapa generasi, terlihat bahwa grafik stagnan, menunjukkan bahwa algoritma telah menemukan solusi optimal atau mendekati optimal pada tahap tersebut. Namun, variasi kecil dalam nilai *fitness* menunjukkan bahwa mutasi dan *crossover* terus mengeksplorasi ruang solusi



Gambar 5.1. Grafik Nilai *Fitness*

untuk memastikan bahwa solusi optimal global ditemukan. Nilai *fitness* paling kecil yang diperoleh adalah sebesar 0,5342398.

Perubahan nilai *fitness* yang signifikan pada awal generasi menunjukkan bahwa algoritma dengan cepat memperbaiki solusi dari populasi awal yang acak. Seiring berjalannya waktu, perbaikan menjadi lebih lambat, yang menunjukkan bahwa algoritma semakin mendekati konvergensi.

5.3.3.2 Waktu Eksekusi

Waktu eksekusi adalah total waktu yang diperlukan untuk menyelesaikan seluruh proses optimisasi. Tabel 5.11 di bawah ini menunjukkan total waktu eksekusi untuk 100 generasi dan rata-rata waktu per generasi.

Tabel 5.11. Waktu eksekusi optimisasi pada perangkat keras tertentu.

Parameter	Nilai
Total waktu eksekusi	2190 detik
Rata-rata waktu per generasi	21 detik

Waktu eksekusi menunjukkan seberapa cepat algoritma dapat menemukan solusi optimal dalam jumlah generasi yang telah ditentukan. Rata-rata waktu per generasi juga memberikan gambaran tentang efisiensi per generasi dalam proses evolusi.

5.3.3.3 Hasil Parameter Optimisasi

Bagian ini membahas hasil parameter optimal yang diperoleh setelah menjalankan algoritma optimisasi. Parameter-parameter ini merupakan solusi terbaik yang ditemukan oleh algoritma genetik berdasarkan nilai *fitness* yang dihasilkan selama proses evolusi. Tabel 5.12 menunjukkan hasil optimisasi yang diperoleh, yaitu nilai kelima parameter utama, yaitu L , C , f_{sw} , t_d , dan d_{cycle} .

Tabel 5.12. Hasil Desain Parameter Sirkuit Berbasis Pendekatan AI

Parameter	Nilai
Induktansi	285,8 μ H
Kapasitansi	127 μ F
Frekuensi <i>switching</i>	39,841 kHz
<i>Dead Time</i>	180,9 ns
<i>Duty Cycle</i>	24 %

5.3.4 Evaluasi Kinerja

Bagian ini akan membahas evaluasi kinerja dari desain parameter sirkuit dengan pendekatan berbasis AI. Evaluasi dilakukan dengan menganalisis hasil simulasi PLECS dan total volume yang dapat diperoleh dari data set.

5.3.4.1 Hasil Simulasi

Tabel 5.13 berisi parameter-parameter hasil optimisasi dan hasil simulasi PLECS. Nilai hasil optimisasi adalah nilai yang diperoleh oleh algoritma genetik atau nilai hasil prediksi model *machine learning*. Di sisi lain, hasil simulasi berisi nilai dari simulasi PLECS berdasarkan Tabel 5.12. Tabel juga menunjukkan eror dari nilai hasil prediksi model *machine learning* (hasil optimisasi) dengan nilai hasil simulasi sebagai validasi. Rumus 2-29 dapat digunakan untuk memperoleh nilai eror tersebut.

Tabel 5.13. Perbandingan Nilai Hasil Optimisasi dengan Nilai Hasil Simulasi PLECS

Parameter	Hasil Optimisasi	Hasil Simulasi	Error (%)
I_L	7,703883 A	7,719713 A	0,205059 %
ΔI_L (%)	9,732289 %	9,757301 %	0,256341 %
V_{out}	11,166117 V	11,126645 V	0,354752 %
ΔV_{out} (%)	0,164272 %	0,168323 %	2,406682 %

$P_{\text{ON-H}} - P_{\text{ON-L}}$	0,078587 W; 0,257976 W	0,077359 W; 0,256367 W	1,587404 %; 0,627615 %
P_{COSS}	0,024145 W	0,024784 W	2,578276 %
P_{D}	0,039344 W	0,038946 W	1,021927 %
P_{G}	0,134587 W	0,135459 W	0,643737 %

Secara umum, nilai error yang diperoleh relatif kecil, menunjukkan bahwa hasil optimisasi mendekati hasil simulasi. Sebagai contoh, I_L memiliki error sebesar 0,205059 %, sedangkan ΔI_L (%) menunjukkan error sebesar 0,256341 %. Tegangan keluaran (V_{out}) memiliki error sebesar 0,354752 %, sementara ΔV_{out} (%) memiliki error sebesar 2,406682 %.

Parameter lainnya, $P_{\text{ON-H}} - P_{\text{ON-L}}$, P_{COSS} , P_{D} , dan P_{G} juga menunjukkan error yang sangat kecil, masing-masing berkisar antara 0,627615 % hingga 2,578276 %. Secara keseluruhan, nilai eror yang kecil ini menunjukkan bahwa model optimisasi yang digunakan cukup akurat dalam merepresentasikan kondisi simulasi yang sebenarnya.

5.3.4.2 Volume

Volume induktor dan kapasitor dapat diperoleh dari data set berdasarkan nilai komponennya masing-masing (L dan C). Tabel 5.14 memberikan hasil nilai volume untuk induktor dan kapasitornya. Volume total dari keduanya (5,732 cm³) sudah sesuai dengan spesifikasi rangkaian dalam Tabel 4.1 ($V_{\text{lim}} \leq 7 \text{ cm}^3$).

Tabel 5.14. Volume Induktansi dan Kapasitansi - Metode Pendekatan Berbasis AI

Parameter	Volume
Induktor	2,289 cm ³
Kapasitor	3,443 cm ³
Total	5,732 cm ³

5.4 Perbandingan Hasil Desain Parameter Sirkuit

Bagian ini akan membandingkan hasil desain parameter sirkuit konvensional dengan hasil pendekatan berbasis AI. Tabel 5.15 adalah perbandingan hasil 5 parameter untuk tiap metode yang sudah diperoleh dari bagian-bagian sebelumnya. Hasil desain akan diuji dengan simulasi perangkat lunak PLECS untuk dianalisis efisiensi dan kinerja rangkaian. Selain itu, hasil grafik arus dan tegangan akan ditampilkan sebagai perbandingan.

Tabel 5.15. Perbandingan Hasil Desain Parameter Sirkuit Konvensional dengan Pendekatan Berbasis AI

Parameter	Konvensional	Pendekatan Berbasis AI
L	243,097 μH	285,8 μH
C	21,692 μF	127 μF
f_{sw}	40 kHz	39,841 kHz
t_d	175,2 ns	180,90 ns
d_{cycle}	22,5 %	24 %

5.4.1 Kinerja Desain Parameter Sirkuit

Berdasarkan nilai parameter dalam Tabel 5.15, simulasi PLECS dapat dijalankan sehingga dapat diperoleh kinerja rangkaian dari rangkaian, berupa nilai tegangan keluaran, riak tegangan, riak arus, dan juga rugi daya. Tabel 5.16 merangkum hasil simulasi desain untuk metode konvensional dan pendekatan berbasis AI.

Tabel 5.16. Hasil Simulasi Desain Parameter Sirkuit

Parameter	Konvensional	Pendekatan Berbasis AI
I_L	7,2284	7,7197
ΔI_L	0,8429	0,7532
ΔI_L (%)	11,6609	9,7573
V_{out}	10,3951	11,1266
ΔV_{out}	0,1200	0,0187
ΔV_{out} (%)	1,1543	0,1683
$P_{\text{ON-H}} - P_{\text{ON-L}}$	0,0634 dan 0,2292	0,0774 dan 0,2564
P_{COSS}	0,0249	0,0248
P_D	0,0355	0,0389
P_G	0,1360	0,1355
Total Rugi Daya	0,4889	0,5329
Efisiensi (%)	99,3535	99,3834

Kinerja desain rangkaian konvensional dan pendekatan berbasis AI menunjukkan performa yang mirip dalam beberapa parameter. Nilai parameter rugi-rugi daya, Nilai parameter rugi-rugi daya, seperti *conduction loss*, *output capacitance loss*, *dead time loss*, dan *gate charge loss*, menunjukkan bahwa kedua metode memiliki tingkat efisiensi yang sebanding (99,3535 % dibandingkan dengan 99,3834 %). Namun, pendekatan berbasis


AI menunjukkan keunggulan dalam beberapa aspek penting lainnya. Arus induktor yang dihasilkan oleh desain berbasis AI sedikit lebih tinggi dengan riak arus yang jauh lebih kecil (9,7573 % dibandingkan dengan 11,6609 %). Sementara itu, tegangan keluaran metode konvensional memiliki eror yang lebih besar (13,37 % dibandingkan dengan 7,28 %) dari tegangan keluaran 12 V yang diinginkan (Lihat Tabel 4.1).

5.4.2 Hasil Simulasi

Subbagian ini akan memaparkan hasil simulasi dari kedua metode desain parameter sirkuit. Hasil simulasi ini mencakup grafik arus dan tegangan sampai 10 ms. Pengaturan dari simulasi sesuai dengan pembahasan pada Bagian 4.3.1.3 tentang proses simulasi. Selain itu, terlihat bahwa terdapat perbedaan respons transien yang

5.4.2.1 Grafik Arus


Gambar 5.2 menunjukkan grafik arus untuk kedua metode. Grafik ini membantu dalam mengamati perbedaan kinerja antara metode konvensional (biru) dan pendekatan berbasis AI (jingga). Kedua arus memiliki nilai rata-rata arus yang sedikit berbeda, yaitu 7,2284 A dan 7,7197 A (Lihat Tabel 5.16).



Gambar 5.2. Grafik Arus - Metode Konvensional dan Metode Pendekatan Berbasis AI

Selain itu, terlihat bahwa terdapat perbedaan respons transien yang cukup signifikan antara kedua metode. Lonjakan arus pada metode pendekatan berbasis AI lebih tinggi pada awal operasi, tetapi mencapai keadaan stabil yang lebih cepat dibandingkan metode konvensional. Meskipun perbedaan dalam respons transien ini menarik untuk di-

analisis lebih lanjut, hal tersebut tidak menjadi fokus utama dari skripsi ini. Fokus utama adalah pada optimasi parameter desain meliputi L , C , f_{sw} , t_d , dan d_{cycle} .




Gambar 5.3. Grafik Arus - Metode Konvensional dan Metode Pendekatan Berbasis AI (4 ms - 5 ms)

Gambar 5.3 adalah grafik arus yang diperbesar untuk rentang waktu 4 ms - 5 ms. Rentang waktu tersebut dipilih karena sistem sudah dalam keadaan stabil. Riak arus keduanya terlihat cukup besar, yaitu 11,6609 % untuk metode konvensional dan 9,7573 % untuk pendekatan berbasis AI. Hal ini menunjukkan bahwa meskipun pendekatan berbasis AI lebih efektif dalam mengurangi riak arus, kedua metode masih menghasilkan fluktuasi yang signifikan dalam kondisi stabil.


5.4.2.2 Grafik Tegangan

Selain arus, grafik tegangan juga ditampilkan untuk menganalisis keadaan sistem. Gambar 5.4 adalah grafik tegangan untuk metode konvensional dan pendekatan berbasis AI. Grafik berwarna biru adalah hasil desain konvensional, sementara grafik berwarna jingga adalah untuk desain berbasis pendekatan AI. Kedua grafik memiliki nilai tegangan dengan selisih sekitar 1 V, yaitu 11,1266 V dan 10,3951 V. Respons sistem memiliki pola yang sama dengan grafik arus sebelumnya, di mana terdapat lonjakan nilai tegangan saat keadaan transien (desain berbasis pendekatan AI).

Walaupun terdapat perbedaan yang cukup signifikan saat respons transien, tegangan keluaran dari desain berbasis pendekatan AI lebih bagus dibandingkan hasil desain konvensional (Gambar 5.5). Error dan riak tegangan keluaran desain konvensional jauh lebih besar dibandingkan desain berbasis pendekatan AI.



Gambar 5.4. Grafik Tegangan - Metode Konvensional dan Metode Pendekatan Berbasis AI



Gambar 5.5. Grafik Tegangan - Metode Konvensional dan Metode Pendekatan Berbasis AI (4 ms - 5 ms)

5.4.2.3 Analisis Hasil Perbandingan

Setelah melakukan simulasi dan memperoleh hasil dari kedua metode, dilakukan analisis perbandingan untuk menilai kinerja masing-masing metode. Berikut adalah

beberapa poin utama dari hasil analisis:

1. Efisiensi:

Hasil simulasi menunjukkan bahwa desain menggunakan pendekatan berbasis AI memiliki efisiensi yang lebih tinggi dibandingkan dengan desain konvensional. Hal ini mengindikasikan bahwa algoritma *machine learning* lebih efektif dalam meminimalkan kehilangan daya dalam sirkuit.

2. Tegangan Keluaran:

Tegangan keluaran dari desain *machine learning* lebih stabil dan mendekati nilai yang diinginkan dibandingkan dengan desain manual. Stabilitas tegangan ini menunjukkan bahwa metode pendekatan berbasis AI mampu mengendalikan fluktuasi tegangan dengan lebih baik.

3. Riak Tegangan dan Riak Arus:

Desain berbasis pendekatan AI menunjukkan riak tegangan dan arus yang lebih rendah dibandingkan dengan desain konvensional. Riak yang lebih rendah ini menunjukkan bahwa desain berbasis pendekatan AI menghasilkan performa yang lebih baik dalam menjaga kestabilan sistem. Selain itu, riak tegangan dan arus dari hasil metode konvensional tidak memenuhi spesifikasi dalam Tabel 4.1 tentang spesifikasi rangkaian.

4. Volume:

Volume induktor dan kapasitor dari hasil desain berbasis pendekatan AI ($5,7322 \text{ cm}^3$) sudah sesuai dengan spesifikasi rangkaian ($\leq 7 \text{ cm}^3$). Di sisi lain, hasil desain konvensional melebihi batasan volume tersebut, yaitu sebesar $7,176 \text{ cm}^3$.

5. Kelebihan dan Kelemahan:

Hasil simulasi mengungkapkan kelebihan dan kekurangan dari kedua metode. Pendekatan berbasis AI menunjukkan efisiensi yang lebih tinggi dan tegangan keluaran yang lebih stabil, mengindikasikan kemampuan superior dalam mengelola kestabilan sirkuit dengan meminimalkan riak. Namun, metode ini memerlukan investasi yang lebih besar dalam hal sumber daya dan waktu komputasi, yang dapat menjadi pertimbangan penting dalam implementasi praktis. Sebaliknya, metode konvensional, meskipun lebih cepat dan mudah untuk diimplementasikan, sering kali kurang efisien. Hal ini tercermin dari tingkat kestabilan tegangan keluaran yang lebih rendah dan pemenuhan spesifikasi yang kurang optimal dibandingkan dengan pendekatan berbasis AI. Ini menyoroti pentingnya memilih pendekatan yang tepat berdasarkan kebutuhan spesifik dan sumber daya yang tersedia.

BAB VI

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Pada tugas akhir ini, penelitian yang bertujuan untuk mengoptimalkan parameter sirkuit rangkaian *synchronous buck converter* menggunakan metode pendekatan berbasis AI. Hasil dari pendekatan tersebut akan dibandingkan efisiensi, tegangan keluaran, arus keluaran, dan total rugi daya dengan metode konvensional.

Berdasarkan hasil simulasi dan analisis yang telah dilakukan, dapat disimpulkan bahwa:

1. Desain parameter sirkuit berbasis pendekatan AI memiliki efisiensi yang lebih tinggi (99,3834 %) dibandingkan dengan desain konvensional (99,3535 %).
2. Error tegangan keluaran yang dihasilkan oleh metode pendekatan berbasis AI lebih rendah (7,28 %) dibandingkan dengan desain konvensional (13,37 %).
3. Riak tegangan keluaran hasil dari metode pendekatan berbasis AI lebih rendah (0,0187 V atau 0,1683 %) dibandingkan dengan desain konvensional (0,1200 V atau 1,1543 %).
4. Desain parameter sirkuit berbasis pendekatan AI juga memiliki riak arus yang lebih rendah (0,7532 A atau 9,7573 %) dibandingkan dengan desain konvensional (0,8429 A atau 11,6609 %).

Dengan demikian, tujuan penelitian untuk mengoptimalkan parameter sirkuit dengan metode pendekatan berbasis AI telah tercapai. Temuan ini menunjukkan bahwa desain parameter sirkuit dengan pendekatan AI lebih efektif dalam meningkatkan efisiensi dan kinerja rangkaian *buck converter* dibandingkan dengan desain parameter sirkuit konvensional.

6.2 Saran

Berdasarkan hasil penelitian ini, beberapa saran yang dapat diberikan untuk penelitian selanjutnya adalah sebagai berikut:

1. Menambahkan komponen *parasitic* induktor dan kapasitor dalam rangkaian *buck converter* sehingga dapat menghasilkan model yang lebih sesuai dengan implementasi.
2. Mengembangkan teknik kendali *buck converter* supaya respons transien sistem dapat diperbaiki. Misalnya dengan menggunakan metode kendali adaptif atau kendali

berbasis *machine learning*.

3. Memperluas penelitian dengan membandingkan metode *machine learning* lainnya, seperti *reinforcement learning* atau *deep learning*.

Saran-saran ini diharapkan dapat membantu dalam pengembangan penelitian tentang desain parameter sirkuit *buck converter* lebih lanjut dan peningkatan kinerja *buck converter* melalui metode optimasi yang lebih baik dan lebih efisien.

DAFTAR PUSTAKA

- [1] Z. Gong, B. A. V. D. Ven, K. M. Gupta, C. D. Silva, C. H. Amon, H. J. Bergveld, M. C. Donkers, and O. Trescases, "Distributed control of active cell balancing and low-voltage bus regulation in electric vehicles using hierarchical model-predictive control," *IEEE Transactions on Industrial Electronics*, vol. 67, 2020.
- [2] J. A. Sanguesa, V. Torres-Sanz, P. Garrido, F. J. Martinez, and J. M. Marquez-Barja, "A review on electric vehicles: Technologies and challenges," 2021.
- [3] S. Habib, M. M. Khan, F. Abbas, A. Ali, M. T. Faiz, F. Ehsan, and H. Tang, "Contemporary trends in power electronics converters for charging solutions of electric vehicles," *CSEE Journal of Power and Energy Systems*, vol. 6, 2020.
- [4] S. Thangavel, D. Mohanraj, T. Girijaprasanna, S. Raju, C. Dhanamjayulu, and S. M. Muyeen, "A comprehensive review on electric vehicle: Battery management system, charging station, traction motors," 2023.
- [5] X. Li, X. Zhang, and F. Lin, "Multi-objective design of output lc filter for buck converter via the coevolving-amosa algorithm," *IEEE Access*, vol. 9, 2021.
- [6] F. Blaabjerg, H. Wang, I. Vernica, B. Liu, and P. Davari, "Reliability of power electronic systems for ev/hev applications," *Proceedings of the IEEE*, vol. 109, 2021.
- [7] X. Li, X. Zhang, F. Lin, and F. Blaabjerg, "Artificial-intelligence-based design for circuit parameters of power converters," *IEEE Transactions on Industrial Electronics*, vol. 69, 2022.
- [8] B. Hauke and T. Instruments, "Basic calculation of a boost converter's power stage," 11 2022. [Online]. Available: <https://www.ti.com/lit/an/slva477b/slva477b.pdf>
- [9] V. Aase and M. T. Inc., "Buck converter design and feedback controller using core independent peripherals," 2020. [Online]. Available: <https://www.ti.com/lit/an/slva477b/slva477b.pdf>
- [10] Z. Xiao, Z. Li, Z. He, H. Wang, Y. Tang, and A. Luo, "Computer-aided time-domain operation and design optimization of resonant converters," *IEEE Journal of Emerging and Selected Topics in Power Electronics*, vol. 11, 2023.
- [11] L. F. Costa, Y. Ko, and M. Liserre, "Design and experimental analysis of a modular smart transformer architecture," *2023 IEEE Energy Conversion Congress and Exposition (ECCE)*, pp. 861–868, 10 2023.
- [12] Z. Lv, J. Zhuang, J. Wu, L. Liu, Z. Yuan, Z. Jiang, and X. Wang, "Parameter optimization design of the commutation circuit of a hybrid dc-current-limiting circuit breaker," *Energies*, vol. 16, 2023.
- [13] Y. Cui, Y. Wang, and X. Ma, "Parameters design and optimization of a high frequency, interleaved, dual-buck, bidirectional, grid-connected converter," *Electronics (Switzerland)*, vol. 8, 2019.

- [14] A. Andreta, L. F. L. Villa, Y. Lembeye, and J. C. Crebier, "A novel automated design methodology for power electronics converters," *Electronics (Switzerland)*, vol. 10, 2021.
- [15] S. Fan, N. Cao, S. Zhang, J. Li, X. Guo, and X. Zhang, "From specification to topology: Automatic power converter design via reinforcement learning," *IEEE/ACM International Conference on Computer-Aided Design, Digest of Technical Papers, ICCAD*, vol. 2021-November, 2021.
- [16] M. H. Jahanbakhshi and M. Etezadinejad, "Modeling and current balancing of interleaved buck converter using single current sensor," *ICEE 2019 - 27th Iranian Conference on Electrical Engineering*, 2019.
- [17] J. M. Martinez-Heredia, F. Colodro, J. L. Mora-Jimenez, A. Remujo, J. Soriano, and S. Esteban, "Development of gan technology-based dc/dc converter for hybrid uav," *IEEE Access*, vol. 8, 2020.
- [18] Z. W. Khan, H. Minxiao, C. Kai, L. Yang, and A. u. Rehman, "State of the art dc-dc converter topologies for the multi-terminal dc grid applications: A review," in *2020 IEEE International Conference on Power Electronics, Smart Grid and Renewable Energy (PESGRE2020)*, 2020, pp. 1–7.
- [19] M. Sobaszek, "Self-tuned class-d audio amplifier with post-filter digital feedback implemented on digital signal controller," *IEEE Transactions on Circuits and Systems I: Regular Papers*, vol. 67, 2020.
- [20] B. Chandrasekar, C. Nallaperumal, S. Padmanaban, M. S. Bhaskar, J. B. Holm-Nielsen, Z. Leonowicz, and S. O. Masebinu, "Non-isolated high-gain triple port dc-dc buck-boost converter with positive output voltage for photovoltaic applications," *IEEE Access*, vol. 8, 2020.
- [21] A. Penin, *Pulse-Width Modulation Regulators*. Cham: Springer International Publishing, 2015, pp. 317–337. [Online]. Available: https://doi.org/10.1007/978-3-319-16351-2_12
- [22] M. Zhang, N. Ren, Q. Guo, W. Yao, and K. Sheng, "An investigation of near-field radiated emission for silicon carbide power module in buck converter," *2020 17th China International Forum on Solid State Lighting and 2020 International Forum on Wide Bandgap Semiconductors China, SSLChina: IFWS 2020*, 2020.
- [23] C. B. Barth, T. Foulkes, I. Moon, Y. Lei, S. Qin, and R. C. Pilawa-Podgurski, "Experimental evaluation of capacitors for power buffering in single-phase power converters," *IEEE Transactions on Power Electronics*, vol. 34, 2019.
- [24] R. W. Rachmad, T. Abuzairi, R. W. Rachmad, and T. Abuzairi, "Efficiency comparison of asynchronous and synchronous buck converter with variation in duty cycle and output current," *Buletin Ilmiah Sarjana Teknik Elektro*, vol. 5, 2023.
- [25] R. Semiconductor, "Efficiency of buck converter," ROHM CO., Ltd., Tech. Rep., 2022.
- [26] A. Burkov, *The Hundred-Page Machine Learning Book-Andriy Burkov*. Expert Systems, 2019, vol. 5.

- [27] K. Pawluszek-Filipiak and A. Borkowski, "On the importance of train-test split ratio of datasets in automatic landslide detection by supervised classification," *Remote Sensing*, vol. 12, 2020.
- [28] S. Naeem, A. Ali, S. Anam, and M. M. Ahmed, "An unsupervised machine learning algorithms: Comprehensive review," *International Journal of Computing and Digital Systems*, vol. 13, 2023.
- [29] B. Hambly, R. Xu, and H. Yang, "Recent advances in reinforcement learning in finance," *Mathematical Finance*, vol. 33, 2023.
- [30] H. Magapu, K. Sai, and B. Goteti, "Human deep neural networks with artificial intelligence and mathematical formulas," *International journal of emerging science and engineering*, vol. 12, no. 4, p. 1–2, Mar 2024.
- [31] B. P. dan Pembinaan Bahasa, "Kbbi vi daring." [Online]. Available: <https://kbbi.kemdikbud.go.id/entri/optimisasi>
- [32] S. Katoch, S. S. Chauhan, and V. Kumar, "A review on genetic algorithm: past, present, and future," *Multimedia Tools and Applications*, vol. 80, 2021.
- [33] U. C.-C. Inc., "Kze-series," Nippon Chemi-Con Corporation, Tech. Rep., 2019.
- [34] A. Magnetics, "Taf200 toroid core," Alliance Magnetic Limited, Tech. Rep., 2019.
- [35] H. Eraydin and A. F. Bakan, "Efficiency comparison of asynchronous and synchronous buck converter," in *2020 6th International Conference on Electric Power and Energy Conversion Systems (EPECS)*, 2020, pp. 30–33.
- [36] M. Ramesh, B. Mallikarjuna, and T. Rajasekar, "A novel investigation on single-input three-output dc-dc buck converter for electrical vehicles," in *2021 7th International Conference on Electrical Energy Systems (ICEES)*, 2021, pp. 141–146.